Föreläsning 5

Statistisk översiktskurs

Anders Fredriksson

Statistiska Institutionen
Stockholms Universitet

30 mars 2026

Föreläsning 5 - vart är vi på väg?

- **Vi börjar med två illustrationer i R:**
  - Vi tittar på ett stort antal fiktiva "opinionsundersökningar" med slumpmässiga urval (punktskattning av en andel mm.)
  - Vi drar slumpmässiga urval från ett dataset (en tänkt population) där två variabler är (linjärt) associerade med varandra. Vad kan vi säga, från våra urval, om hur sambandet ser ut? (regression mm.)

Exempel 1 - fiktiva opinionsundersökningar

- Vi tittar på ett antal exempel på fiktiva ”opinionsundersökningar”
- Antag att partiet S har 40% opinionsstöd (”Skulle rösta på S om det vore val idag.”) bland de röstberättigade (vår population)
- Vi visar fördelningar av andelen som svarar att de skulle rösta på S, från ett antal slumpvisa urval av 100 individer från de röstberättigade
- Illustration av vad som beskrivs i början av kapitel 13 i kursboken
- Andel från ett urval (eng: sample proportion)

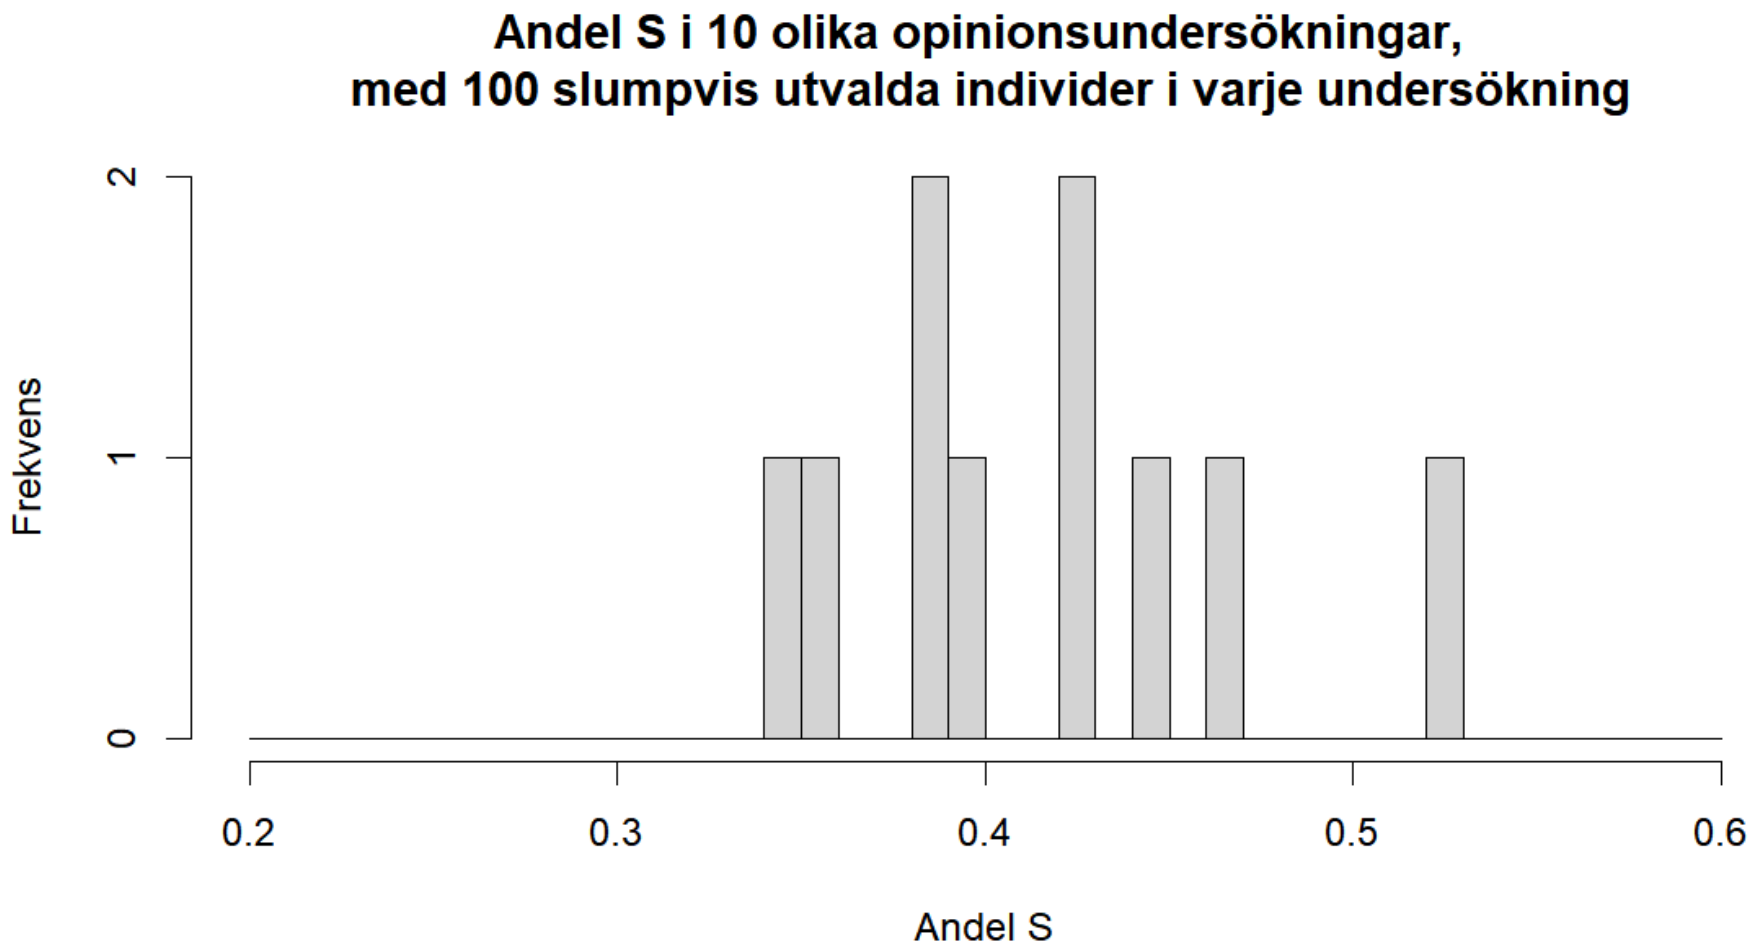
Andel S i 10 olika opinionsundersökningar,
med 100 slumpvis utvalda individer i varje undersökning
Frekvens
0
1
2
0.2
0.3
0.4
0.5
0.6
Andel S

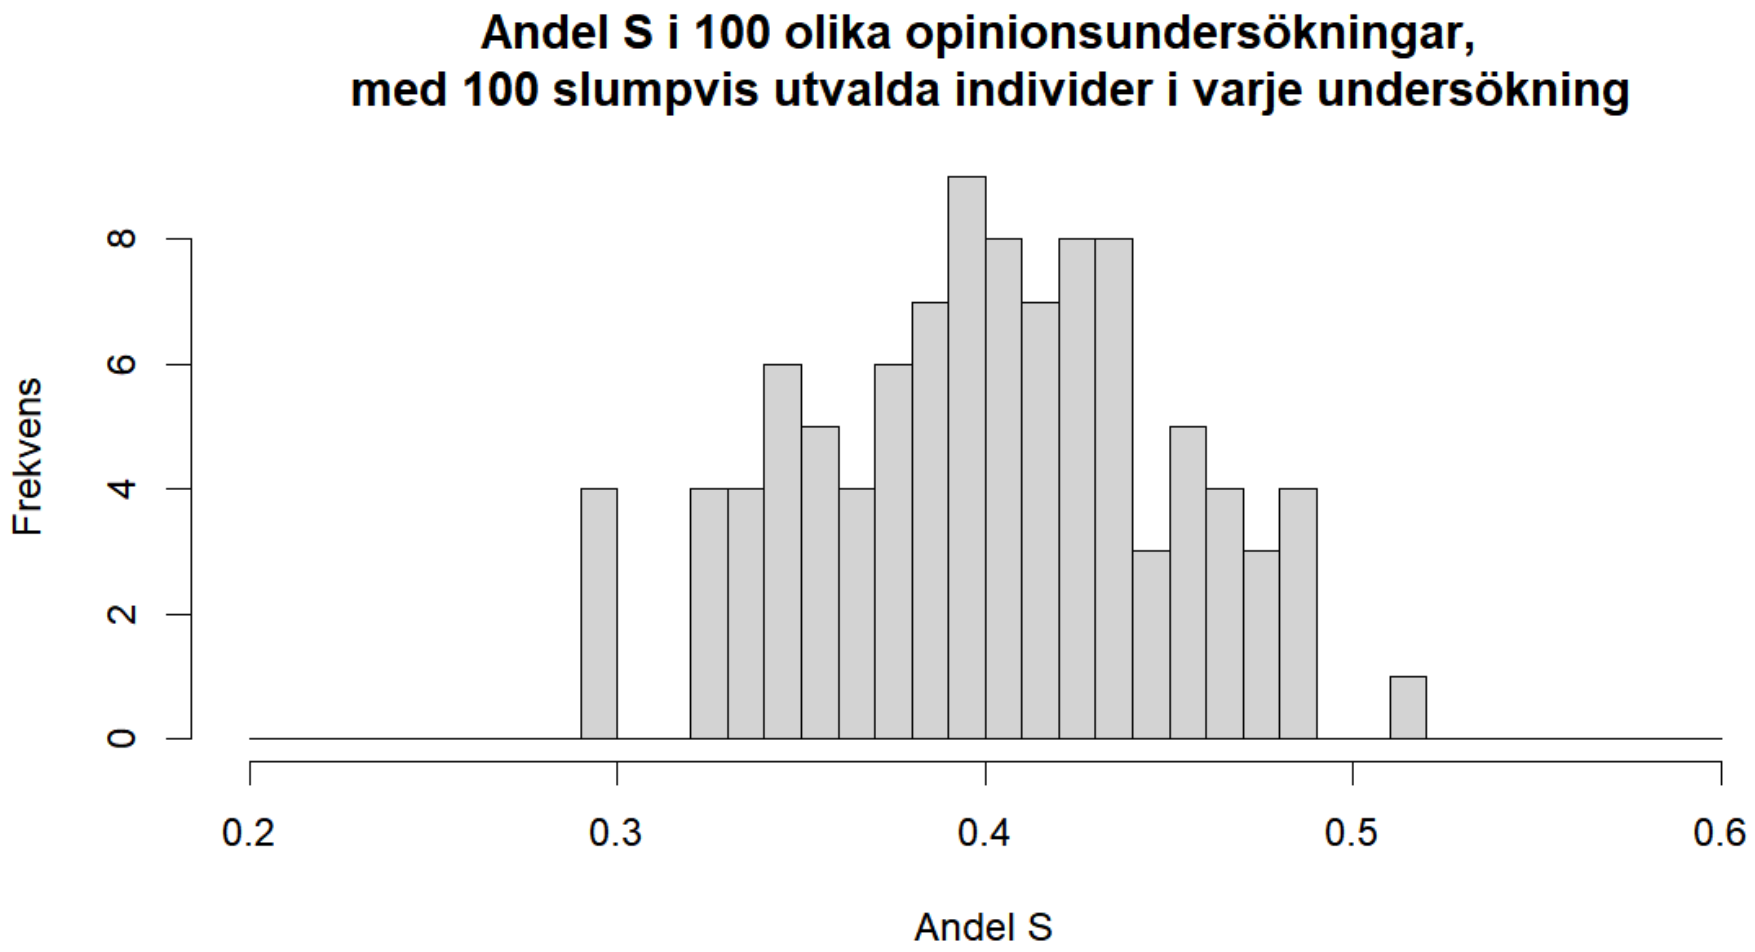
Andel S i 100 olika opinionsundersökningar,
med 100 slumpvis utvalda individer i varje undersökning
Frekvens
0
2
4
6
8
0.2
0.3
0.4
0.5
0.6
Andel S

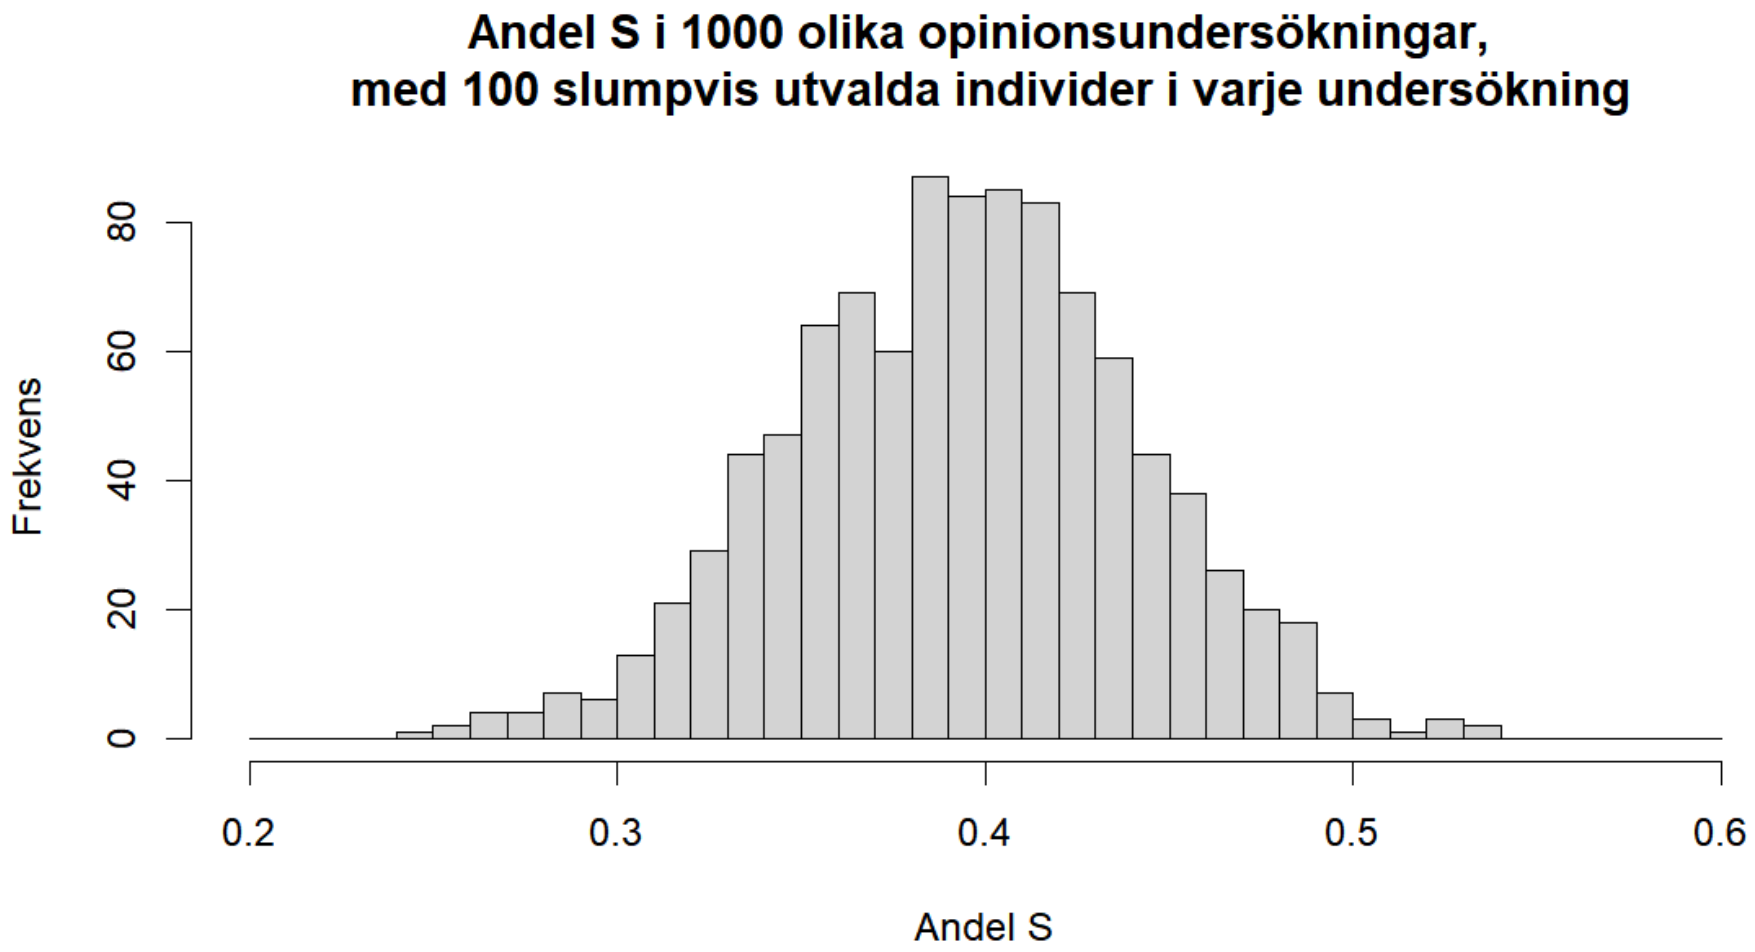
Andel S i 1000 olika opinionsundersökningar,
med 100 slumpvis utvalda individer i varje undersökning
Frekvens
0
20
40
60
80
0.2
0.3
0.4
0.5
0.6
Andel S

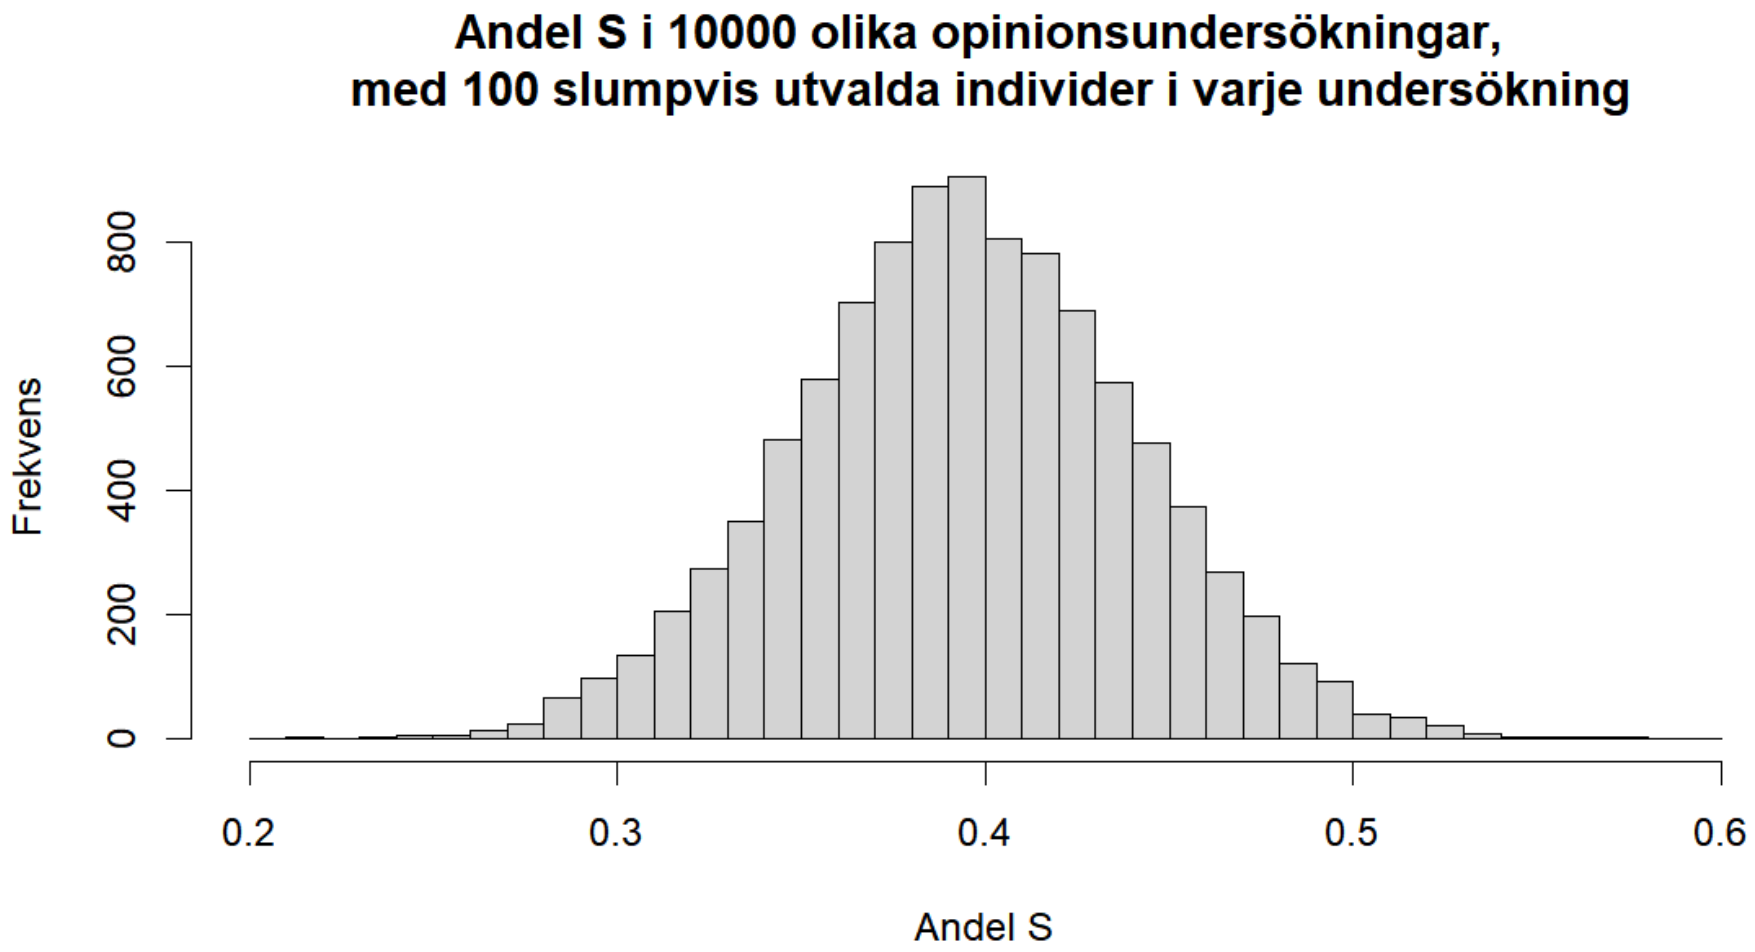
Andel S i 10000 olika opinionsundersökningar,
med 100 slumpvis utvalda individer i varje undersökning
Frekvens
0
200
400
600
800
0.2
0.3
0.4
0.5
0.6
Andel S

Exempel 2 - urval för att studera förhållandet mellan människors längd och kaloriintag

- Antag att vi har en population individer, varje individ har en längd och ett kaloriintag
- I populationen finns ett visst samband, ”i medel”, mellan de två variablerna
- Vi vill säga något om sambandet genom att studera slumpvisa urval från populationen

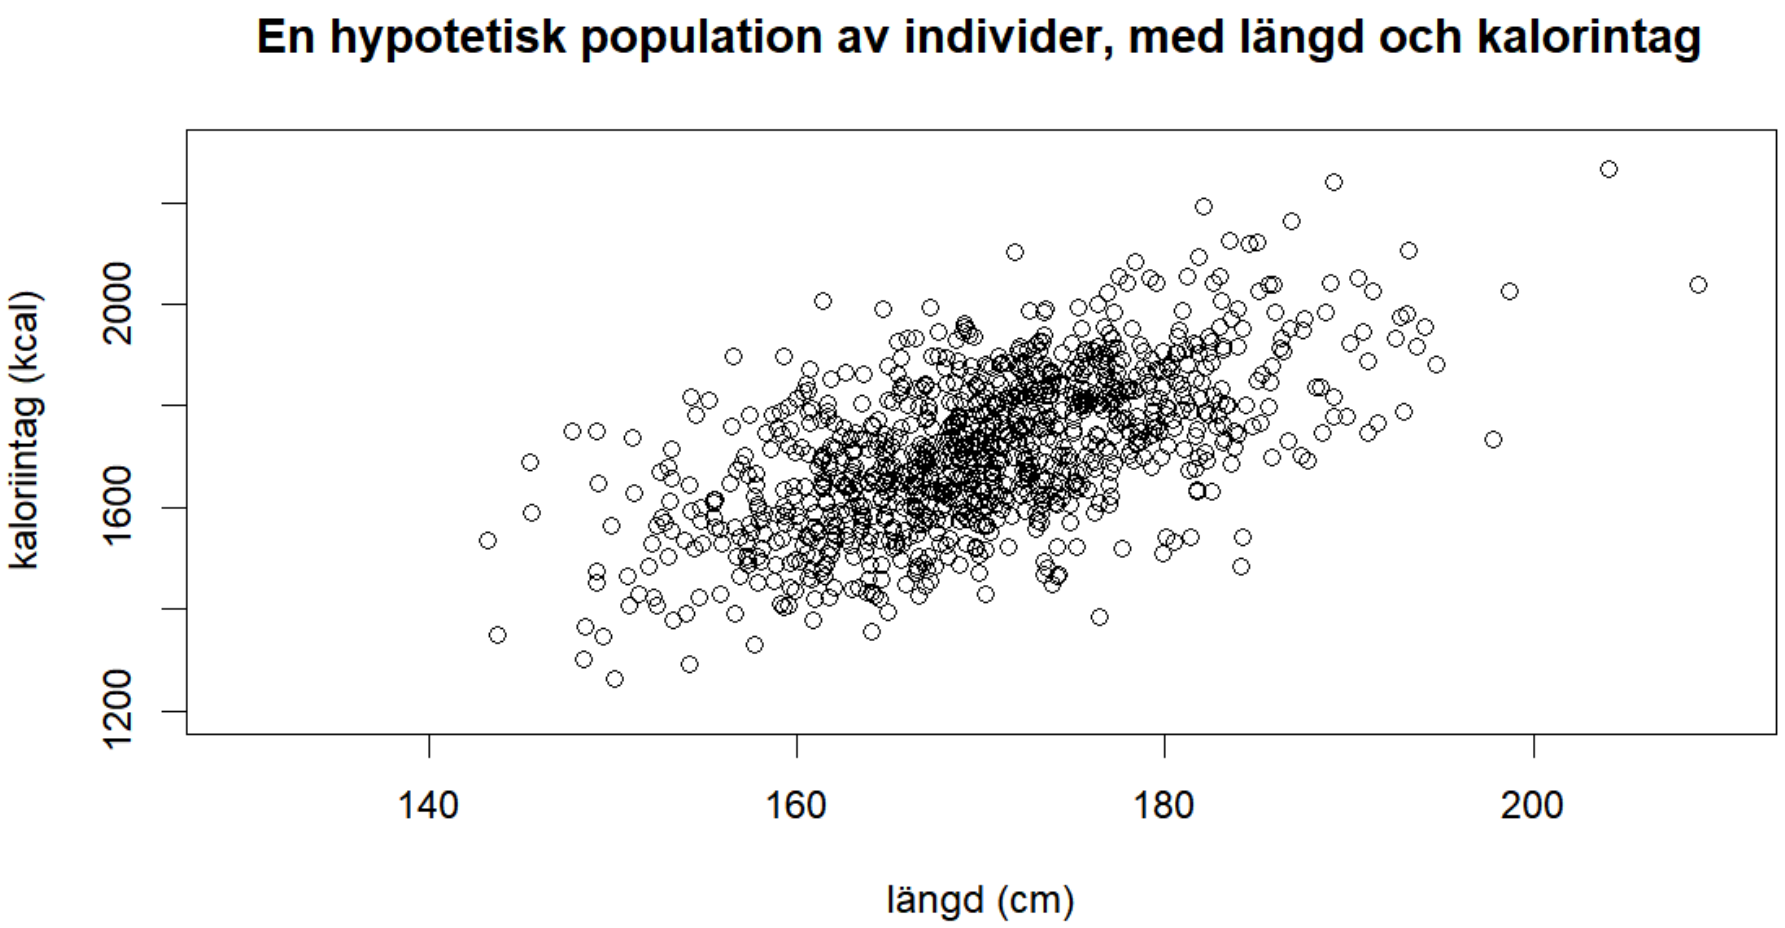
En hypotetisk population av individer, med längd och kalorintag
kaloriintag (kcal)
1200
1600
2000
140
160
180
200
längd (cm)

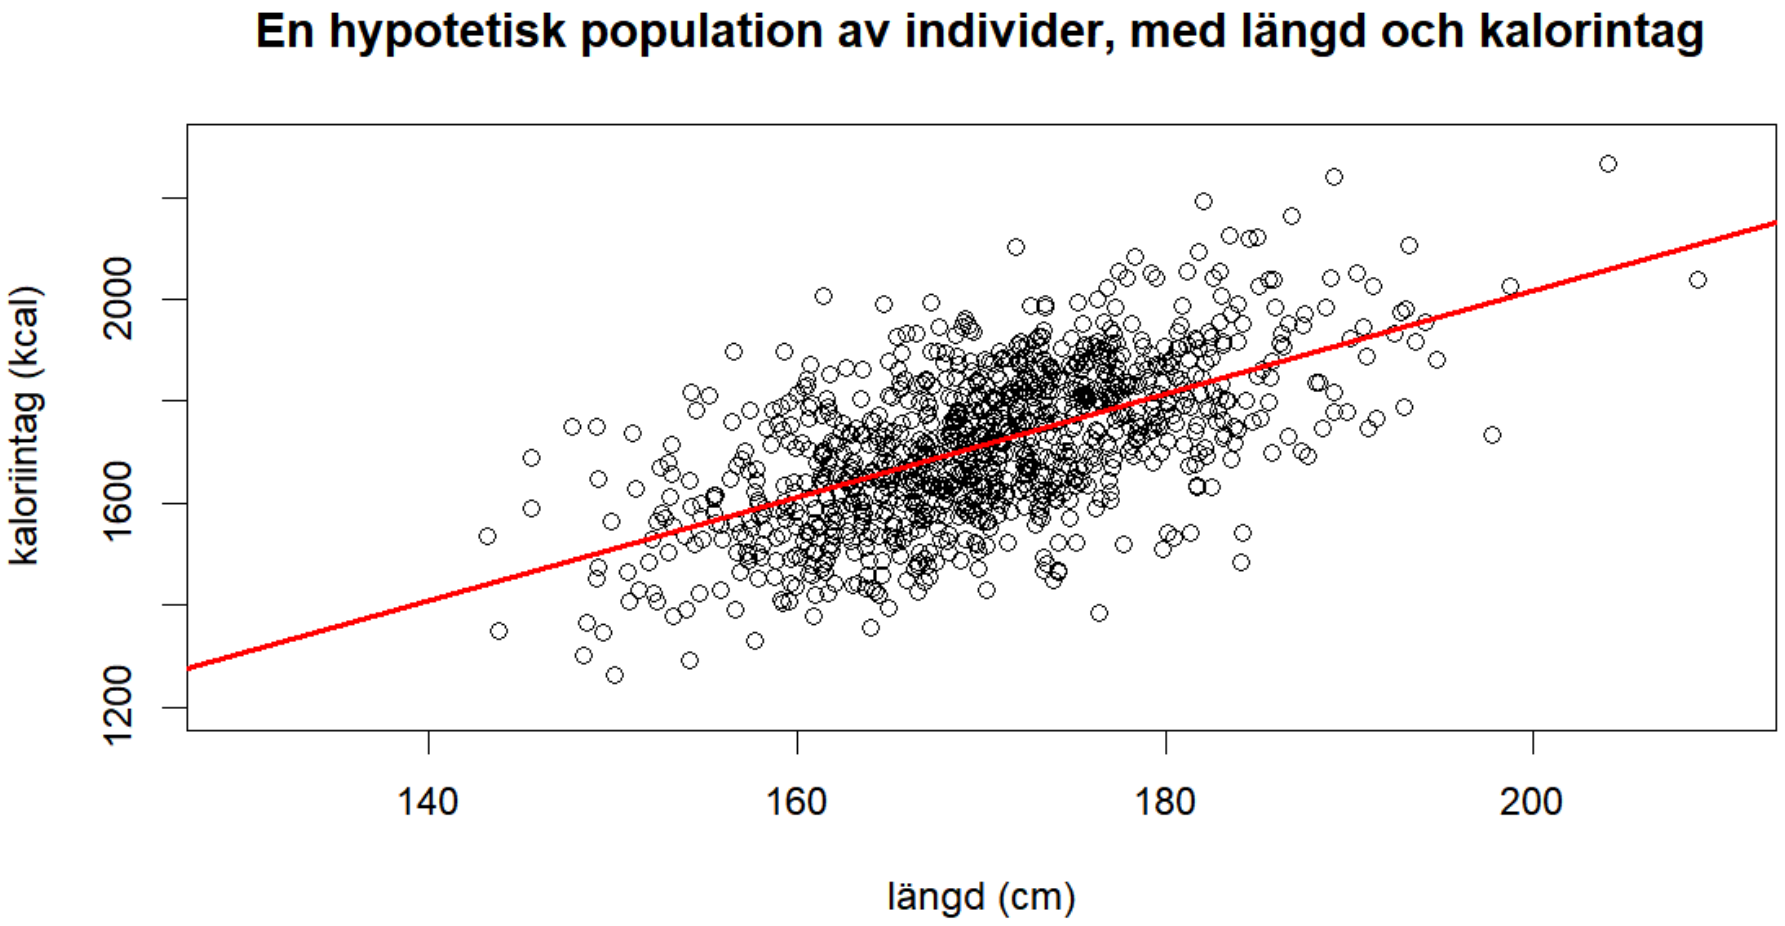

En rät linje har anpassats. Lutningen är 10.12 kcal/cm - i medel intar en individ som är 1 cm längre än en annan individ 10.12 kcal mer.

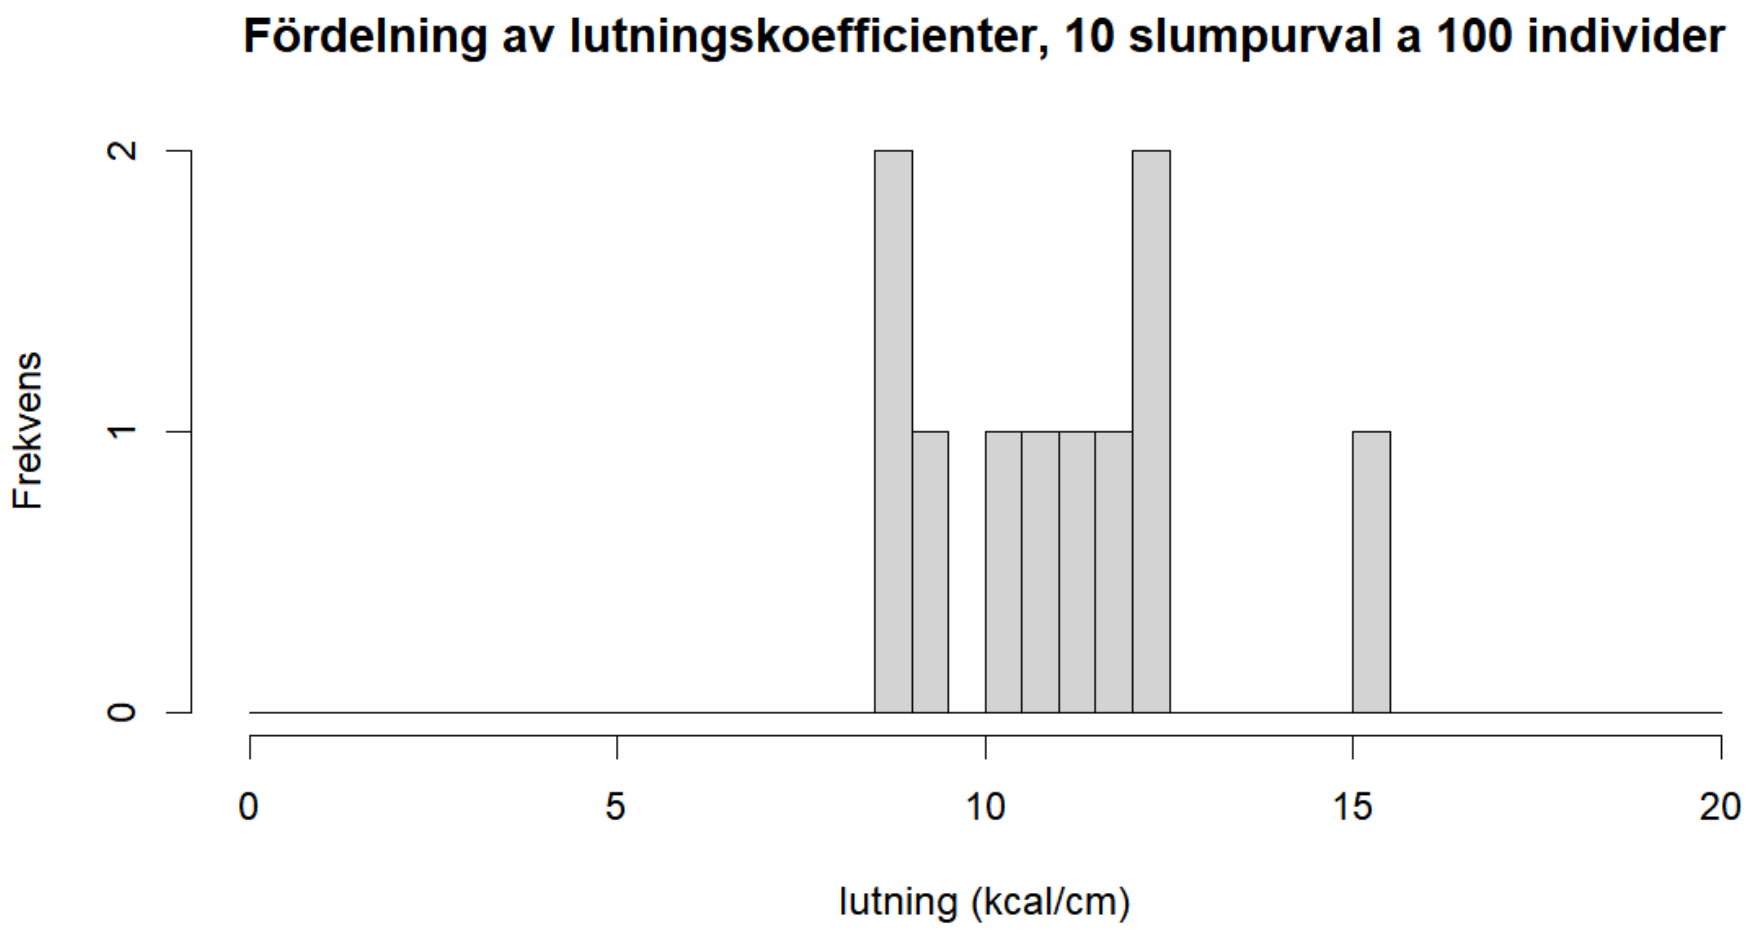
Fördelning av lutningskoefficienter, 10 slumpurval a 100 individer
Frekvens
0
1
2
0
5
10
15
20
lutning (kcal/cm)

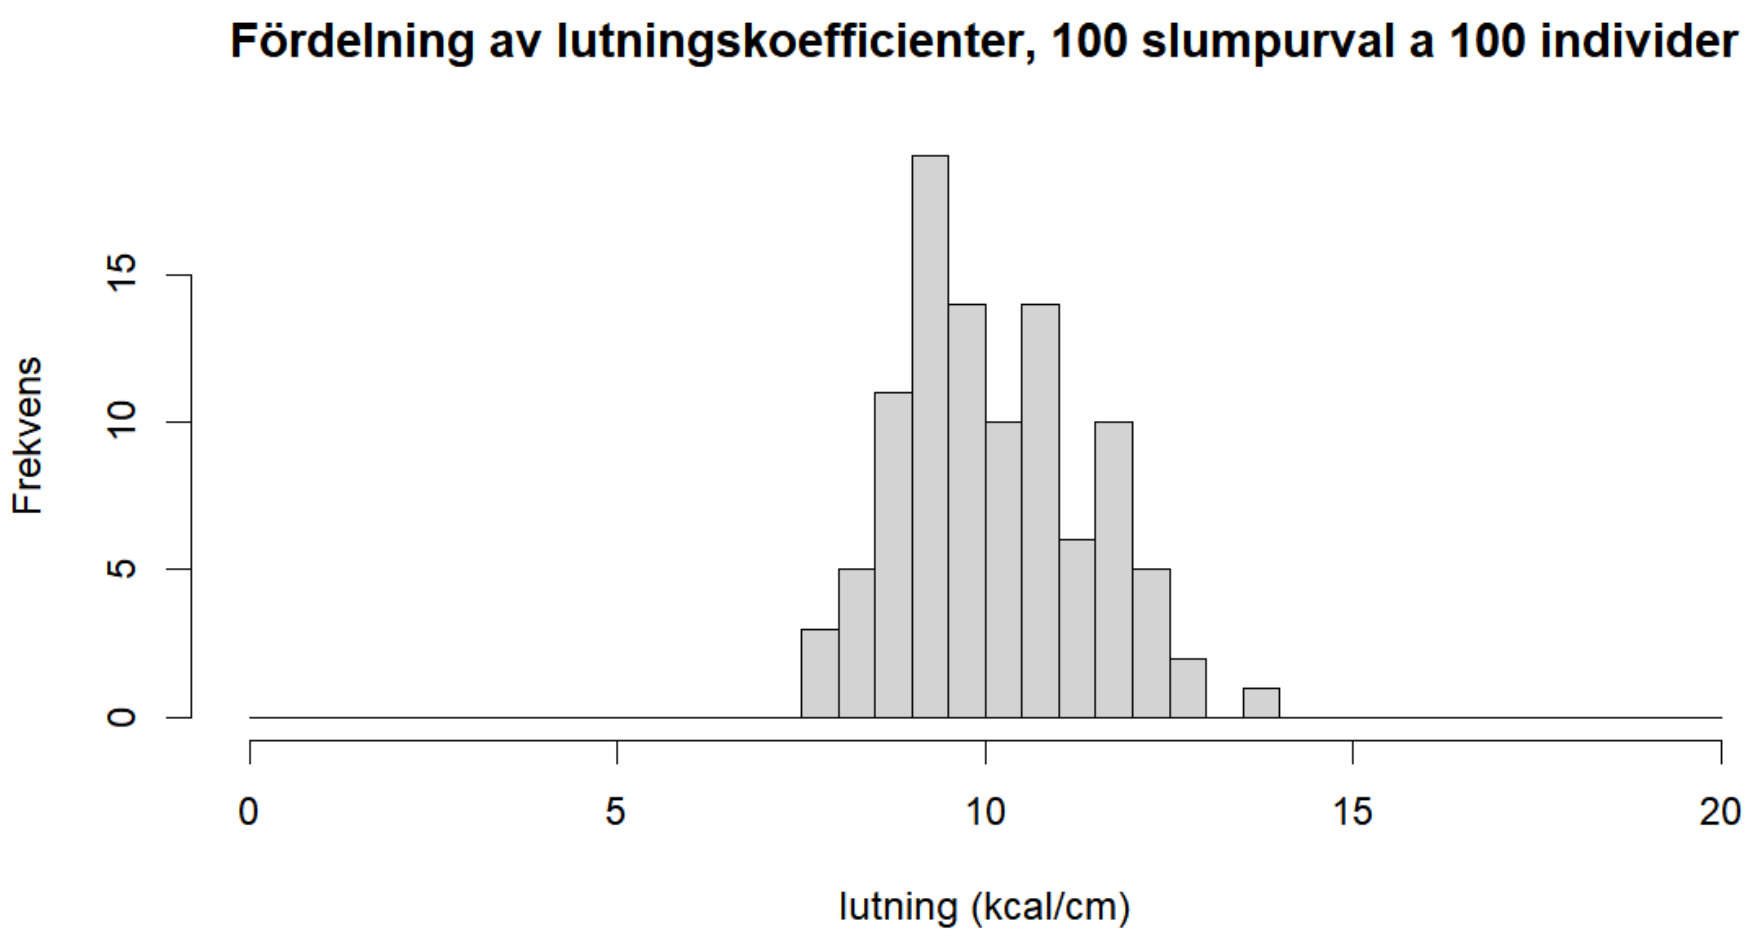
Fördelning av lutningskoefficienter, 100 slumpurval a 100 individer
Frekvens
0
5
10
15
0
5
10
15
20
lutning (kcal/cm)

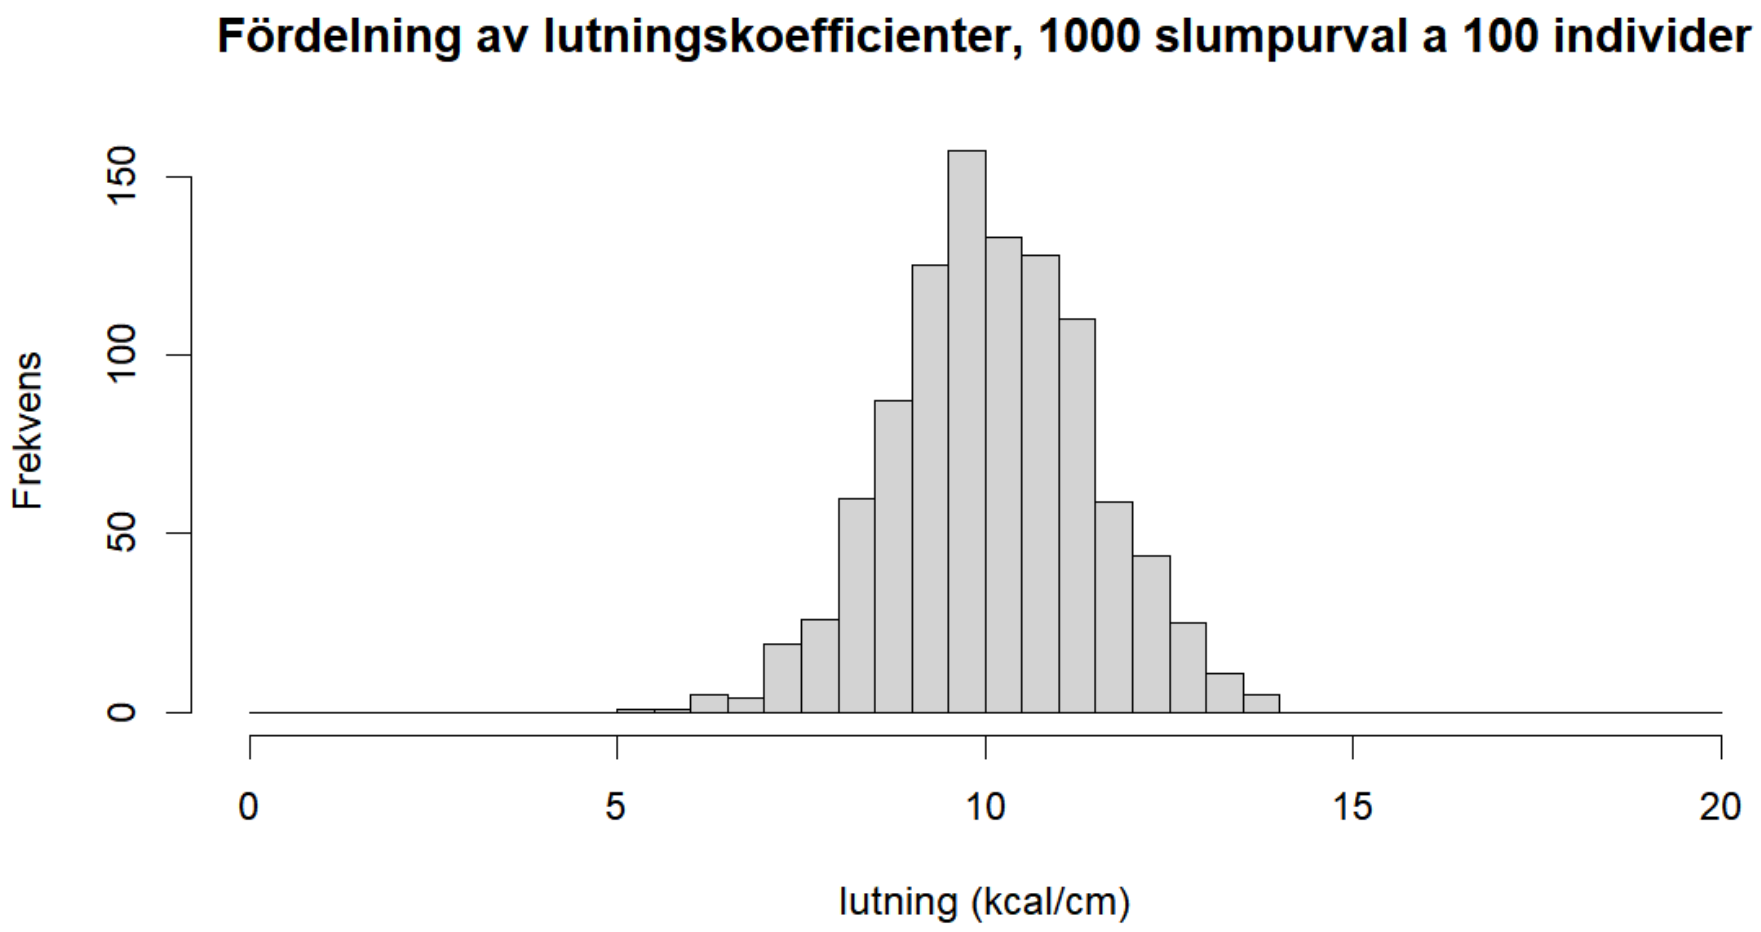
Fördelning av lutningskoefficienter, 1000 slumpurval a 100 individer
Frekvens
0
50
100
150
0
5
10
15
20
lutning (kcal/cm)

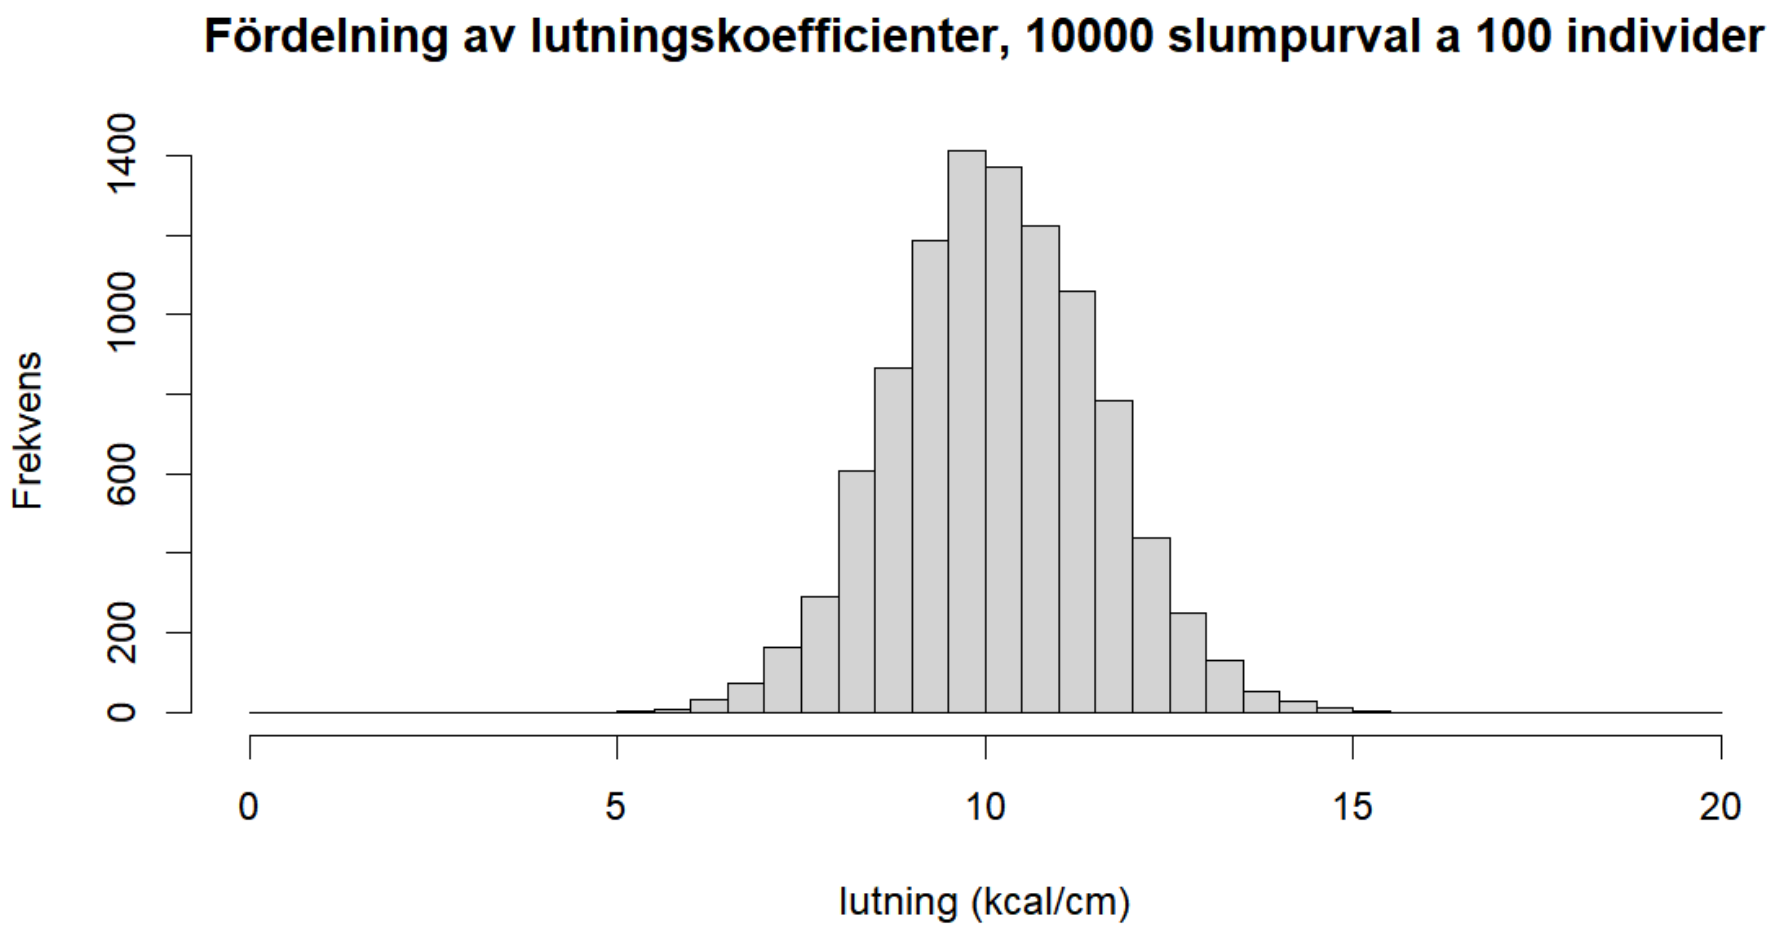
Fördelning av lutningskoefficienter, 10000 slumpurval a 100 individer
Frekvens
0
200
600
1000
1400
0
5
10
15
20
lutning (kcal/cm)

Ovanstående två exempel

- Exemplen är olika men fördelningarna vi får liknar varandra
- I vårt fall började vi med data på en population men typiskt har vi inte sådana data, utan vill dra slutsatser om populationen från (oftast) ett enda urval
- Hur kan vi dra slutsatser om (exv.) andelen S-väljare bland 8 miljoner röstberättigade, från ett urval på 1000 personer? Vilka slutsatser kan vi dra?
- Hur kan vi dra slutsatser om (exv.) sambandet mellan inkomstnivå och hälsa, från ett urval? Vilka slutsatser kan vi dra?

Föreläsning 5 - vart är vi på väg?

- **Föreläsning 6-7** tar upp bla punktskattning, konfindensintervall, inferens och hypotesprövning.
- **Föreläsning 8-10** tar upp samband mellan två och flera variabler, regression, prediktion.
- På vägen dit behöver vi förstå bla. slump och sannolikhet, samplingfördelning, normalfördelningen, och de stora talens lag - **Föreläsning 5**.

Föreläsning 5 - innehåll

- Slump och sannolikhet - begrepp och motivering
- Exempel med tärningskast (många kast...)
- De stora talens lag
- Centrala gränsvärdessatsen
- Samplingfördelning
- Normalfördelning

- Läs SDM kap 12 (Athena) och kursboken 13.1-13.3
- I början av kap. 13.1 - notera utseenedet på fördelningarna i Figur 13.1, ni förväntas inte kunna redogöra för innehållet som refereras från kap. 11-12

Slump och sannolikhet - motivering

- Modellera fenomen som har en slumpkomponent
- **Ex:** Vi väljer slumpvis 1000 röstberättgade och beräknar andelen socialdemokrater, och får exv. 0.40. Vilka slutsatser kan vi dra?
- Vi behöver en verktygslåda för hur vi ska hantera sådana mätningar - vilka slutsatser kan vi dra? (**inferens**)
- Här kommer sannolikhetsteori in

- Fatta beslut i en osäker värld.
- **Ex:** Hur många skyddsmasker ska finnas i lager, hur ofta kan tunnelbanan gå utan att vi får trafikstockning?, vilken andel pensionspengar bör investeras i aktier?

Slump, slumpvariabler

- **Slump** - när ett händelseförlopp inte är deterministiskt
  - Kasta ett mynt, en tärning - vi vet inte vad resultatet kommer att bli
  - Vädret - finns ingen deterministisk modell för att förutspå exakt väder (exv., ska det snöa på valborg?) - det finns en slumpkomponent
  - Samhällsvetenskapliga fenomen (**Ex:** vad bestämmer inflationen?) - vi har ekonomisk teori men det finns också en slumpkomponent
  - Om man behöver reparera sin bil eller inte - beror delvis på oförutsägbara händelser
- **Slumpvariabel/Stokastisk variabel** (Random/stochastic variable) - en variabel vars värden helt eller delvis bestäms av slumpen
  - Vilket värde vi får på ett tärningskast
  - Temperatur, nederbörd etc., vid olika tidpunkter
  - Inflationsutfall för olika månader
  - Årlig reparationskostnad för en bil

Sannolikhet

- **Sannolikhet** (probability) - den relativa frekvensen av ett visst utfall
- **Ex:** Hälften av slantsinglingarna leder till "krona" (sannolikhet för krona $= 0.5$)

Sannolikhet - begrepp

- Vi utför ett **försök** (trial): kastar ett mynt, kastar en tärning
- Observerar ett **utfall** (outcome): krona, en 6:a
- **Utfallsrummet** (sample space) är alla möjliga utfall som kan inträffa (S). För ett kast med en tärning: $S = \{1, 2, 3, 4, 5, 6\}$.
- En **händelse** (event) är en mängd av utfall.
- **Ex 1:** En 6:a på ett tärningskast, vi kan kalla detta händelsen $A = \{6\}$.
- **Ex 2:** Två 6:or på två tärningskast, vi kan kalla detta händelsen $B = \{(6, 6)\}$.

Sannolikhet - ytterligare exempel på en händelse

- **Ex 3:** Händelsen C - få summan 7 på två tärningskast
- $C = \{(1,6),(2,5),(3,4),(4,3),(5,2),(6,1)\}$
- Bilden visualiserar utfallsrummet för två tärningskast, visar summan för kast 1 och kast 2, samt händelsen C (i blått).

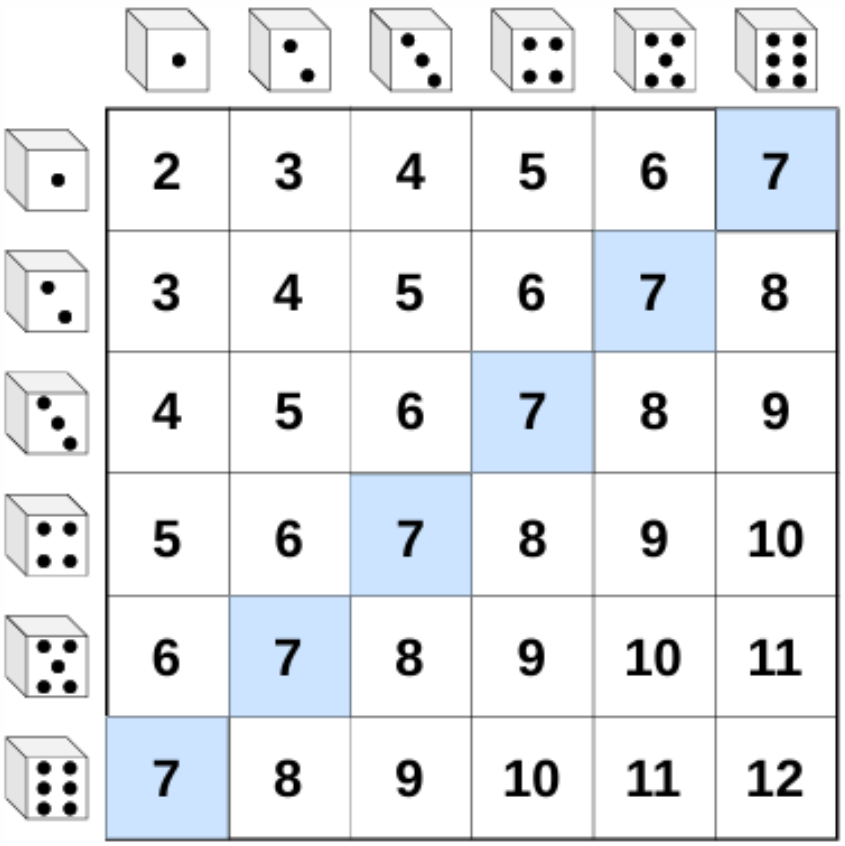

2	3	4	5	6	7
3	4	5	6	7	8
4	5	6	7	8	9
5	6	7	8	9	10
6	7	8	9	10	11
7	8	9	10	11	12

Sannolikhet

- Vad är sannolikheten att få en 6:a (händelsen $A = \{6\}$)?
- Att få en 6:a är ett av sex möjliga utfall.
- **Matematisk (logisk) sannolikhet** Om tärningen är helt symmetrisk är varje utfall lika sannolikt

$$P(A) = \text{Sannolikhet för 1 av 6 utfall} = \frac{1}{6}$$

- **Empirisk sannolikhet:** andelen 6:or om jag kastar tärningen ett "oändligt" (mycket stort) antal gånger

$$P(A) = \frac{\text{Antal 6:or}}{\text{Antal försök}}$$

- **Subjektiv sannolikhet** Min tidigare erfarenhet av tärningskast och min uppfattning om en tärnings symmetri säger mig att min sannolikhet att få en 6:a är 1/6

- **Övning 1** - vi gör sannolikhetsberäkningar (SDM, kap. 12)

Tärningskast och slumpdragningar - exempel

- Exemplen som följer hjälper oss (förhoppningsvis) att förstå:
  - De stora talens lag
  - Begreppet samplingfördelning
  - Centrala gränsvärdessatsen
  - Normalfördelningen

Andel 1:or, 2:or, osv. **36** tärningskast, 4 gånger (röd linje - 1/6).

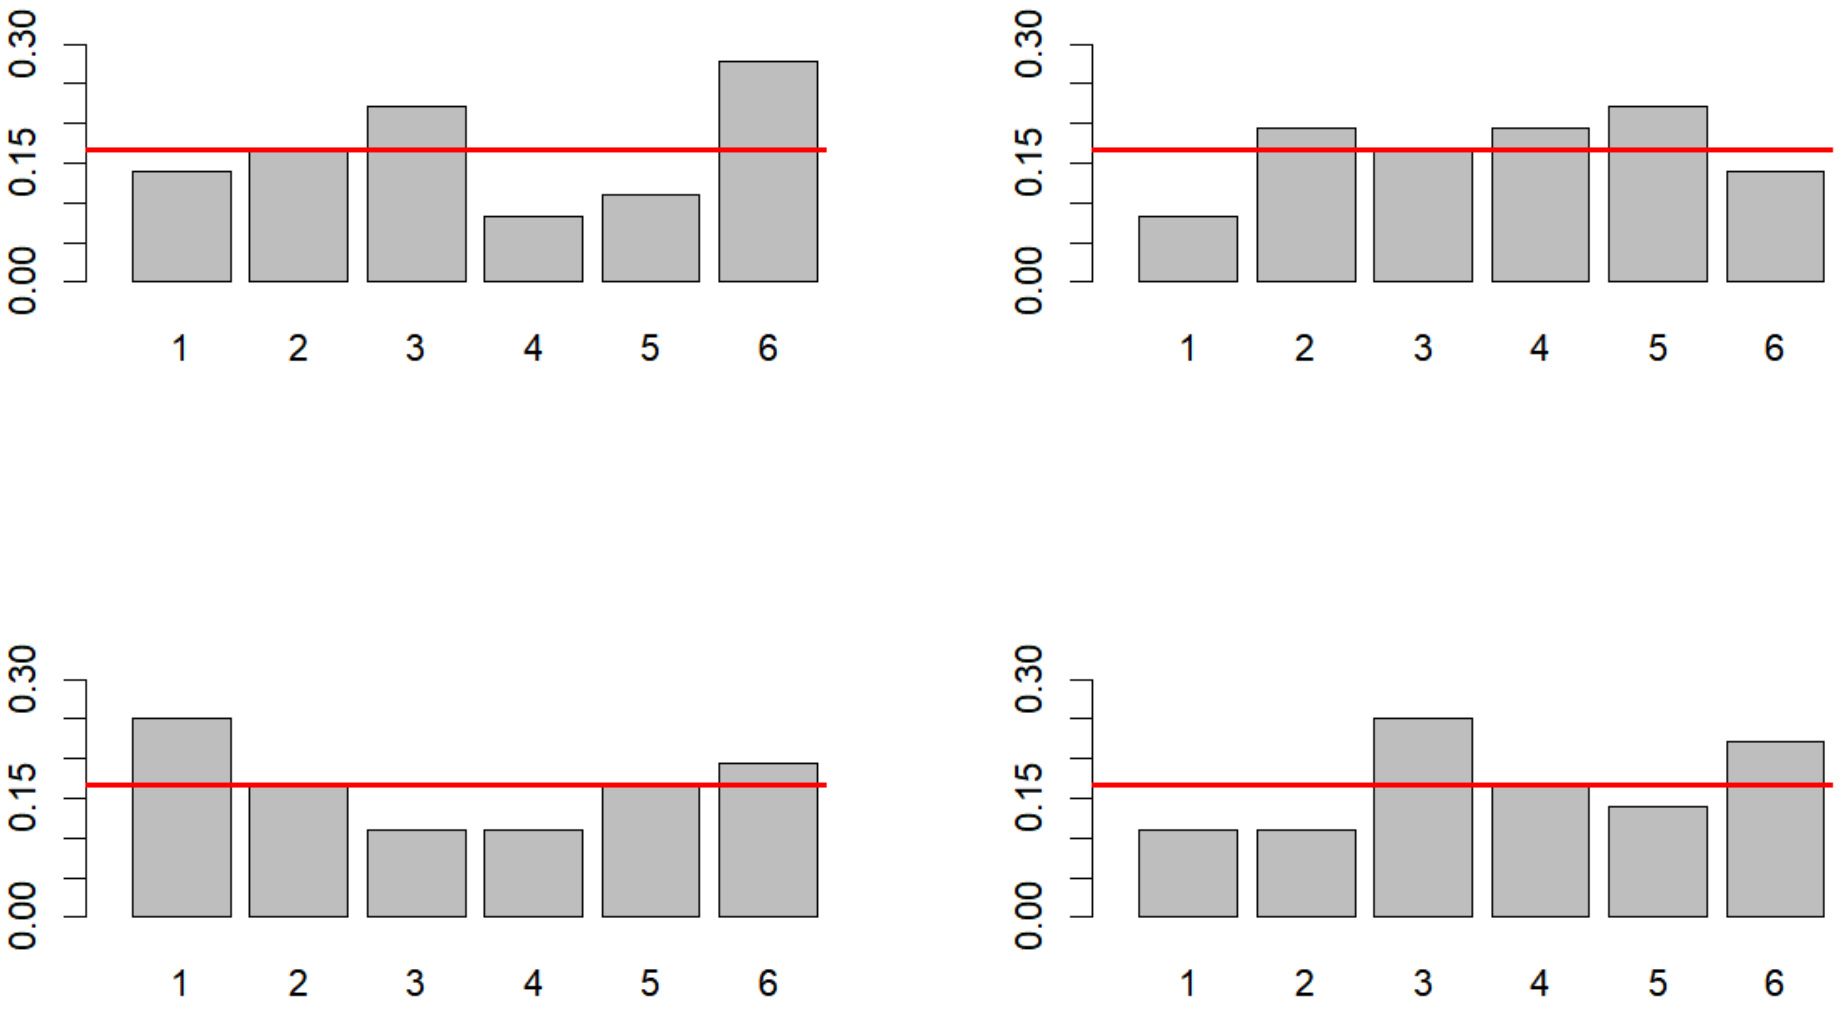

Andel 1:or, 2:or, osv. **360** tärningskast, 4 gånger (röd linje - 1/6).

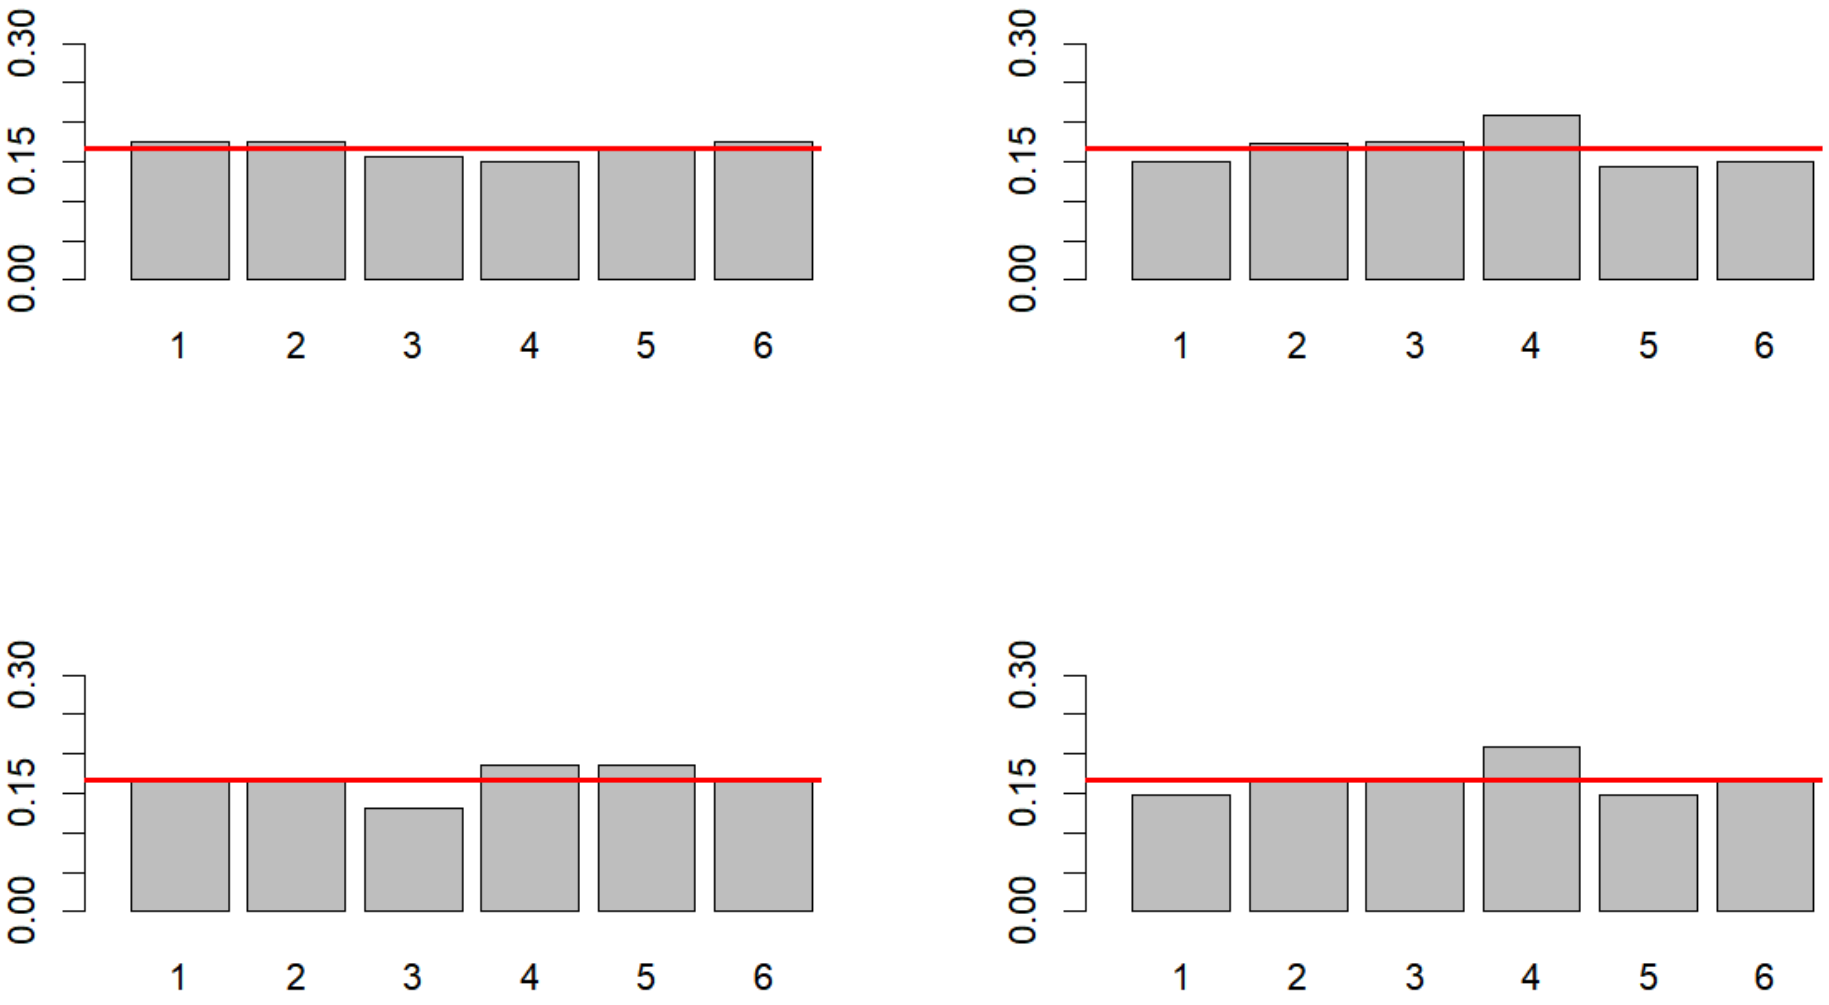

Andel 1:or, 2:or, osv. **3600** tärningskast, 4 gånger (röd linje - 1/6).

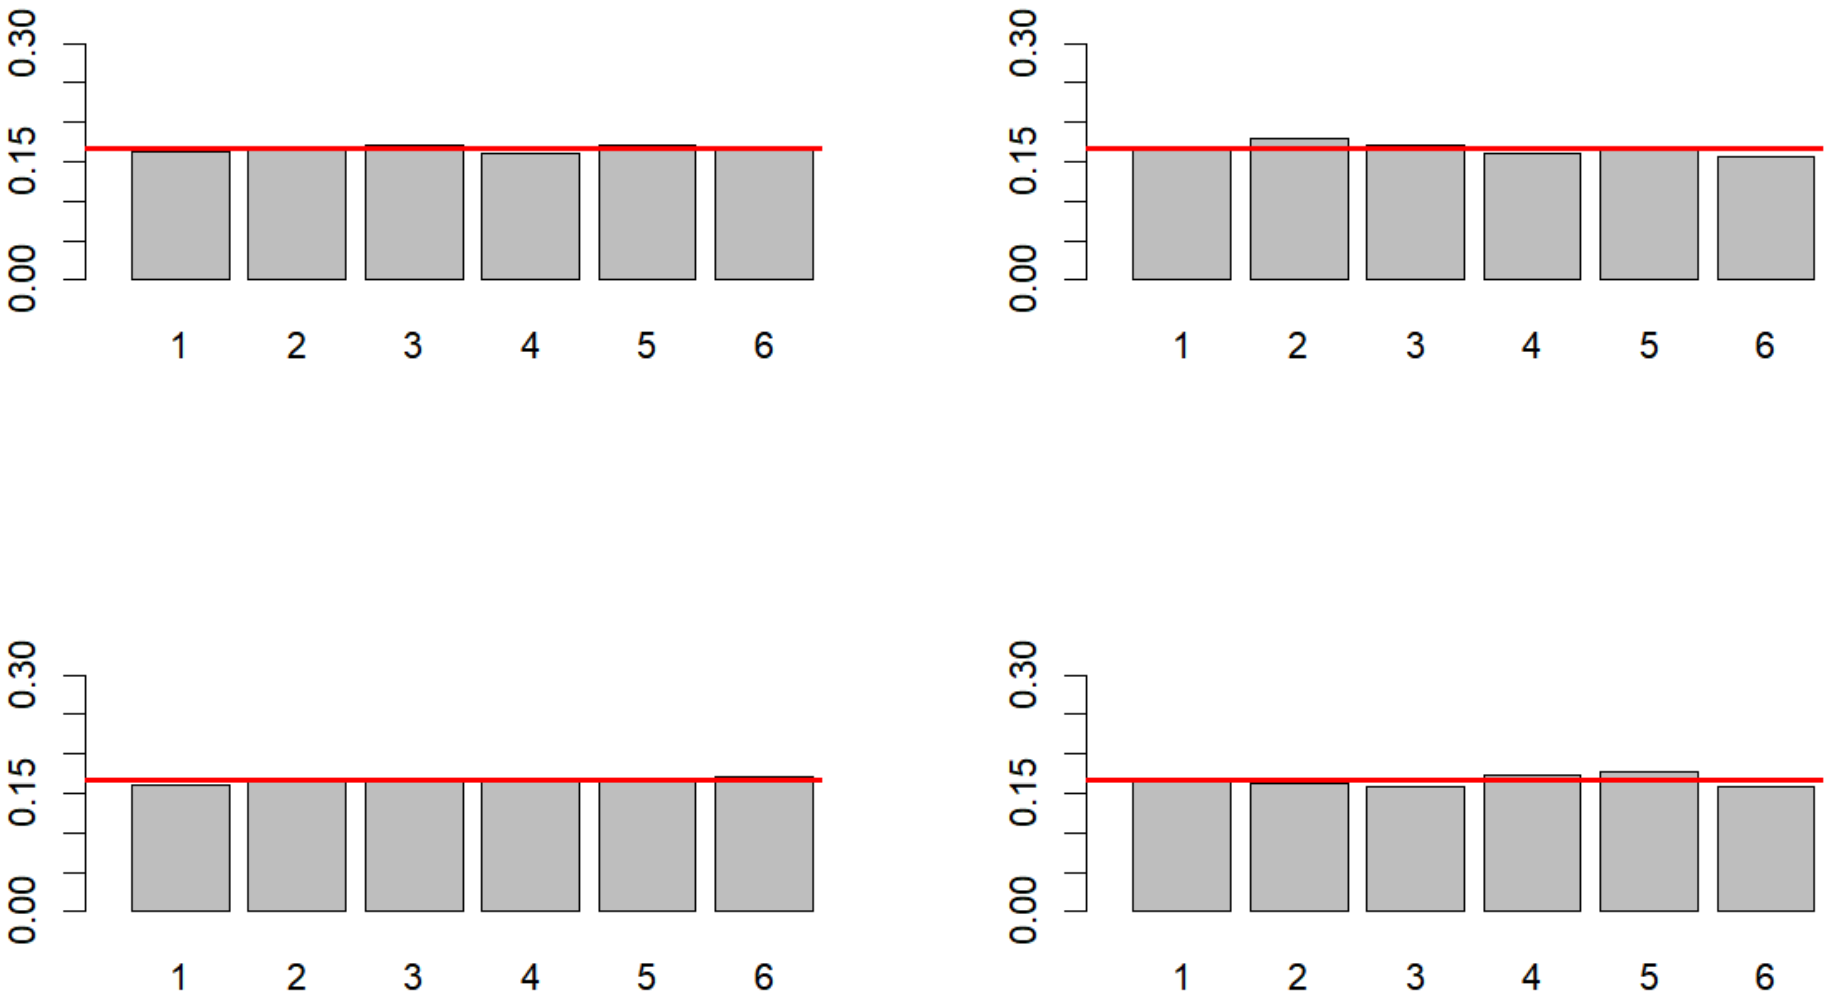

Andel 1:or, 2:or, osv. **36000** tärningskast, 4 gånger (röd linje - 1/6).

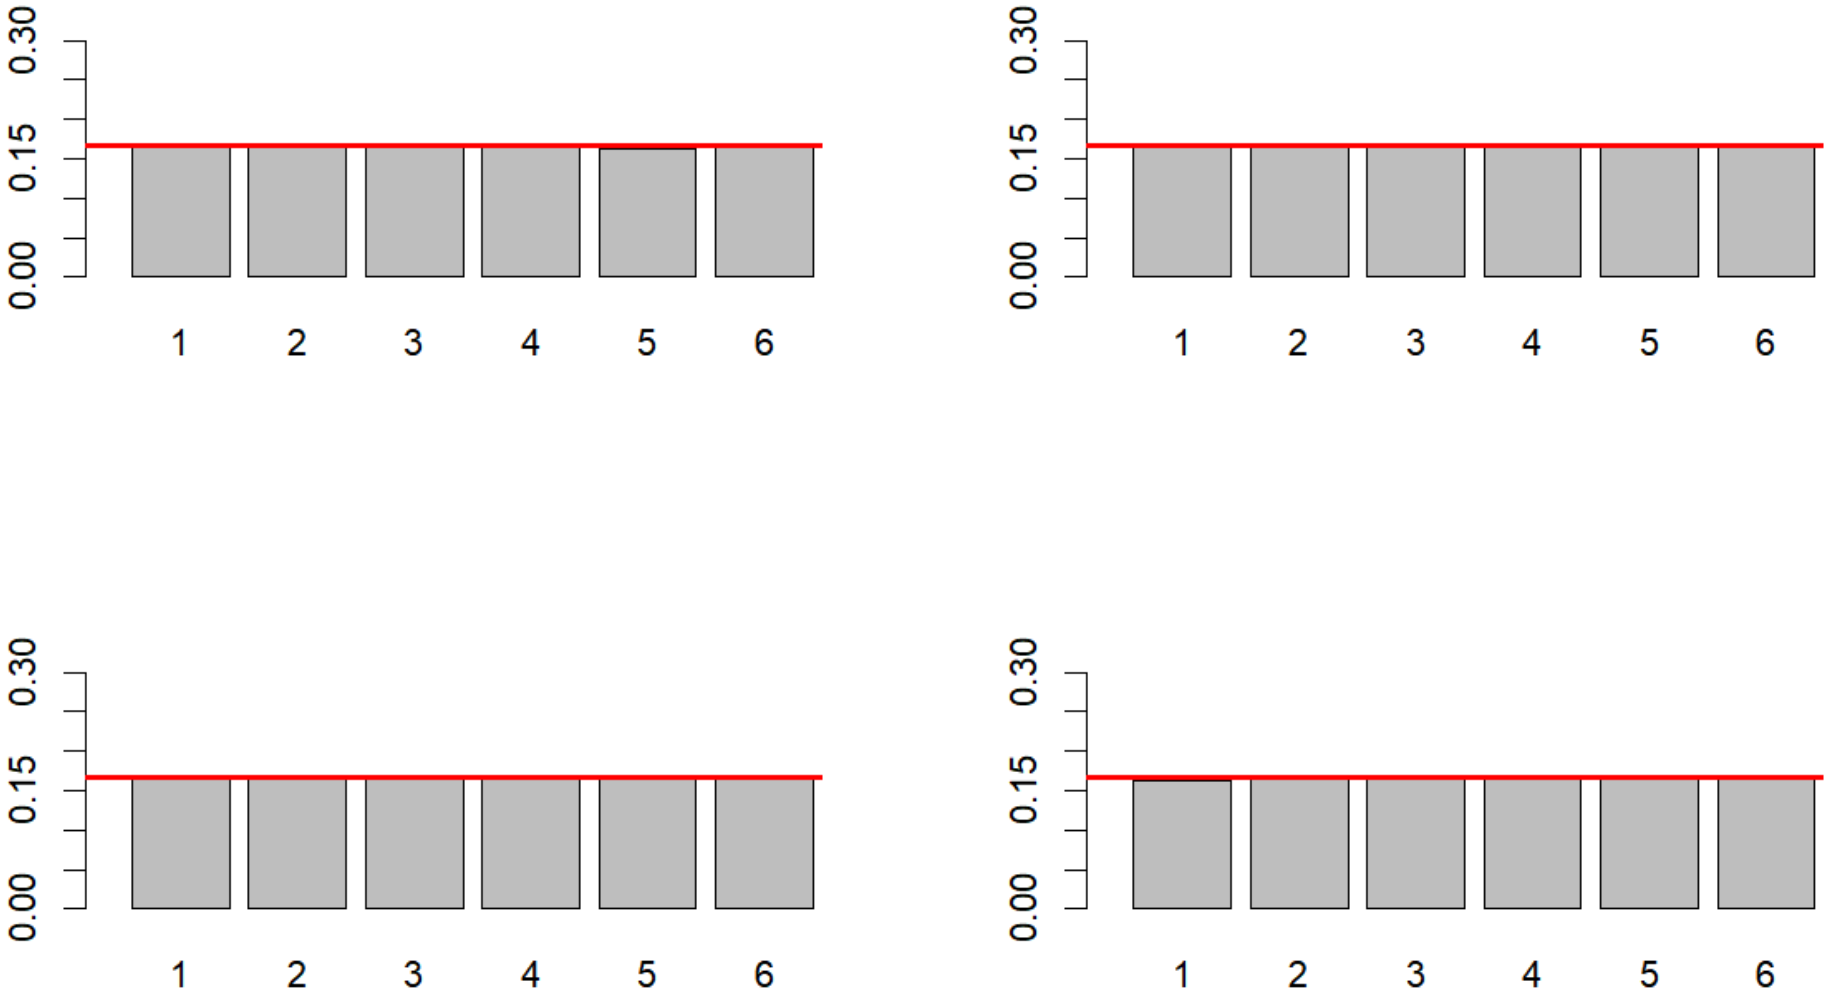

Stora talens lag ("Law of large numbers")

- **Stora talens lag:** När vi gör tillräckligt många försök, med **oberoende** händelser, konvergerar andelen "lyckade" försök (exv: en 6:a på en tärning) till ett bestämt tal (sannolikheten).
- **Oberoende** händelser (tärningar) - vad som kommer upp på tärningen i ett visst tärningskast beror inte på vad som kommer upp i andra kast.
- **Oberoende** händelser (generellt) - händelserna A och B är oberoende om vetskapen att B har inträffat inte påverkar sannolikheten för A. Och vice versa.

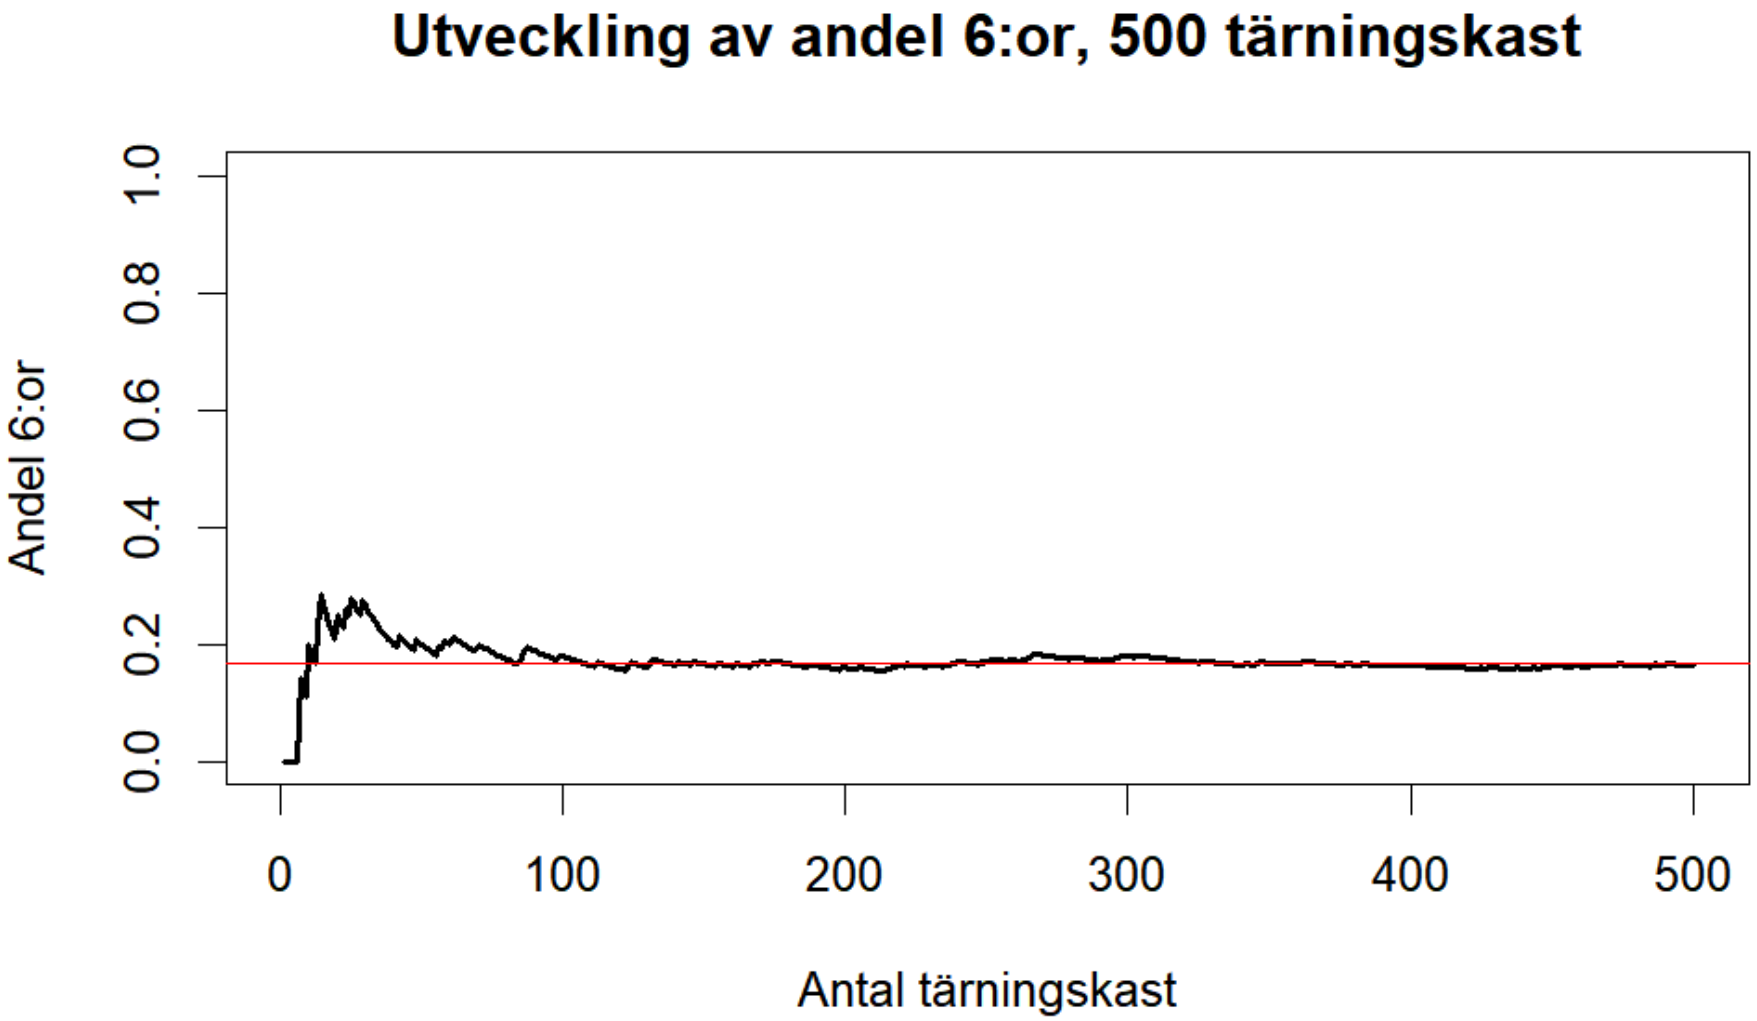
Utveckling av andel 6:or, 500 tärningskast
Andel 6:or
0.0
0.2
0.4
0.6
0.8
1.0
0
100
200
300
400
500
Antal tärningskast

Samplingfördelning ("Sampling distribution")

- Antag att vi kastar en tärning ett visst antal gånger, exv. 500, och repeterar detta förfarande väldigt många gånger.
- Vi skulle exempelvis kunna få
  - 100 1:or, 80 var av 2-6
  - 84 var av 1-5, och 80 6:or
  - 99 var av 1-5, och fem 6:or (extremt osannolikt, men teoretiskt möjligt)
  - en 1:a och 499 6:or (ännu mer osannolikt, men teoretiskt möjligt)
  - det finns en enorm mängd möjliga kombinationer...
- Fördelningen av medelvärdena, från alla möjliga kombinationer, kallas **samplingfördelningen**
- I praktiken kan vi inte ta ta fram alla kombinationer, istället slumpar vi ett stort antal gånger, exv. 10000 gånger, 500 tärningskast (också liknande vad vi gjorde i början av föreläsningen)

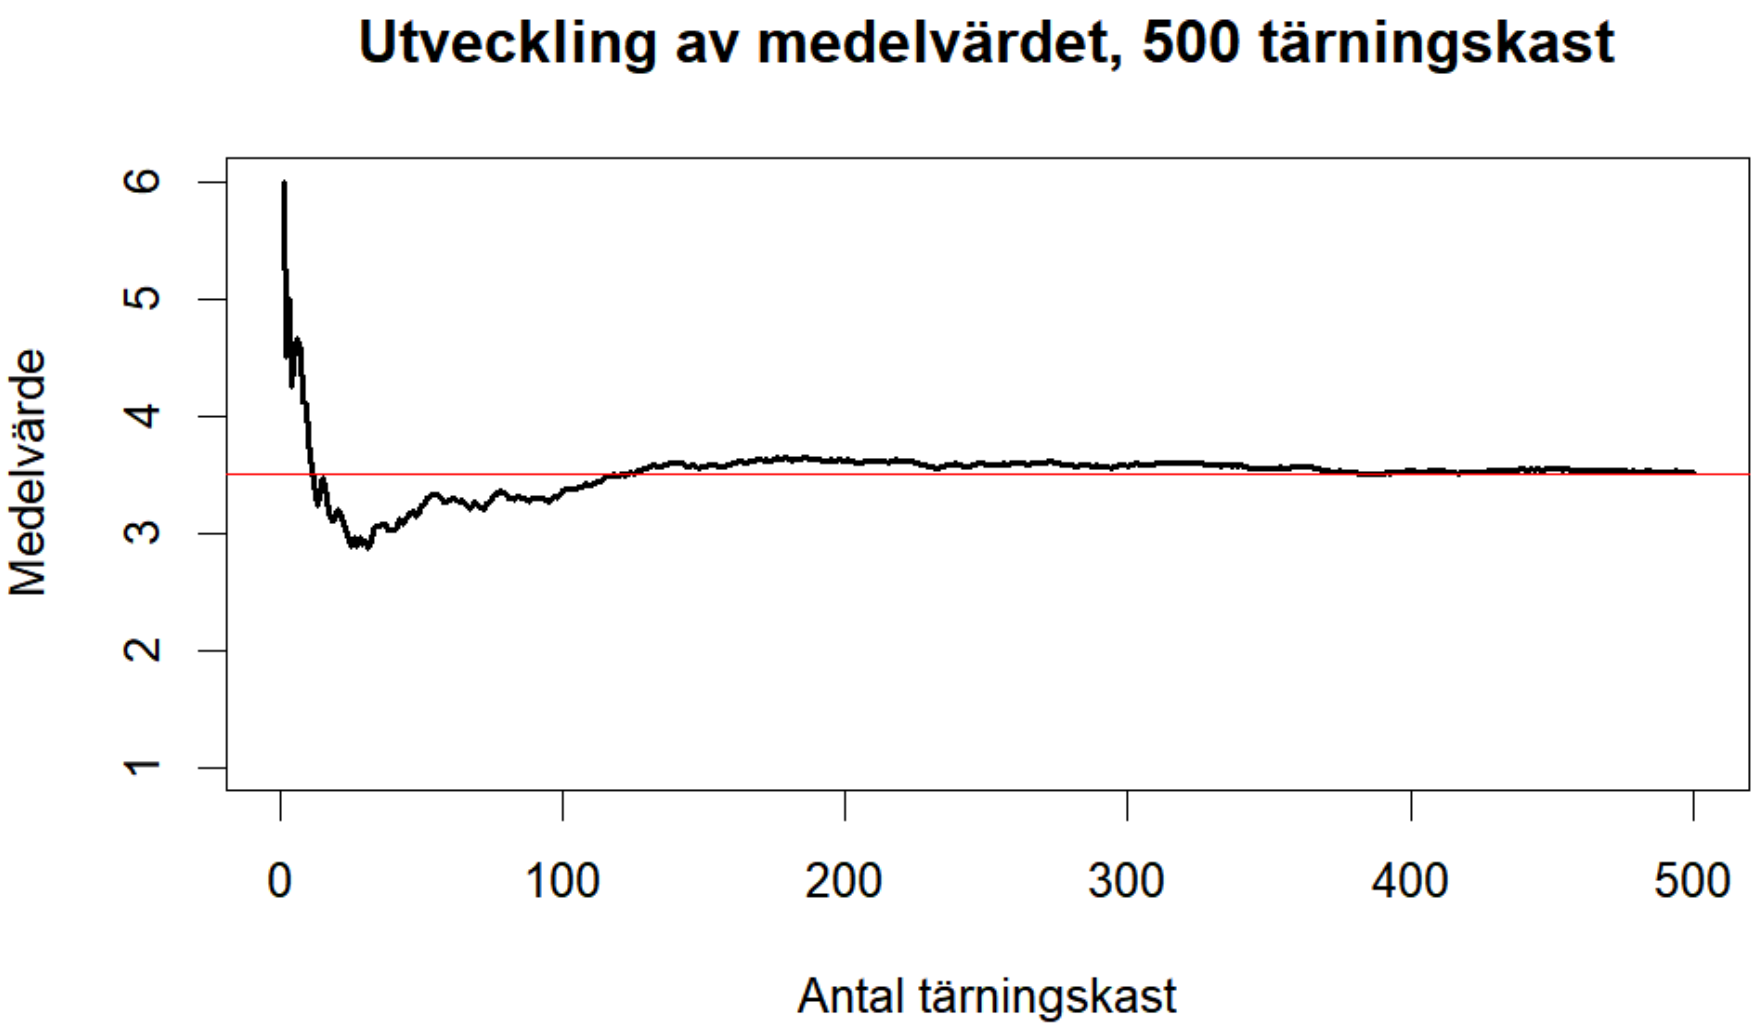
Utveckling av medelvärdet, 500 tärningskast
Medelvärde
1
2
3
4
5
6
0
100
200
300
400
500
Antal tärningskast

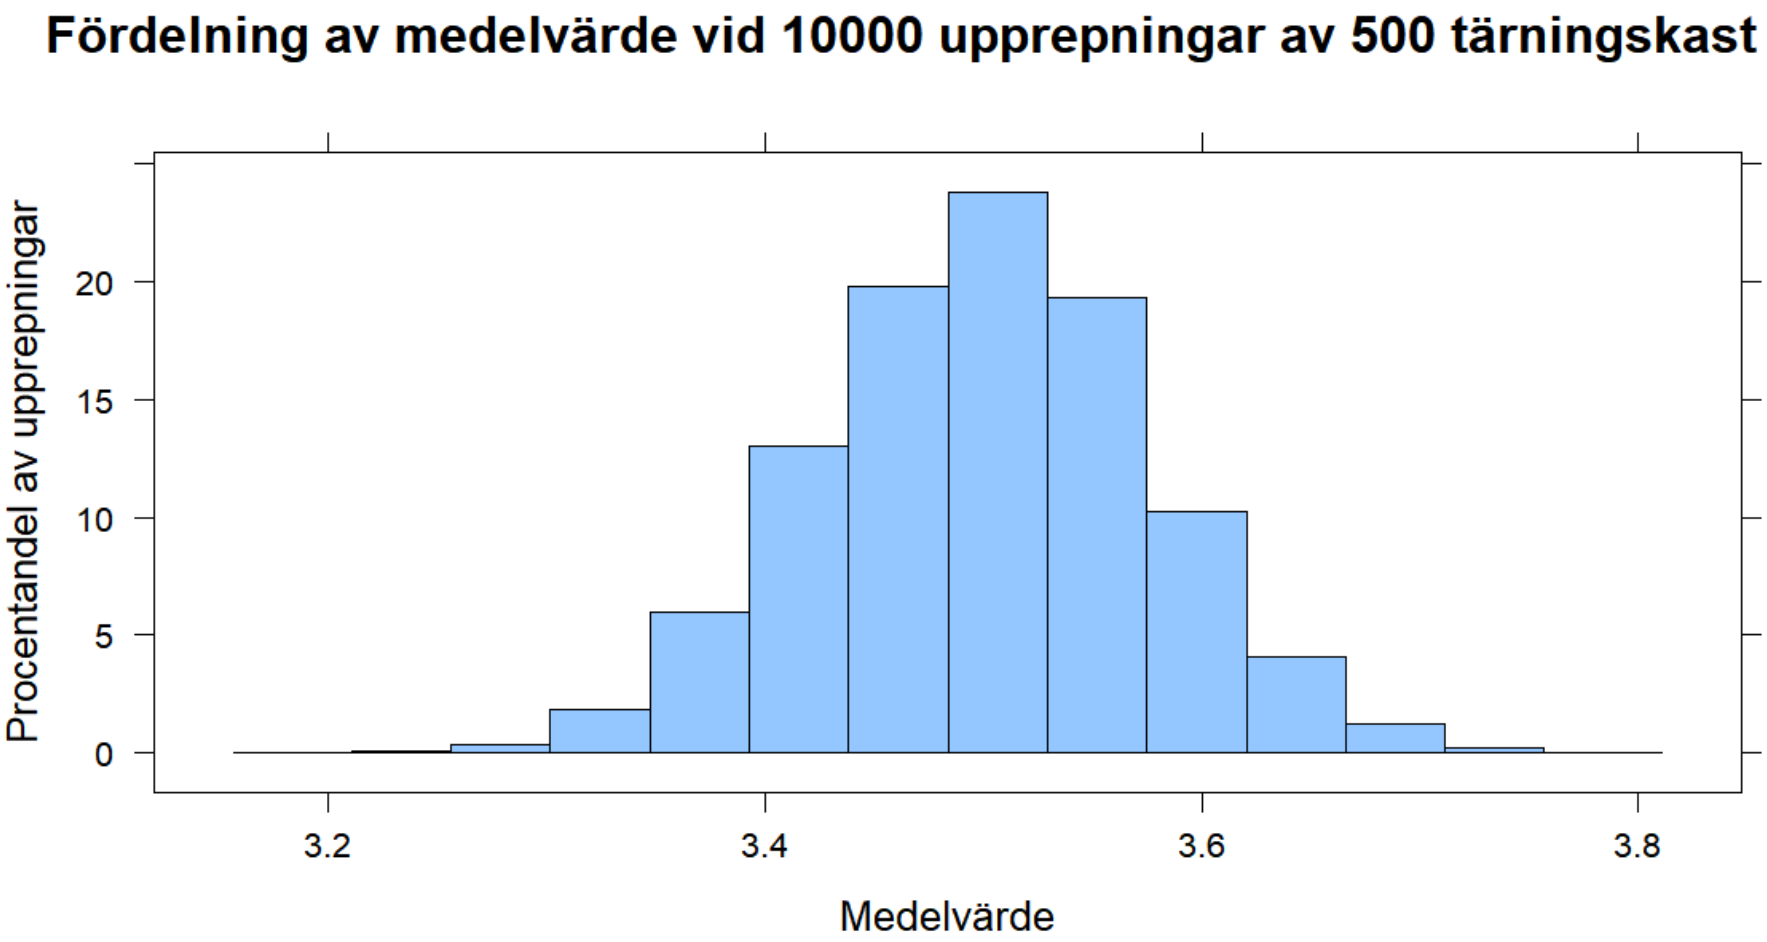
Fördelning av medelvärde vid 10000 upprepningar av 500 tärningskast
Procentandel av upprepningar
0
5
10
15
20
3.2
3.4
3.6
3.8
Medelvärde

Andra exempel på samplingfördelningar

- Slantsingling
- Andel "Huset vinner" i roulette (nummer 0-36, 37 nummer, huset vinner på nollan)
- Fler exempel kan ges - tid mellan olika individers ankomst till ett myndighetskontor, medelantal gäster på restaurang, antal tillverkningsfel per dag i en viss fabrik, andel socialdemokrater i opinionsundersökning, osv. (under antagande om oberoende)

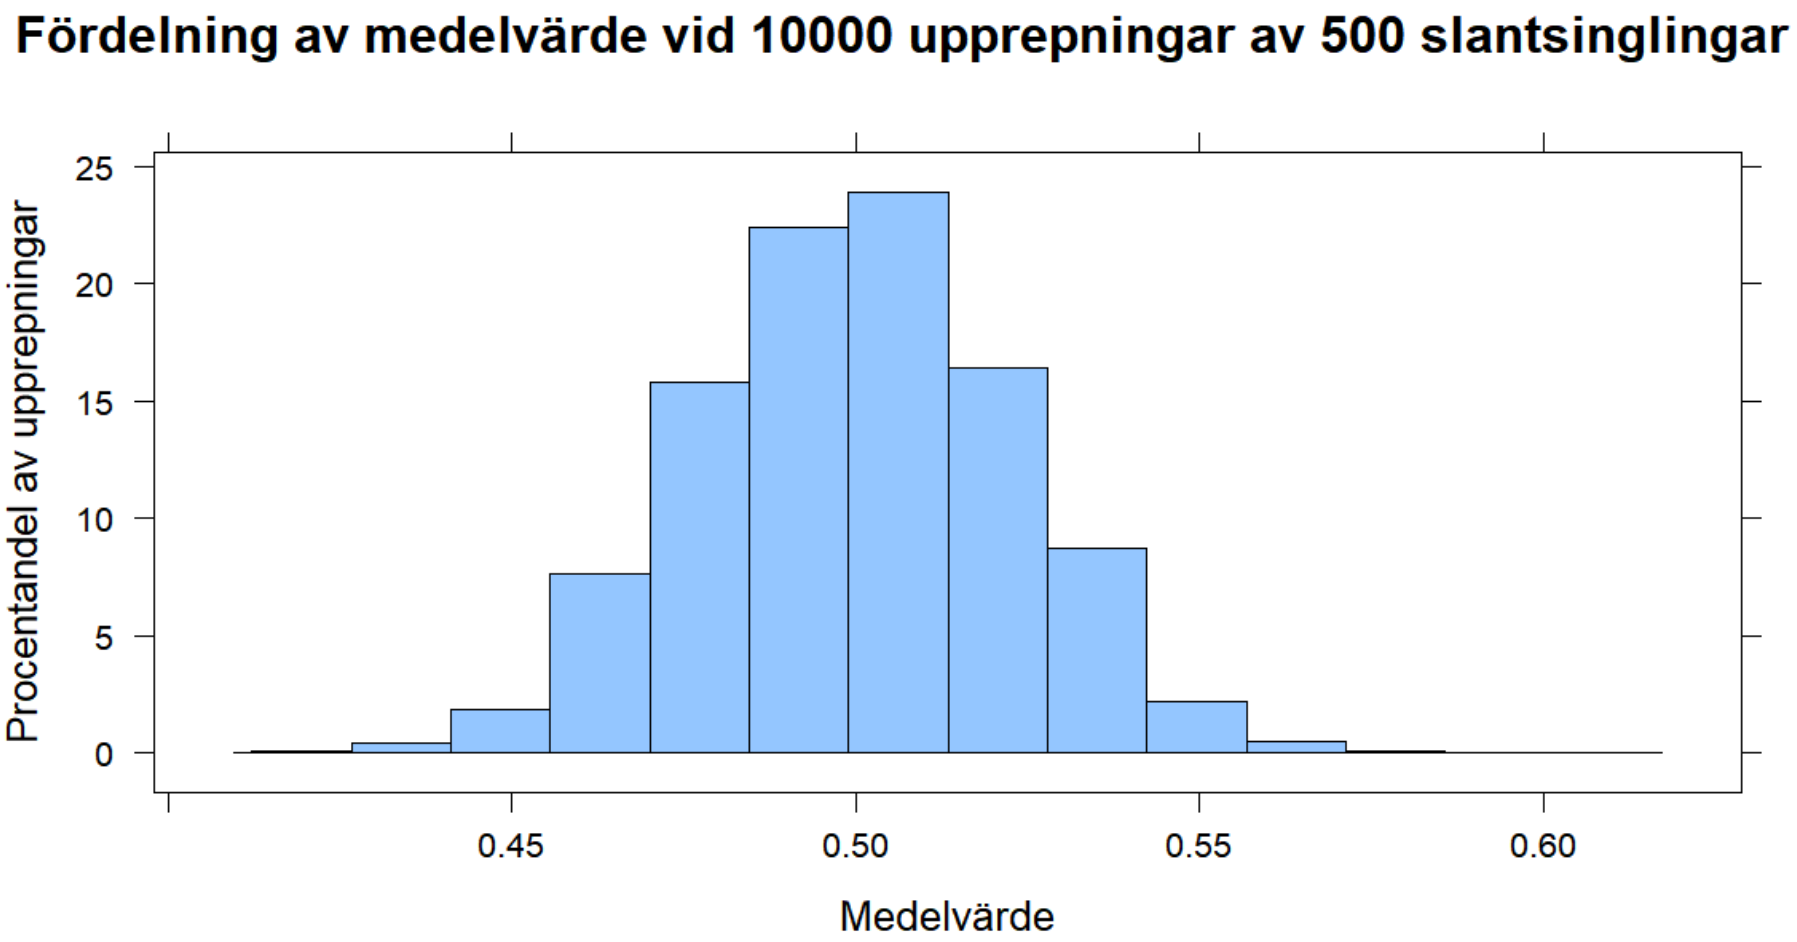
Fördelning av medelvärde vid 10000 upprepningar av 500 slantsinglingar
Procentandel av upprepningar
25
20
15
10
5
0
0.45
0.50
0.55
0.60
Medelvärde

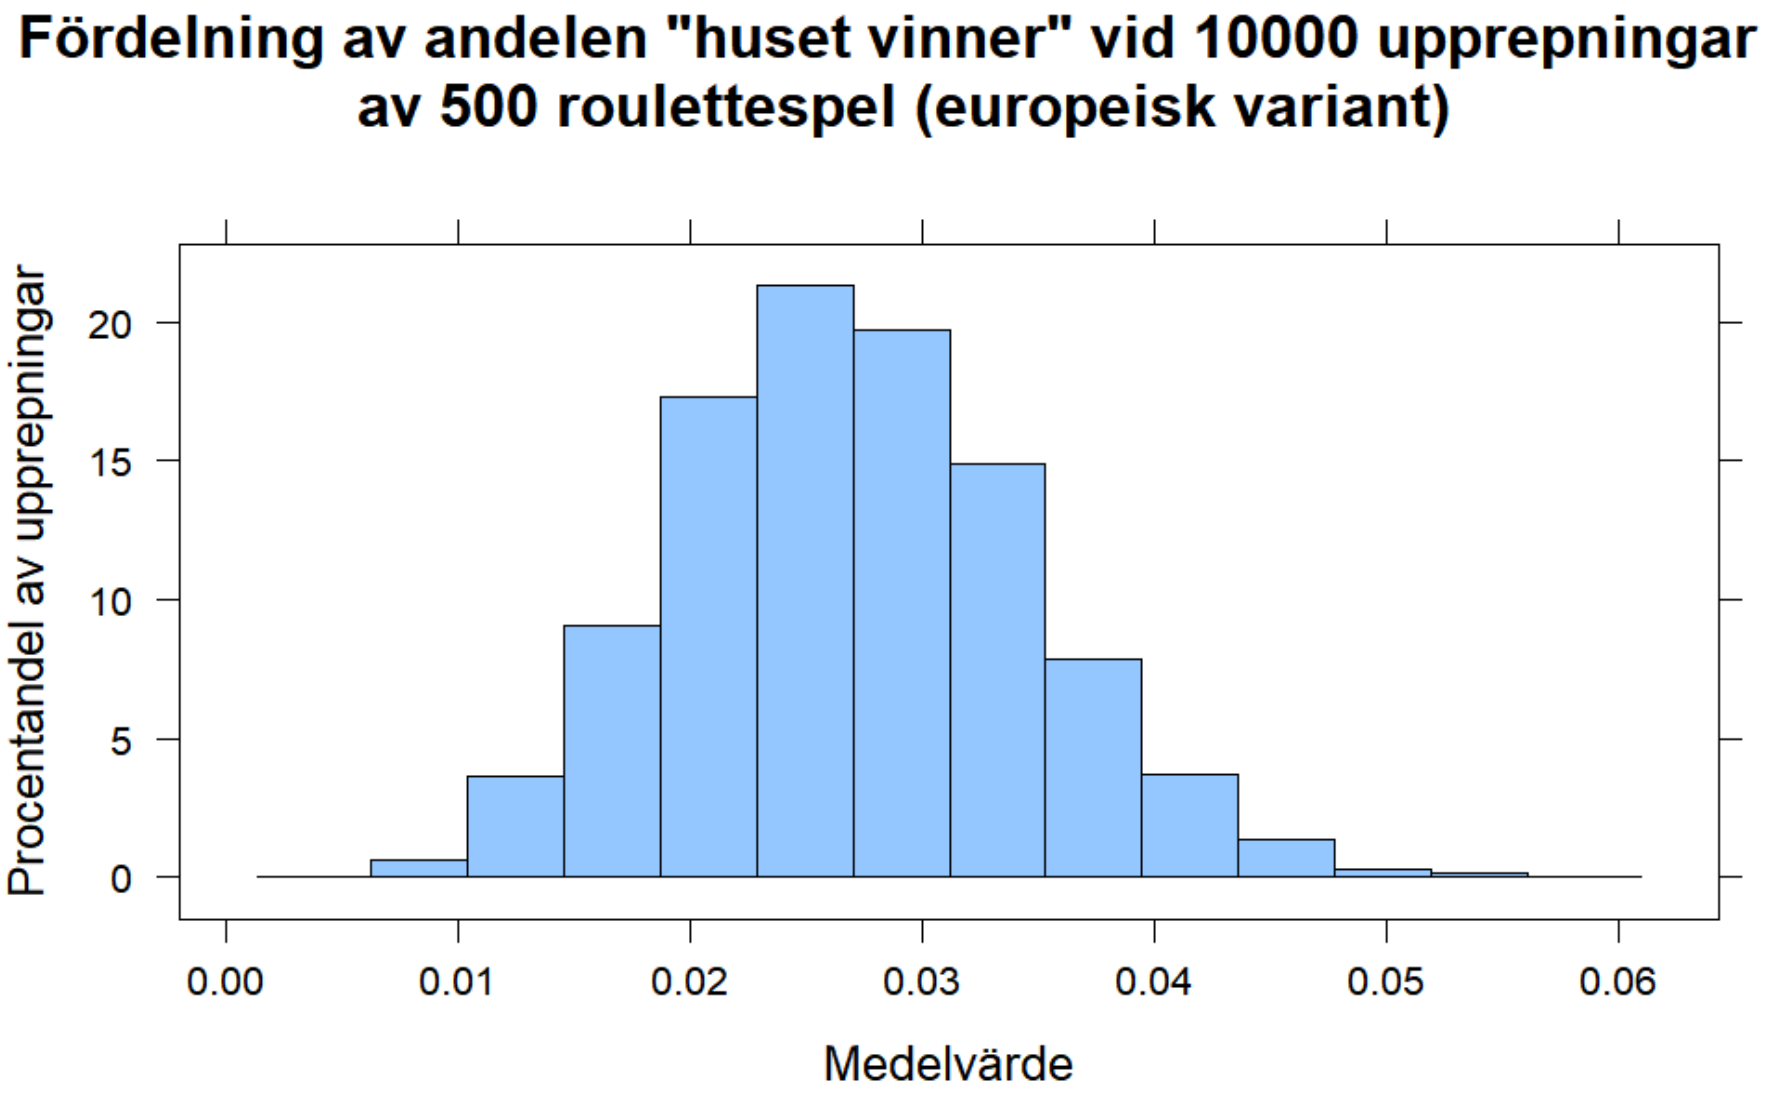
Fördelning av andelen "huset vinner" vid 10000 upprepningar av 500 roulettespel (europeisk variant)
Procentandel av upprepningar
0
5
10
15
20
0.00
0.01
0.02
0.03
0.04
0.05
0.06
Medelvärde

Centrala gränsvärdessatsen, normalfördelningen

- Graferna ser väldigt lika ut (om än på olika skala).
- Fördelningarna liknar alla **normalfördelningen**.
- Detta beror på **Centrala Gränsvärdessatsen:**

  Samplingfördelningen av medelvärden av **oberoende försök (observationer), från vilken fördelning som helst**, går mot en normalfördelning (om antal försök är tilläckligt stort, och utfallen är ändliga tal).

- Det spelar mao. ingen roll vilken fördelning data i sig har, så länge observationerna är oberoende (och ändliga) kommer medelvärdesfördelningen från olika slumpmässiga urval att gå mot en normalfördelning.
- Ytterligare exempel nästa sida

Ex: Antag köttkonsumtion är mellan 0 och 400 kcal per individ och dag och är **jämnt fördelad mellan dessa värden**, i en viss population. Räkna ut medelvärden för 10000 stickprov av 100 slumpmässigt valda individer.

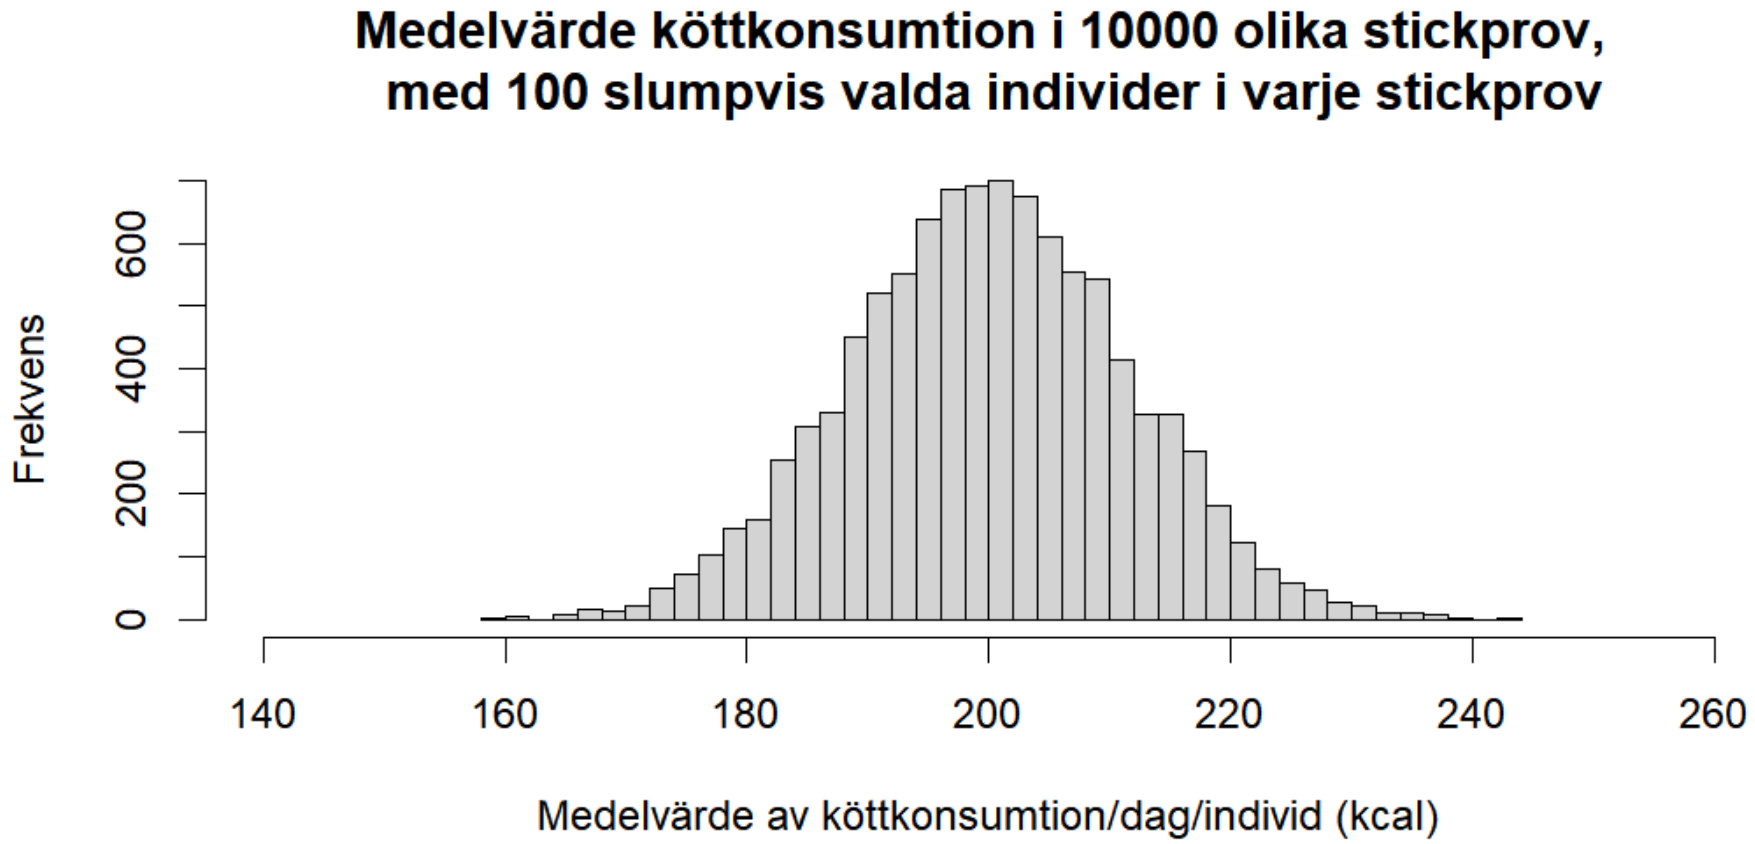

Normalfördelningen (normal distribution)

- En sannolikhetsfördelning som är symmetrisk kring medelvärdet
- Definieras av två parametrar:
  - Medelvärde (μ): Det centrala värdet
  - Standardavvikelse (σ): Mått på spridning
- Kontinuerlig, symmetrisk, klockformad kurva
- Medelvärde, median och typvärde är lika
- Vi kommer träffa på normalfördelningen igen på föreläsning 6 och 7, bland annat när vi ska dra slutsatser från statistiska undersökningar (inferens).
- Gå igenom i kapitel 13 (13.1-13.3).

Mer om normalfördelningen

- Följer 68-95-99.7-regeln:
  - 68% av värdena ligger inom 1σ från medelvärdet
  - 95% inom 2σ
  - 99.7% inom 3σ

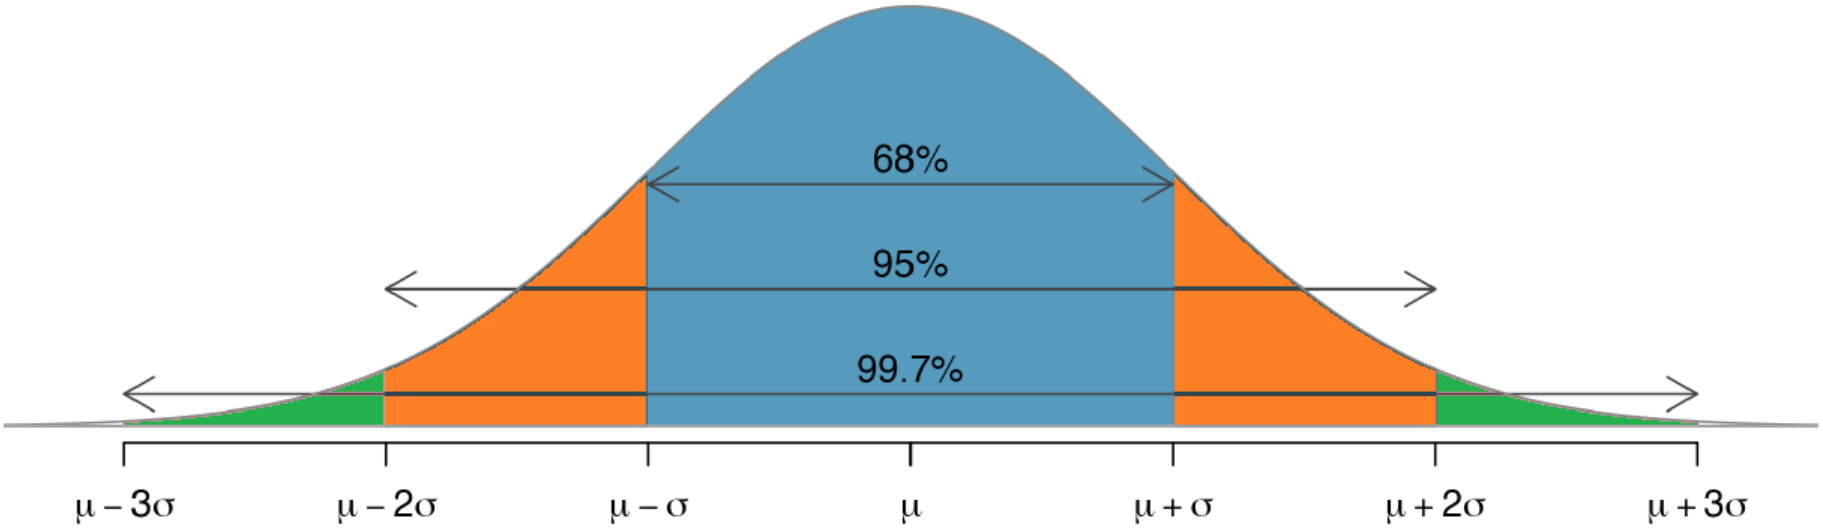

Standardisering av Normalfördelningen

- Av olika skäl är det praktiskt att "standardisera" normalfördelningen
  - Vi vill kunna jämföra fördelningar, där exempelvis ett dataset har variabler i SEK och ett annat i USD
  - Oberoende av skala på våra data vill vi ta reda hur sannolikt ett visst värde är, för detta används standardiserade tabeller/R-kommandon.
  - Vi arbetar därför med en fördelning centrerad kring 0 och med standarvavvikelse 1 (**standardnormalform**).
- Omvandla till så kallade Z-värden:

$$Z = \frac{X - \mu}{\sigma}$$

Exempel på standardisering

- Givet: $x = 75, \mu = 70, \sigma = 5$
- Beräkna z-värde:

$$z = \frac{75 - 70}{5} = 1$$

- Tolkning:
  - Värdet 75 är 1 standardavvikelse över medelvärdet
  - Enligt en Z-tabell (**standardiserade normalfördelningstabellen**), (F6, F7) är sannolikheten för att $X \leq 75$ lika med 0.8413 (eller 84.13%)

Denna version av dokumentet: 2026-03-30

Materialet i Statistisk översiktskurs har tagits fram av Ulf Högnäs och Anders Fredriksson, med inspiration och ibland direkt användande av material från andra kurser och personer, bland annat kurserna Statistik och dataanalys 1-3, med material av Michael Carlson, Ellinor Fackle Fornius, Jessica Franzén, Oskar Gustafsson, Oscar Oelrich, Mona Sfaxi, Karl Sigfrid, Mattias Villani, Valentin Zulj, med flera.