Föreläsning 6

Statistisk översiktskurs

Anders Fredriksson

Statistiska Institutionen
Stockholms Universitet

31 mars 2026

Föreläsning 6

- Mer om **samplingfördelningen**, **centrala gränsvärdessatsen** och **normalfördelningen**
- Diskussion om inferens gällande medelvärdet av en numerisk variabel resp. en andel
  - Kort om **binomialfördelningen**, relevant för variabler med två möjliga utfall, exv. Nej/Ja, skulle inte rösta/skulle rösta på S, misslyckat/lyckat (failure/success), **0/1**
- Lite mer om fördelningar

Föreläsning 6

- **Punktskattning** av en populationsparameter, skattningens **standardfel** och skattningens **konfidensintervall**
  - för variabler som är en andel - exv. andel S-väjare (härledd från en 0/1-variabel)
  - för numeriska variabler i allmänhet - exv. medellängd
- **Felmarginal** - ett relaterat begrepp

Föreläsning 6 (att läsa)

- Ca sju sidor totalt i IMS kapitel 11 och 12, se separat läsinstruktion
- IMS kapitel 13.1-13.3 (normalfördelningen)
- IMS kapitel 16.2.1-16.2.4 (inferens, andel)
- IMS kapitel 19.2.1-19.2.4 (inferens, medelvärde)

Kommer på föreläsning 7 (specifikt om hypotesprövning)

IMS kapitel 16.2.5 (andel)

IMS kapitel 19.2.5 (medelvärde)

Om kapitel 16, 17, 19, 20 i boken

V Statistical inference 256

16 Inference for a single proportion 258
16.1 Bootstrap test for a proportion . . . 258
16.2 Mathematical model for a proportion . . . 261
16.3 Chapter review . . . 268
16.4 Exercises . . . 269

17 Inference for comparing two proportions 279
17.1 Randomization test for the difference in proportions . . . 279
17.2 Bootstrap confidence interval for the difference in proportions . 281
17.3 Mathematical model for the difference in proportions . . . 285
17.4 Chapter review . . . 292
17.5 Exercises . . . 293

19 Inference for a single mean 319
19.1 Bootstrap confidence interval for a mean . . . 320
19.2 Mathematical model for a mean . . . 325
19.3 Chapter review . . . 335
19.4 Exercises . . . 336

20 Inference for comparing two independent means 342
20.1 Randomization test for the difference in means . . . 343
20.2 Bootstrap confidence interval for the difference in means . . . 346
20.3 Mathematical model for testing the difference in means . . . 348
20.4 Mathematical model for estimating the difference in means . . 351
20.5 Chapter review . . . 353
20.6 Exercises . . . 354

Exempel: en opinionsundersökning, ett visst partis andel

Exempel: ett partis andel, i två olika undersökningar (exv. olika tidpunkter)

Exempel: en undersökning om kvinnors medellängd

Exempel: två undersökningar om kvinnors medellängd, för två olika år (exv 2010, 2020)

(OBS: slumpmässiga urval från populationen)

Ingår

Tas upp på föreläsning 7, endast föreläsningsmaterialet ingår

Mer om samplingfördelningen, centrala gränsvärdessatsen och normalfördelningen - från F5

- Vi såg att (många) upprepade slumpvässiga urval (stickprov) för att skatta en andel ger oss (den ungefärliga) **samplingfördelningen** av andelen. Fördelningen kan approximeras med **normalfördelningen**.
- Detsamma gäller för upprepade slumpmässiga urval för att skatta en populationsparameter av typen "vuxna kvinnors medellängd" - samplingfördelningen kan approximeras med normalfördelningen.
- För båda variabeltyperna (andel mellan 0 och 1, kontinuerlig numerisk variabel i allmänhet) ger **centrala gränsvärdessatsen** att samplingfördelningen kan approximeras med normalfördelningen.
- Gäller om n är tillräckligt stort och utfallen är ändliga tal (F5, s. 37)

Samplingfördelningen, centrala gränsvärdessatsen och normalfördelningen - betydelse för oss

- Antag nu att vi har en (1) **punktskattning** av en andel från ett (1) stickprov, exv. från ett slumpmässigt urval av röstberättigade är andelen S-sympatisörer 38%
- eller en **punktskattning** av medelvärdet av en numerisk variabel, exv. från ett slumpmässigt urval är kvinnors medellängd 166,5 cm
- Med hjälp av resultaten ovan kan vi använda **normalfördelningen** för att ta fram
  - ett **konfidensintervall** för vår skattning (F6)
  - **testa hypoteser gällande populationsparametern** (exv. påståendet "S har högre stöd än i senaste valet") (F7)

Skattning av andel och av medelvärde av numerisk variabel

Andel

- Antag att vi upprepade gånger gör n på varandra följande 0/1-försök, exv. frågar n slumpvis utvalda röstberättigade om de ska rösta på S
- Koda "ska rösta på S" som 1, annars 0
- Vi får då en fördelning av antalet 1-or som är **binomialfördelad** (en diskret funktion som beror av urvalsstorleken n och populationsandelen p av 1-or
- Vi kan dividera antalet med n och istället studera andelen 1-or (samma utseende på fördelningen)

Skattning av andel och av medelvärde av numerisk variabel

Andel, fortsättning

- På F5 såg vi exempel med fördelningen av "andel S" från olika sådana slumpmässiga urval (två bilder nedan)
- Vi känner till vilken teoretisk funktionsform vi har (binomialfördelningen), och kan därtill approximera denna med **normalfördelningen** (mha. centrala gränsvärdessatsen)

Från F5 - vår empiriska fördelning, från 10000 slumpmässiga urval
Absolut frekvens på y-axeln

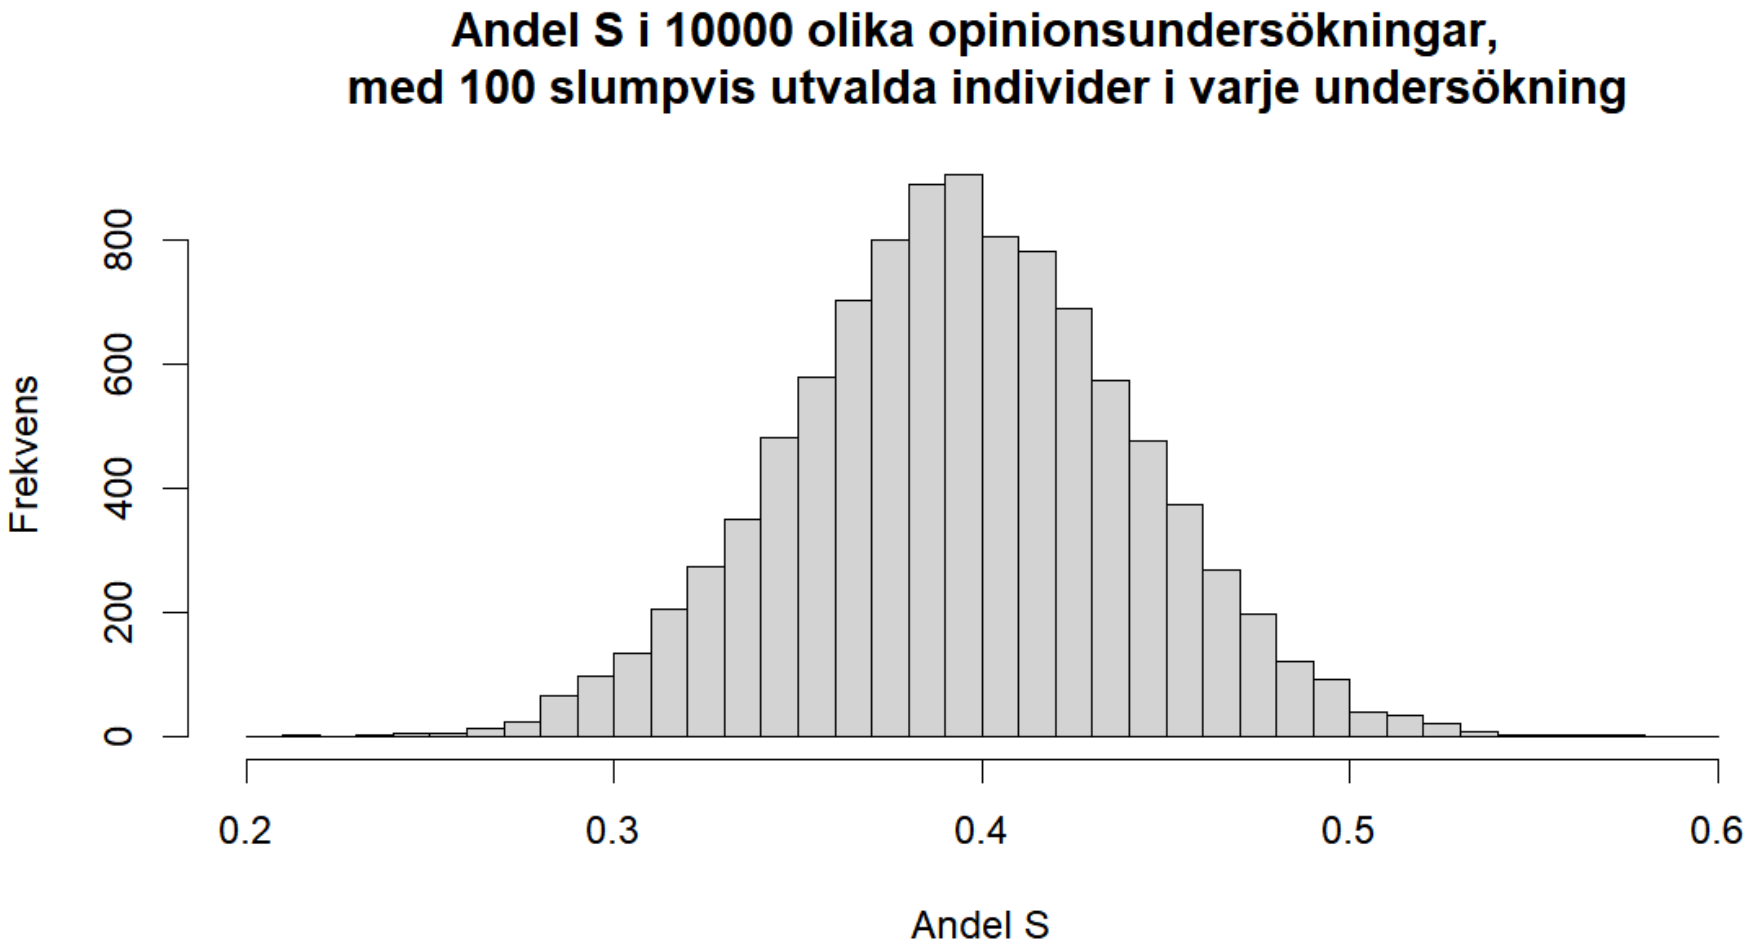

Samma fördelning men med relativ frekvens (sannolikhet för visst utfall - andel S - i de 10000 stickproven). ”Empirisk sannolikhetsfördelning”.

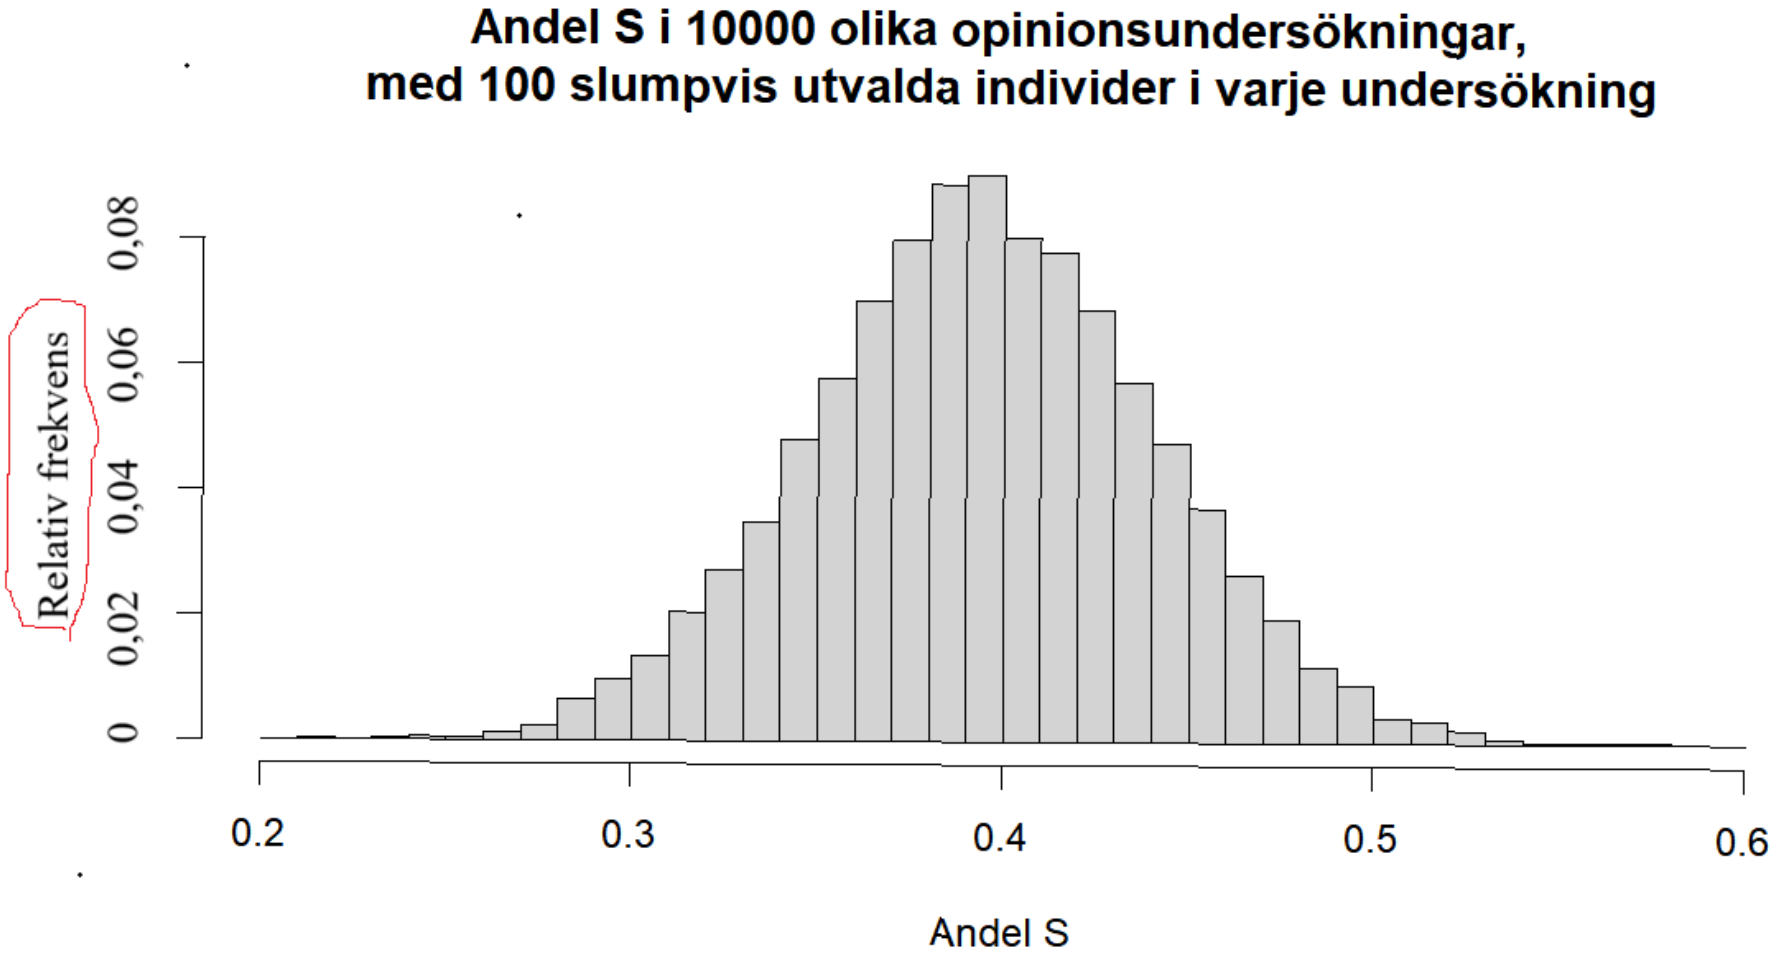

Skattning av andel och av medelvärde av numerisk variabel

Numerisk variabel (exv. kvinnors längd, mäns längd, köttkonsumtion)

- Variablen i sig är typiskt inte begränsad att ligga inom ett visst intervall och ofta känner vi inte till dess fördelning
- Om vi gör upprepade slumpvisa urval från populationen känner vi typiskt inte heller till den exakta samplingfördelningen (av medelvärdet)

- Men mha. av centrala gränsvärdessatsen kan vi ändå approximera samplingfördelningen med **normalfördelningen**

Något om sannolikhetsfördelningar, relaterat till ovan

- Kan vara kontinuerliga (exv. normalfördelningen) eller diskreta (exv. binomialfördelningen)
- Begreppet täthetsfunktion används för kontinuerliga och sannolikhetsfunktion för diskreta sannolikhetsfördelningar
- Kan vara teoretisk (den matematiska funktionen) eller empirisk (från data)
- Area under kurvan är alltid 1 (= hela sannolikheten)
- Tre exempel nästa sida

Bra att veta / kursivt: I kursen använder vi beteckningen populationsmedelvärde. Eftersom vi studerar slumpvariabler finns en alternativ och statistiskt mer formell beteckning: **väntevärde**.

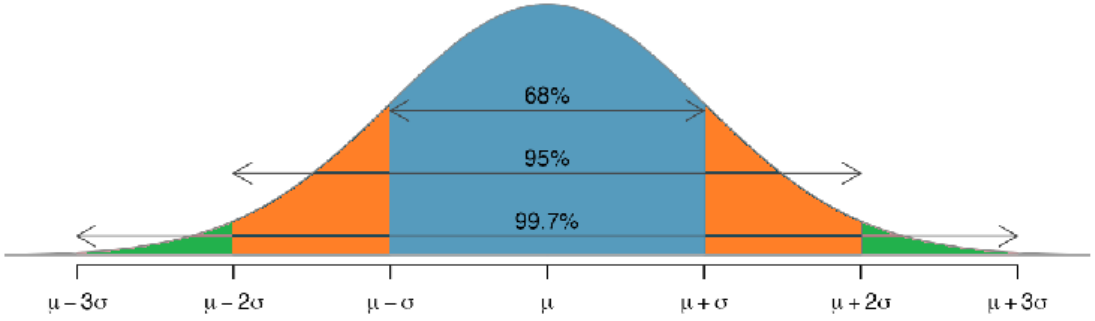

Kontinuerlig sannolikhetsfördelning
täthetsfunktion (density function)
teoretisk normalfördelning
(från boken kap 13 och F5)

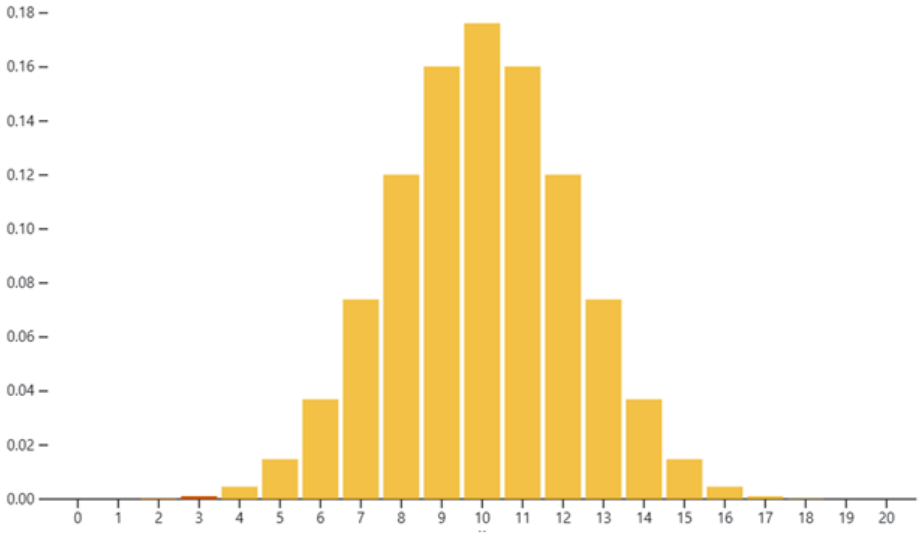

Diskret sannolikhetsfördelning
sannolikhetsfunktion
teoretisk binomialfördelning
(här: 20 myntkast, 50% sannolikhet för krona/klave, mao. n=20, p=0.5)

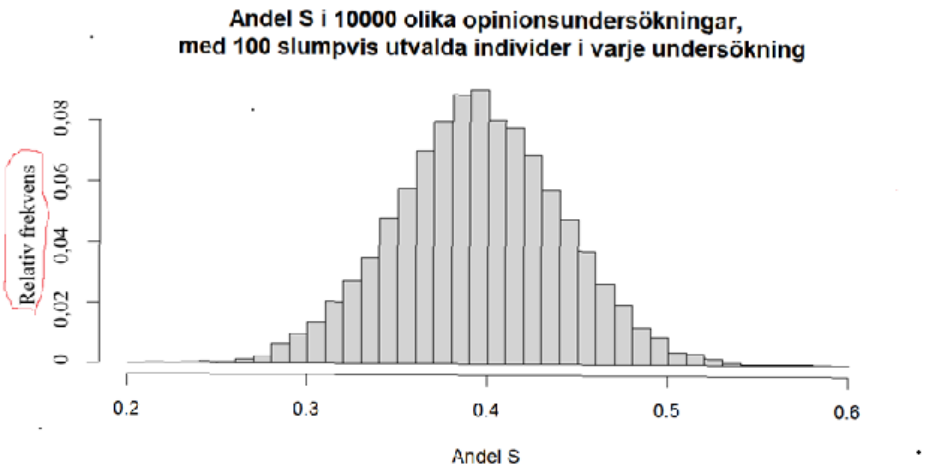

Diskret fördelning
empirisk fördelning från stickprov
den bakomliggande teoretiska fördelningen är binomialfördelningen
(från tidigare exempel)

Punktskattning, variation, standardfel

- Vi har sett att hur olika punktskattningar är fördelade kan approximeras med normalfördelningen
- **Standardfel** (standard error) är ett mått på variationen i skattningarna:

$$SE = \frac{\sigma}{\sqrt{n}}$$

- där σ är standardavvikelsen i populationen
- Varför ska vi dividera med $\sqrt{n}$?
  - Större urval - mer precisa skattningar (nästa bild)

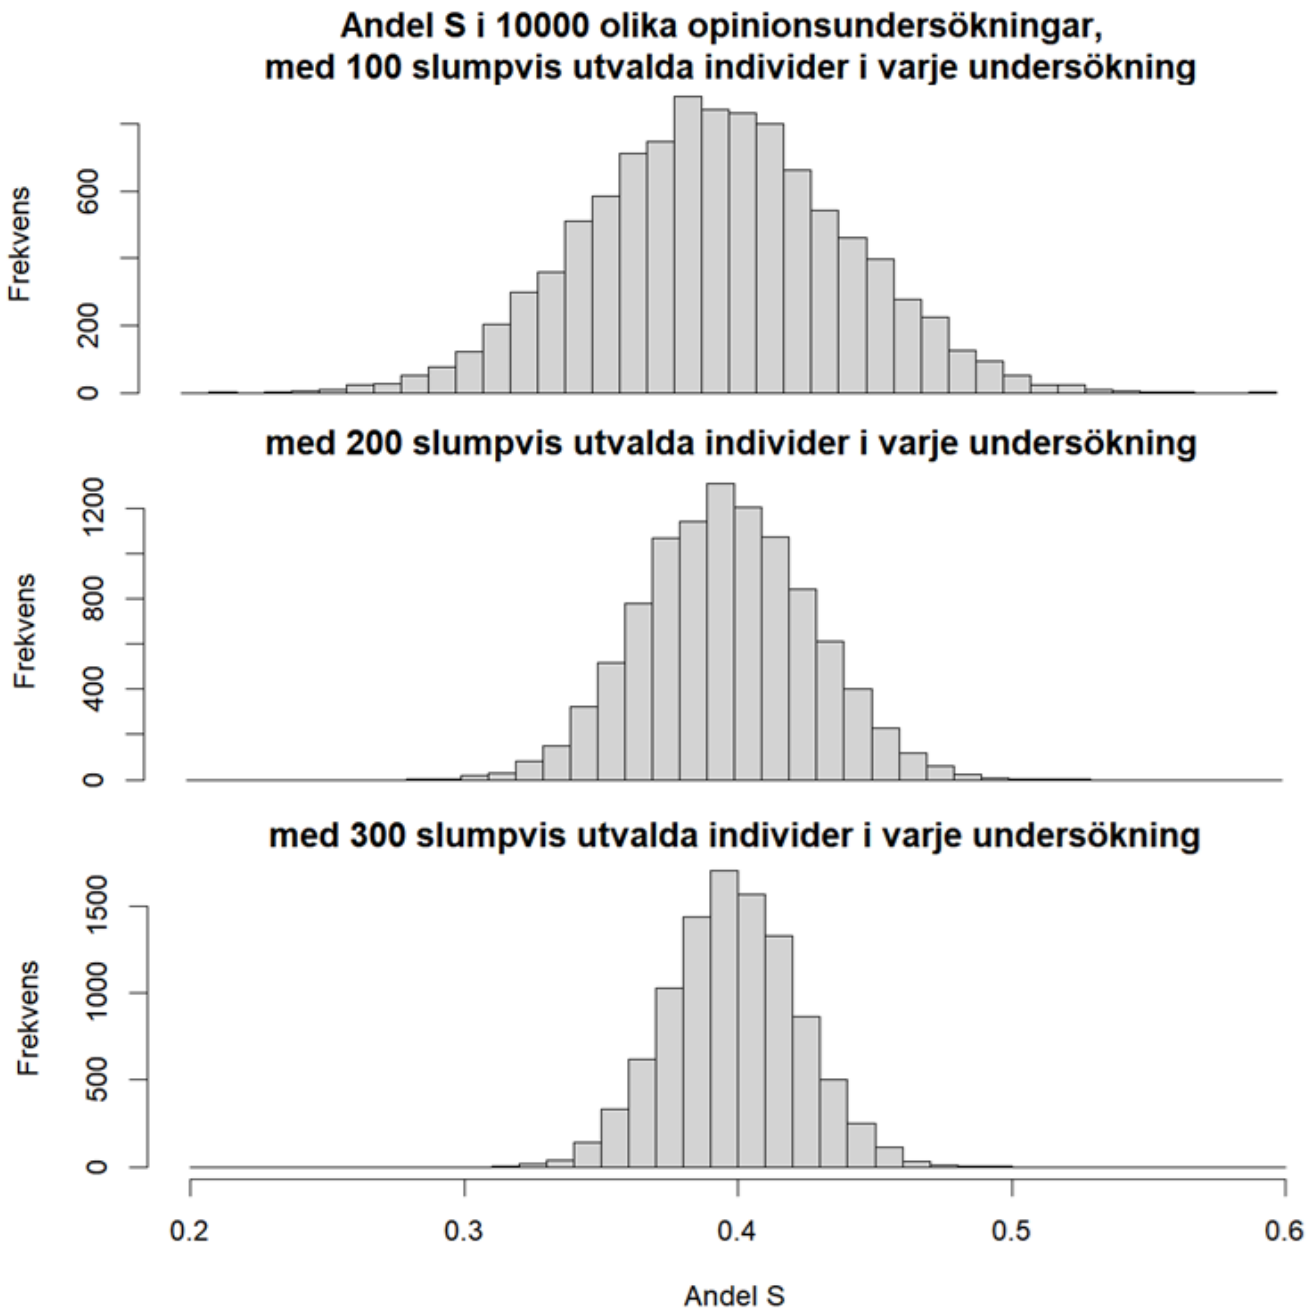

Vad händer med variationen i skattningen, när vi ökar storleken på stickproven?

Punktskattning, variation, standardfel

- På samma sätt som vi inte känner till den populationsparameter vi försöker skatta (exv. populationsmedelvärdet μ) känner vi typiskt inte heller till dess standardavvikelse σ
- Vi använder oss därför av en skattning av σ, standardavvikelen s i vårt stickprov
- **Standardfel** (standard error):

$$SE = \frac{s}{\sqrt{n}}$$

- där s är standardavvikelsen i stickprovet

Punktskattning, variation, standardfel

- För en numerisk variabel - räkna ut standardavvikelsen i stickprovet "som vanligt" (från F3), och sätt in i formeln för standardfel:

$$s = \sqrt{\frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2}$$

$$SE = \frac{s}{\sqrt{n}}$$

- För en **andel** $\hat{p}$ kan man härleda att standardfelet är

$$SE = \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$$

- där $\hat{p}$ är den skattade andelen

Exempel, andel

- Andel S-sympatisörer, i ett stickprov av storleken n=1000, är 0.38 ($\hat{p}$=0.38)
- Standardfelet blir

$$SE = \sqrt{\frac{\hat{p}(1-\hat{p})}{n}} = \sqrt{\frac{0.38(1-0.38)}{1000}} = \sqrt{\frac{0.38(0.62)}{1000}} \approx 0.0153$$

När kan vi använda normalfördelningsapproximationen?

- "Gäller om n är tillräckligt stort och utfallen är ändliga tal"
- **Observationerna ska vara oberoende**
- För **andelar** ska vi verifiera **success-failure condition** (kap 16.2.1):
  - Stickprovsfördelningen för $\hat{p}$, från ett urval av storlek n från en population med sann andel p, är ungefärligen normalfördelad när vi förväntar oss minst 10 lyckade och 10 misslyckade utfall:
  - $np \geq 10$ och $n(1-p) \geq 10$ (i praktiken: använd $\hat{p}$)
- På tenta etc. - kolla detta villkor
- Ovan hade vi: $n = 1000$, $\hat{p} = 0.38$ $n\hat{p} = 380$, $n(1-\hat{p}) = 620$, OK!

När kan vi använda normalfördelningsapproximationen?

- "Gäller om n är tillräckligt stort och utfallen är ändliga tal"
- **Observationerna ska vara oberoende**
- För **numeriska variabler** används **n>30** typiskt som kriterium - vi kan då anta att medelvärdesfördelningen är ungefärligen normalfördelad
  - I statistik (speciellt i större kurser) är fokus mycket på att delaljkontrollera antaganden. "Plotta!".
  - Nyanser diskuteras i kap 19.2.2, exv. om vi har outliers
  - Om data i sig är normalfördelade kan lägre urvalsstorlek vara OK
- På tenta etc. - kolla villkoret ($n > 30$)

Med vilken säkerhet vill vi kunna dra slutsatser?

- Baserat på vårt urval vill vi kunna säga något om populationsparametern med en viss grad av säkerhet
- Beroende på vilken grad av säkerhet vi väljer får vi olika **felmarginal** och olika stora **konfidensintervall**

Normalfördelningen igen

- På föreläsning 5 såg vi, **om en normalfördelad variabel**, att fördelningen följer 68-95-99.7-regeln:
  - 68% av värdena ligger inom 1σ från medelvärdet
  - 95% inom 2σ
  - 99.7% inom 3σ

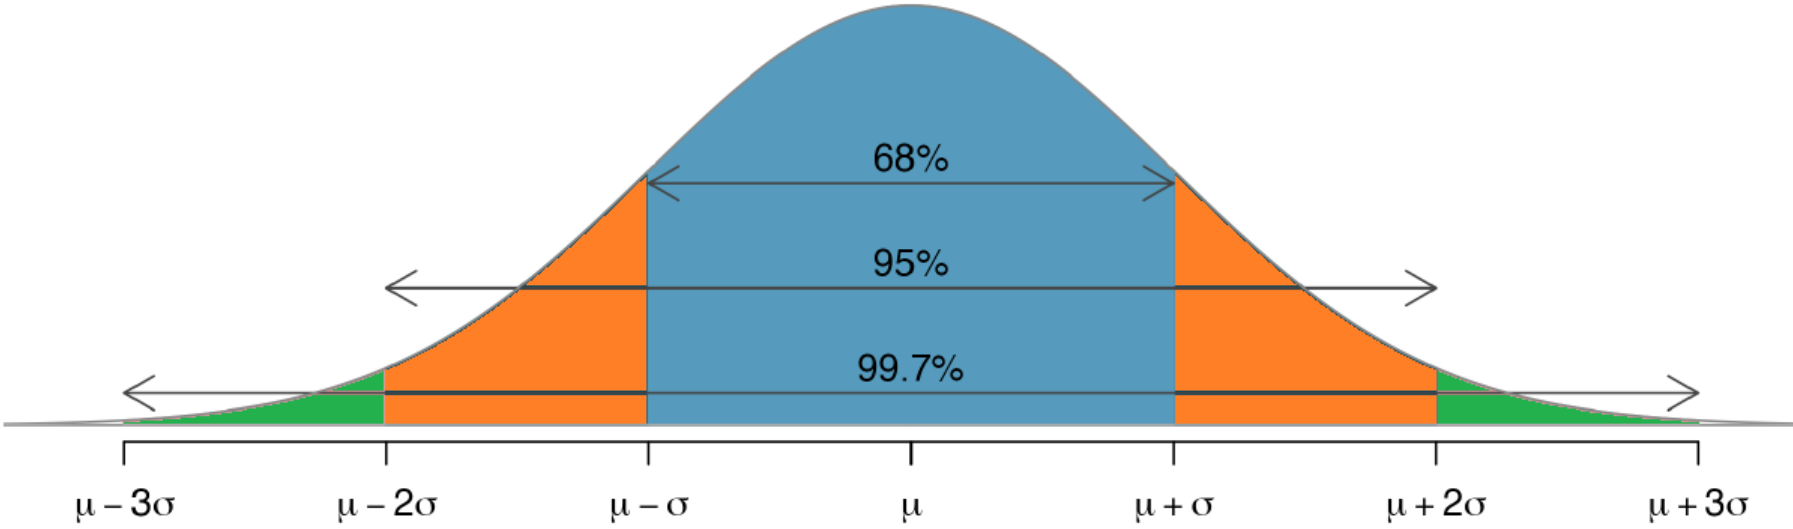

Konfidensintervall, 95%

- Använd 68/**95**/99.7-regeln
- Kom ihåg att vi studerar inte en variabel i sig utan en **skattning av ett medelvärde eller av en andel**
  - Vi ska inta använda μ utan vår skattning
  - Vi ska inta använda σ utan standardfelet för vår skattning
- Då kan vi ta fram ett (ungefärligt) **95%-igt konfidensintervall** för skattningen
  - **Punktskattning** $\pm$ **2**$\times$**standardfelet**, mao
  - $\bar{x} \pm \ 2\frac{s}{\sqrt{n}}$ - för skattning av medelvärde (med s enligt vanliga formeln)
  - $\hat{p} \pm 2\sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$ - för skattning av andel
  - där tvåan kommer från att vi ska vara 2 standardfel "ut från" värdet på skattningen för att 95% av sannolikheten ska täckas (föreg. sida)

Konfidensintervall, 95%, exempel

Exempel 1

- Antag att i ett stort och slumpmässigt urval med oberoende observationer har kvinnor en medellängd 166,2 cm och vi beräknar standardfelet till 0.5 cm
- Konfidensintervallet blir $166.2 \pm 2 \times 0.5$ cm = (165.2, 167.2) cm
- OBS: ta med enhet

Exempel 2

- Antag att i ett slumpmässigt urval enligt ovan är andel S-sympatisörer 0.38 och vi har beräknat standardfelet till 0.0153
- Konfidensintervallet blir $0.38 \pm 2 \times 0.0153$ = (0.3494, 0.4106)

Mer om konfidensintervall

- Lite informellt kan vi säga att "vi är 95% säkra på att intervallet fångar det sanna värdet på populationsparametern"
- Det exakta värdet i formeln är inte 2 utan 1.96:
  - $\bar{x} \pm 1.96 \frac{s}{\sqrt{n}}$ - för skattning av medelvärde (med s enligt vanliga formeln)
  - $\hat{p} \pm 1.96 \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$ - för skattning av andel
- Den andra termen i formlerna kallas också **felmarginal**

Konfidensintervall och konfidensgraden α

- Vi kanske vill ha något annat, exv. ett 90%-igt konfidensintervall
- Allmänt gäller att ett $(1-\alpha)100\%$-igt konfidensintervall (för ett medelvärde) ges av:
  - $\bar{x} \pm Z_{\alpha/2} \frac{\sigma}{\sqrt{n}}$ om σ är känd, annars
  - $\bar{x} \pm Z_{\alpha/2} \frac{s}{\sqrt{n}}$
- Analogt, för andelar, fås ett $(1-\alpha)100\%$-igt konfidensintervall av:
  - $\hat{p} \pm Z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$
- Z-värden finns i tabeller över den standardiserade normalfördelningen (och i R), för olika värden på konfidensgraden α
- Exempel kommer på övning 2 och på datorlaboration 3

Konfidensintervall, vanliga nivåer

- Ett 90%-igt konfidensintervall ($\alpha/2 = 0.05$) ges av:

$$\bar{x} \pm Z_{\alpha/2}\frac{s}{\sqrt{n}} = \bar{x} \pm Z_{0.05}\frac{s}{\sqrt{n}} = \bar{x} \pm 1.64\frac{s}{\sqrt{n}}$$

- 95%-igt konfidensintervall ($\alpha/2 = 0.025$) ges av:

$$\bar{x} \pm Z_{\alpha/2}\frac{s}{\sqrt{n}} = \bar{x} \pm Z_{0.025}\frac{s}{\sqrt{n}} = \bar{x} \pm 1.96\frac{s}{\sqrt{n}}$$

- 99%-igt konfidensintervall ($\alpha/2 = 0.005$) ges av

$$\bar{x} \pm Z_{\alpha/2}\frac{s}{\sqrt{n}} = \bar{x} \pm Z_{0.005}\frac{s}{\sqrt{n}} = \bar{x} \pm 2.58\frac{s}{\sqrt{n}}$$

OBS: Konfidensintervall för andelar justeras på motsvarande sätt

Tolkning av konfidensintervall

- Ett konfidensintervall är konstruerat på ett sådant sätt att det väldigt ofta täcker det sanna värdet, exempelvis μ.
- Ett 95%-igt konfidensintervall täcker det sanna värdet i 95 fall av 100, d.v.s. om vi tar 100 olika urval av storleken n från samma population och beräknar ett konfidensintervall för varje urval, kommer dessa intervall att täcka det sanna värdet på μ ungefär 95 gånger.
- Man säger alltså inte att sannolikheten att μ ligger inom ett enskilt konfidensintervall är 0.95. Antingen täcker intervallet μ eller så gör det inte det.
- Man säger istället att vi med 95% konfidens (eller säkerhet) har konstruerat ett intervall som innehåller μ.

Om t-fördelningen (kap 19.2)

- Man behöver känna till begreppen, bland annat eftersom **t-värde** återkommer i regressionsdelen
- I kap 19.2 ser vi att, för numeriska variabler, med skattad standardavvikelse s, är medelvärdet **t-fördelat**, inte normalfördelat
- Praktisk skillnad enbart för små n, säg $n \leq 30$
- För varje värde på $n - 1$ (antal **frihetsgrader**) finns en t-fördelning
- Liknar normalfördelning (figur 19.8, 19.9) men med bredare svansar (högre sannolikhet för värden längre ut)
- Om vi gör konfidensintervall, för små n, bör vi använda T-värden istället för Z-värden (tabell och R-kommando skiljer sig)
- Labb 3: Jämför konf-intervall konstruerade med Z-värde och T-värde
- Återkommer när vi studerar regression (F8-F10)

Denna version av dokumentet: 2026-03-31

Materialet i Statistisk översiktskurs har tagits fram av Ulf Högnäs och Anders Fredriksson, med inspiration och ibland direkt användande av material från andra kurser och personer, bland annat kurserna Statistik och dataanalys 1-3, med material av Michael Carlson, Ellinor Fackle Fornius, Jessica Franzén, Oskar Gustafsson, Oscar Oelrich, Mona Sfaxi, Karl Sigfrid, Mattias Villani, Valentin Zulj, med flera.