Deskriptiv statistik - en variabel

Stickprov, en variabel

Medelvärde: $\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i$

Varians: $s^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2$

Standardavvikelse: $s = \sqrt{s^2}$

Deskriptiv statistik - två variabler

Stickprov, två variabler

Kovarians; $\text{Covar}(x,y) = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})$

Korrelation: $\text{Corr}(x,y) = r = \frac{1}{n-1}\sum_{i=1}^{n}\frac{(x_i-\bar{x})}{s_x}\frac{(y_i-\bar{y})}{s_y}$

Inferens för en population

Standardfel, numerisk variabel (skattning populationsmedelvärde)

$$\frac{s}{\sqrt{n}}$$

Standardfel, andel (skattning populationsandel)

$$\sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$$

Konfidensintervall, numerisk variabel (skattning populationsmedelvärde)

$$\bar{x} \pm Z_{\alpha/2}\frac{s}{\sqrt{n}}$$ (exv. $Z_{\alpha/2}$ =1.96 för 95%-igt konfidensintervall)

Konfidensintervall, andel (skattning populationsandel)

$$\hat{p} \pm Z_{\alpha/2}\sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$$ (exv. $Z_{\alpha/2}$ =1.96 för 95%-igt konfidensintervall)

Värde på testvariabel, numerisk variabel $H_0 : \mu = \mu_0$

$$Z_{\text{obs}} = \frac{\bar{x} - \mu_0}{s/\sqrt{n}}$$

Värde på testvariabel, andel $H_0 : p = p_0$

$$Z_{\text{obs}} = \frac{\hat{p} - p_0}{\sqrt{\hat{p}(1-\hat{p})/n}}$$

Standardisering, normalfördelad variabel

Om $X \sim N(\mu, \sigma)$ så

$$Z = \frac{X - \mu}{\sigma} \sim N(0,1)$$

X - "normalfördelad med medelvärde my och standardavvikelse sigma"

Z - "normalfördelad med medelvärde 0 och standardavvikelse 1"

Enkel linjär regression

Populationsmodell

$$Y = \beta_0 + \beta_1 X + \varepsilon$$

Skattad modell (den skattade regressionslinjen)

$$Y = b_0 + b_1 X$$

Standardfel för b_1

Från regressionstabell (Standard Error - SE)

Konfidensintervall för β_1

$b_1 \pm t^*_{df} \times SE_{b_1}$ (från boken). Vi använder standardnormalfördelningen och använder därför

Z istället för t, dvs: $b_1 \pm Z_{\alpha/2} \times SE_{b_1}$

Värde på testvariabel, regressionskoefficient $H_0 : \beta_1 = 0$

$$t_{obs} = \frac{b_1}{SE_{b_1}} \quad (= z_{obs})$$

(Kallas t-värde i regressionstabeller etc. I kursen använder vi standardnormalfördelningen - inte t-fördelningen - när vi utvärderar vår hypotes.)

Prediktion för $x = x_i$

$$\hat{y}_i = b_0 + b_1 x_i$$

Multipel linjär regression

Populationsmodell

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \ldots + \varepsilon$$

(ex: om du har fem variabler - lägg till två termer)

Skattad modell (den skattade regressionslinjen)

$$Y = b_0 + b_1 X_1 + b_2 X_2 + b_3 X_3 + \ldots$$

(ex: om du har fem variabler - lägg till två termer)

Standardfel för regressionskoefficienter

Från regressionstabell

Konfidensintervall för β_1 (OBS: Analogt för de andra regressionskoefficienterna)

$b_1 \pm t^*_{df} \times SE_{b_1}$ (från boken). Vi använder standardnormalfördelningen och använder därför

Z istället för t, dvs: $b_1 \pm Z_{\alpha/2} \times SE_{b_1}$

Värde på testvariabel, regressionskoefficient $H_0 : \beta_1 = 0$

$$t_{obs} = \frac{b_1}{SE_{b_1}} \quad (= z_{obs})$$

(Kallas t-värde i regressionstabeller etc. I kursen använder vi standardnormalfördelningen - inte t-fördelningen - när vi utvärderar vår hypotes.)

Prediktion för $x = x_i$

$$\hat{y}_i = b_0 + b_1 x_{1,i} + b_2 x_{2,i} + b_3 x_{3,i} + \ldots$$

(där exv. $x_{1,i}$ är värdet på den första förklaringsvariabeln, för den aktuella observationen)