Föreläsning 2

Statistisk översiktskurs

Anders Fredriksson

Statistiska Institutionen
Stockholms Universitet

24 mars 2026

Föreläsning 2

- Variabeltyper och variabelegenskaper
- Deskriptiv statistik: Olika typer av tabeller, diagram och grafer

Variabler

- En variabel är, som ordet antyder, något som kan variera
- En egenskap som kan variera mellan olika element i populationen
- Delas in i kategoriska variabler och numeriska variabler
- I ett välstrukturerat dataset representerar varje kolumn en variabel

Kategoriska variabler

Kategoriska variabler (alternativt: Kvalitativa, Icke-numeriska)

- Kan delas in i kategorier, grupper

Exempel

- kön
- civilstånd
- bilmärken
- studieprogram
- partitillhörighet

Numeriska variabler

Numeriska variabler (alternativt: Kvantitativa)

- Representerar mängder

Exempel

- antal bilar på en parkering
- mängd flingor i ett paket (i gram)
- en individs längd (i cm)
- andel som röstar på ett visst parti (i procent)

Numeriska variabler kan vidare delas in i

Diskreta numeriska variabler

- kan endast anta vissa värden (oftast 0, 1, 2, osv.)
- **Ex:** antal paket flingor

Kontinuerliga numeriska variabler

- kan anta alla värden
- **Ex:** mängd flingor i ett paket (i gram)

Exempel på variabler och *variabeltyp*

- **Färgpreferens**
  Kategorisk
- **Antal hemmavarande barn**
  Kvantitativ och diskret
- **Tid att springa 100 meter**
  Kvantitativ och kontinuerlig
- **Attityd till återinförande av fastighetsskatt**
  Kategorisk
- **Poäng på tenta**
  Kvantitativ och i praktiken diskret
- **Partisympati**
  Kategorisk
- **Ålder**
  Kvantitativ och (om vi avser "antal fyllda år") diskret

Datanivåer / skalnivåer

Utöver indelningen i kategorisk/numerisk delar man också in variabler efter s.k. skalnivå (ungefärligen: informationsinnehåll)

- **Nominalskala** - klassificerar men går inte att rangordna
  Ex: färg - gul/grön/blå

- **Ordinalskala** - går att rangordna
  Ex: gillar du regeringen? - lite/mellan/mycket

- **Intervallskala** - samma avstånd på skalan ("skalsteg")
  Ex: temperatur i grader Celsius

  (skillnaden mellan 3 och 2 grader Celsius är lika med skillnaden mellan 15 och 14 grader Celsius)

- **Kvotskala** - absolut nollpunkt
  Ex: temperatur i Kelvin, antal barn, avstånd till olika turistmål

Skalnivåer, tabell

	Rangordning	**Lika skalsteg**	**Absolut 0-punkt**
Nominal	Nej	Nej	Nej
Ordinal	Ja	Nej	Nej
Intervall	Ja	Ja	Nej
Kvot	Ja	Ja	Ja

Tre saker att hålla reda på

- En kategorisk variabel är antingen på nominal- eller ordinalskala

- Även om vi kodar en kategorisk variabel med siffror innebär det inte att vi får en numerisk variabel

  Ex: civilstånd enligt 1=ogift, 2=gift, 3=..., osv.
  Siffrorna i sig har ingen kvantitativ innebörd

  Ex: Gillar du regeringen? (1=lite, 2=mellan, 3=mycket)
  Skillnad mellan 2 & 1, och mellan 3 & 2, måste inte vara samma

- En numerisk variabel kan göras om till en kategorisk variabel

  Ex: dela in ålder i ålderskategorier, exv. 18-30, 31-40, osv.
  (vi får en kategorisk variabel på ordinalskala)

Vi kommer nu använda data från datasetet Titanic

Några variabler och observationer:

Variabler

Observationer

(eng: cases)

	Name	Survived	Boarded	Class	MWC	Age
1	ABBING, Mr Anthony	Dead	Southampton	3	Man	42.00
2	ABBOTT, Mr Ernest Owen	Dead	Southampton	Crew	Man	21.00
3	ABBOTT, Mr Eugene Joseph	Dead	Southampton	3	Child	14.00
4	ABBOTT, Mr Rossmore Edward	Dead	Southampton	3	Man	16.00
5	ABBOTT, Mrs Rhoda Mary 'Rosa'	Alive	Southampton	3	Woman	39.00
6	ABELSETH, Miss Karen Marie	Alive	Southampton	3	Woman	16.00
7	ABELSETH, Mr Olaus Jrgensen	Alive	Southampton	3	Man	25.00
8	ABELSON, Mr Samuel	Dead	Cherbourg	2	Man	30.00
9	ABELSON, Mrs Hannah	Alive	Cherbourg	2	Woman	28.00
10	ABRAHAMSSON, Mr Abraham August Johannes	Alive	Southampton	3	Man	20.00

Deskription - Att sammanfatta, beskriva och redovisa data
Vi börjar med begreppet fördelning (distribution)

Fördelning

- Vilka värden en variabel kan ha
- Hur ofta olika värden förekommer
- Begreppet används både för hur en viss variabel i ett faktiskt dataset är fördelad och för matematiska modeller (ex: normalfördelningen)
- Återkommer många gånger

Kategoriska variabler - frekvenstabell

En kategorisk variabel

- **Ex:** Titanic, fördelning av överlevande/ej överlevande
- **Ex:** Titanic, fördelning av passagerarklass

Status_överlevnad	Antal_individer	Andel_individer	Procentandel_ind
Överlevde	712	0.322	32.2
Överlevde inte	1496	0.678	67.8
Totalt	2208	1.000	100.0

Klass	Antal_individer	Andel_individer	Procentandel_ind
Första	324	0.147	14.7
Andra	285	0.129	12.9
Tredje	710	0.322	32.2
Besättning	889	0.403	40.3
Totalt	2208	1.000	100.0

Kategoriska variabler - korstabell (contingency table)

Två kategoriska variabler

- **Ex:** Titanic, överlevande och klass
- Begreppen **simultan fördelning** och **marginell fördelning** (återkommer på datorlaboration 2)

Klass	Överlevde (%)	Överlevde inte (%)	Totalt (%)
Första	9.1	5.6	14.7
Andra	5.4	7.5	12.9
Tredje	8.2	24.0	32.2
Besättning	9.6	30.7	40.3
Totalt	32.2	67.8	100.0

Ett annat exempel på en korstabell (från boken)

Table 4.1: A contingency table for application type and homeownership.

	homeownership			
application_type	rent	mortgage	own	Total
joint	362	950	183	1495
individual	3496	3839	1170	8505
Total	3858	4789	1353	10000

Kategoriska variabler - korstabell med betingad fördelning

- Två kategoriska variabler
- **Ex:** Titanic, överlevande per klass ("betingat på klass")
- Begreppet **betingad fördelning** (återkommer på datorlaboration 2)

Status_överlevnad	Första kl.	Andra kl.	Tredje kl.	Besättning
Överlevde (%)	62	41.8	25.4	23.8
Överlevde inte (%)	38	58.2	74.6	76.2
Totalt (%)	100	100.0	100.0	100.0

Kategoriska variabler - stapeldiagram (bar chart / bar plot)

En kategorisk variabel

- **Ex:** Titanic, överlevande
- **Ex:** Titanic, klass

Antal individer som överlevde/inte överlevde Titanic

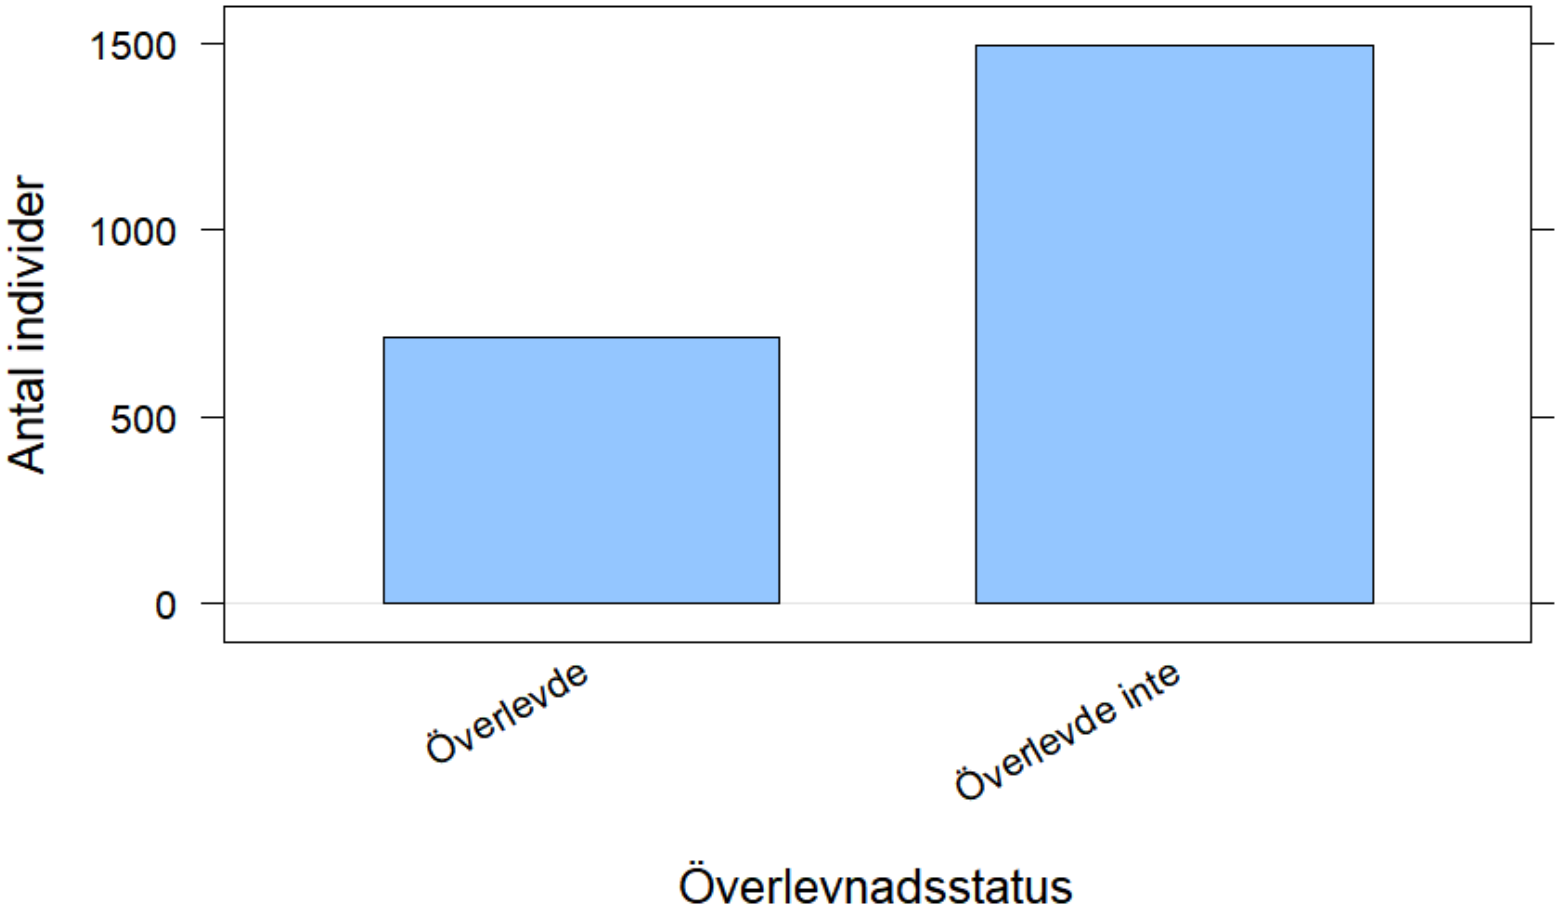

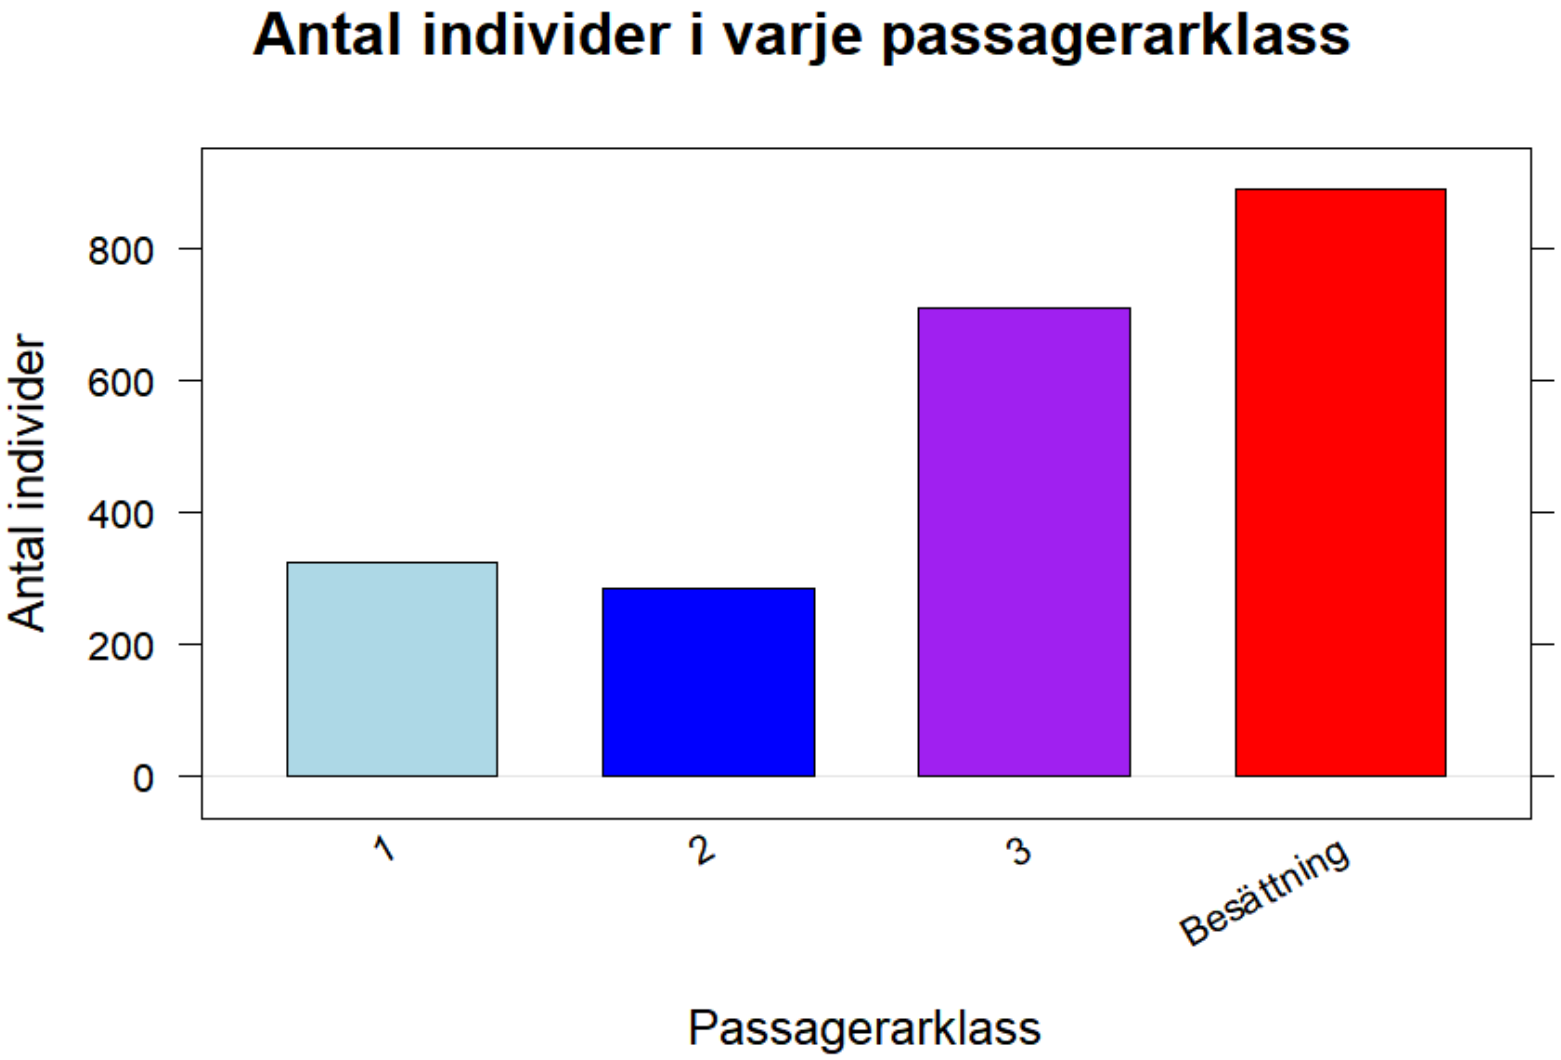
Antal individer i varje passagerarklass
Antal individer
0
200
400
600
800
1
2
3
Besättning
Passagerarklass

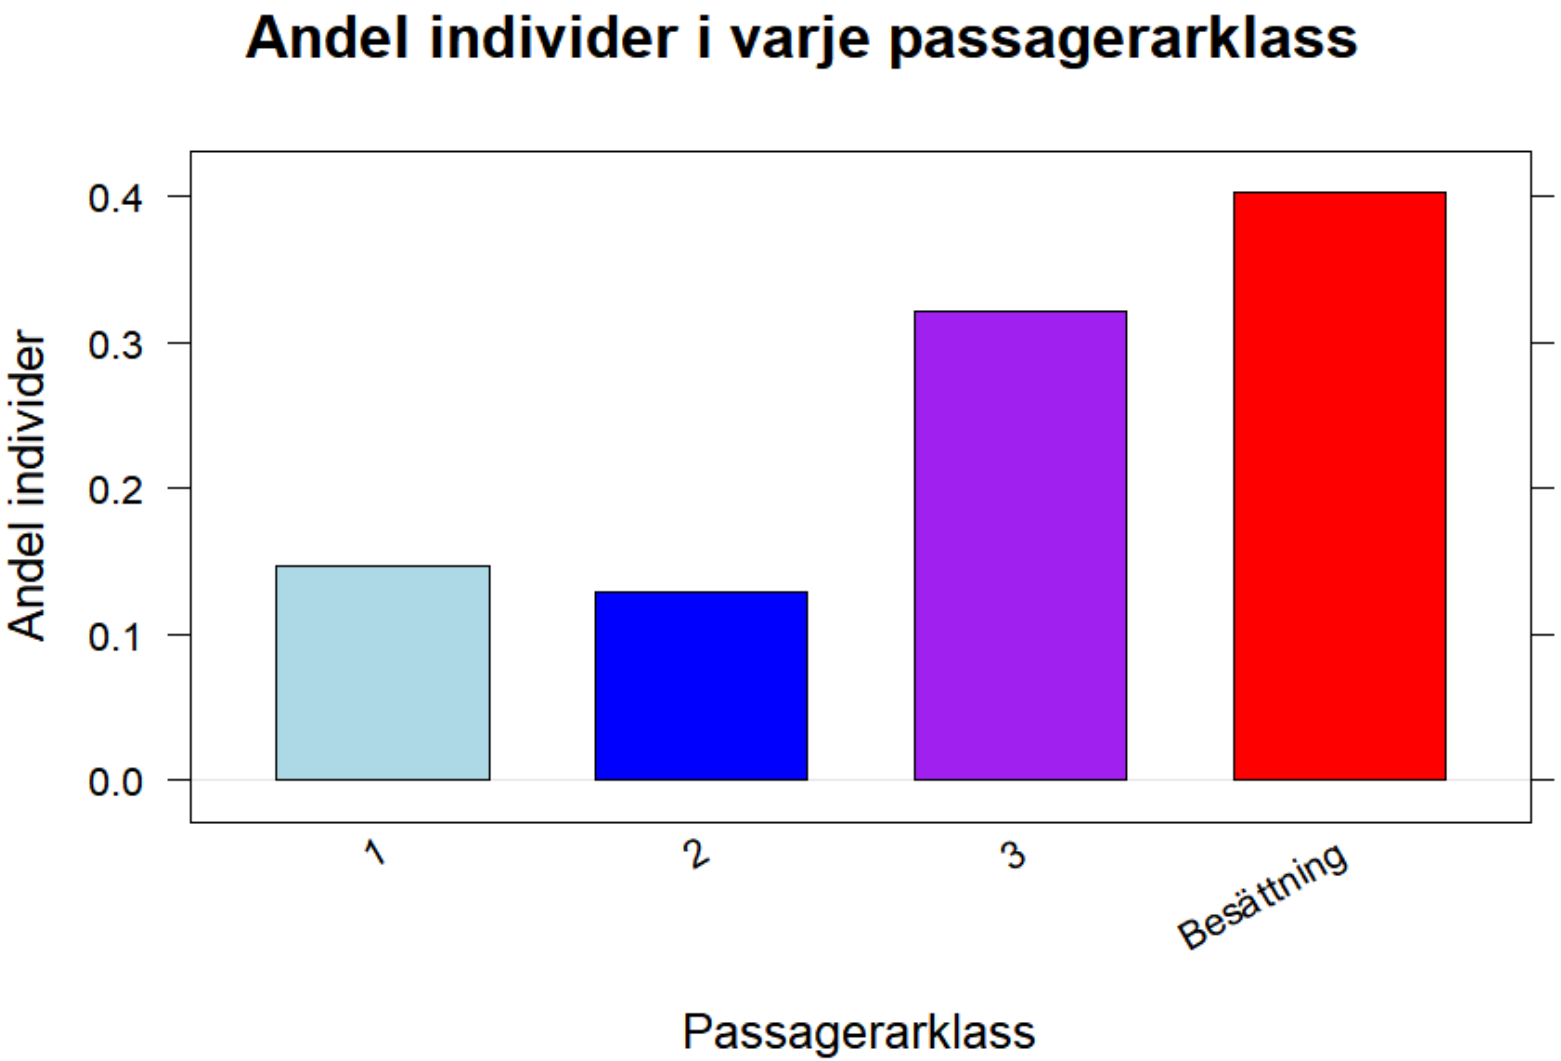
Andel individer i varje passagerarklass
Andel individer
0.0
0.1
0.2
0.3
0.4
1
2
3
Besättning
Passagerarklass

Kategoriska variabler - cirkeldiagram (pie chart)

En kategorisk variabel

- **Ex:** Titanic, klass

Andel individer i varje passagerarklass

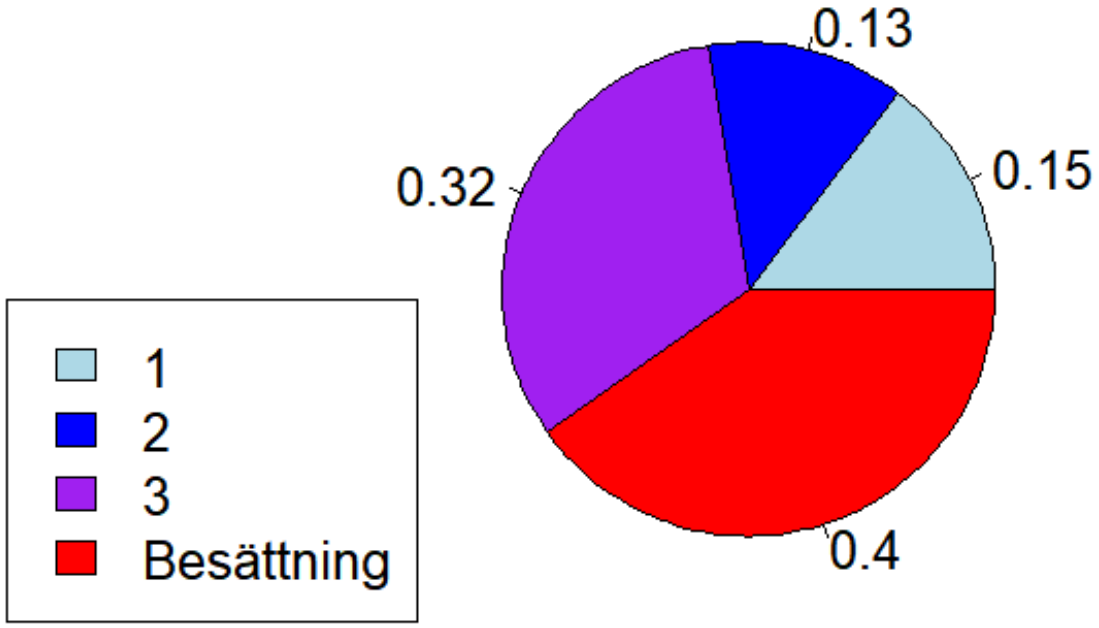

AI and College Value

Students (all) say whether/how the rise of generative AI has changed how they think about the value or purpose of college

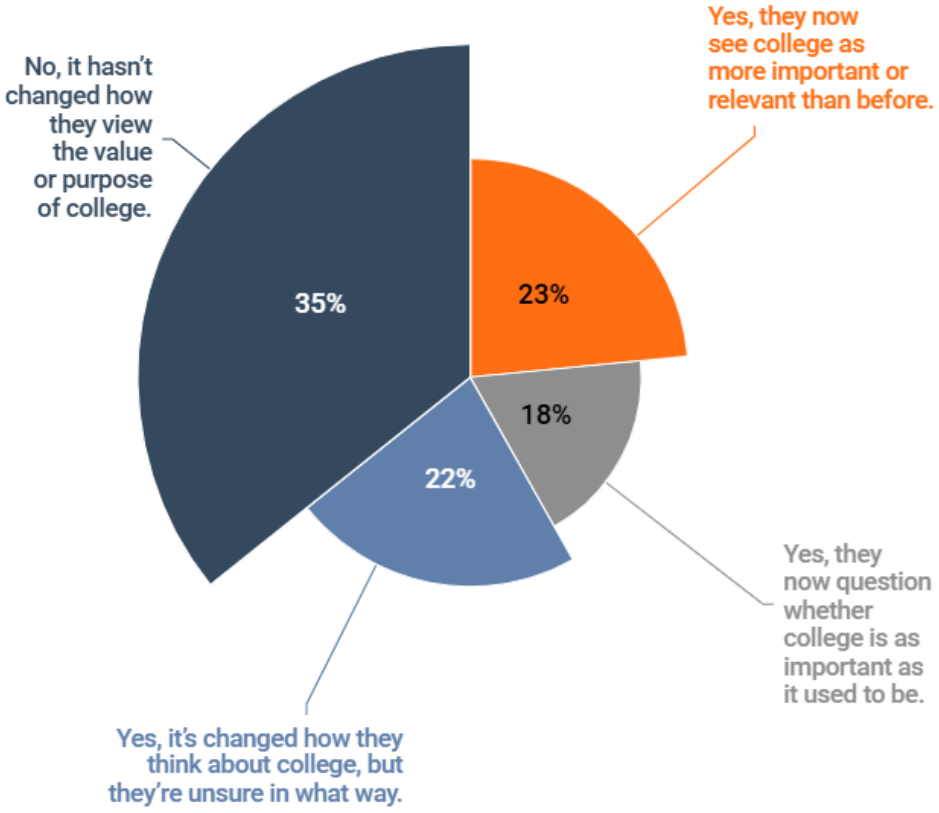

Vad är problemet med denna visualisering?

Källa: https://www.insidehighered.com/news/students/academics/2025/08/29/survey-college-students-views-ai

AI and College Value

Students (all) say whether/how the rise of generative AI has changed how they think about the value or purpose of college

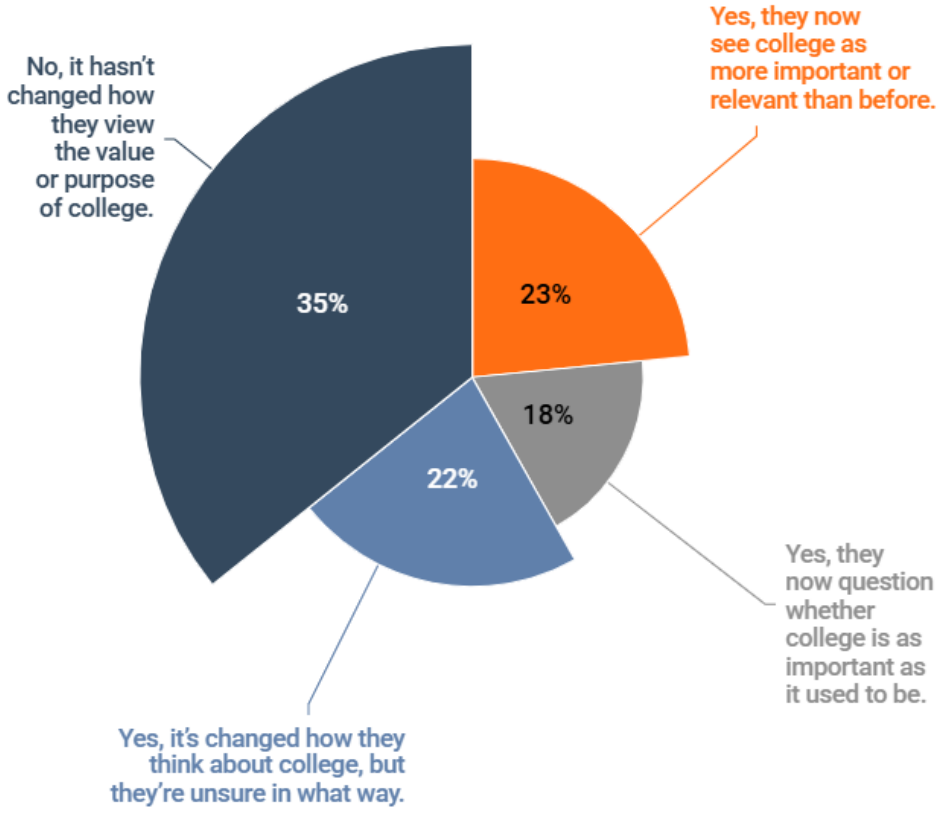

Vad är problemet med denna visualisering?

Arean bör vara proportionell mot storleken på det som "tårtbiten" visar. Gäller även andra typer av diagram ("areaprincipen").

AI and College Value

Students (all) say whether/how the rise of generative AI has changed how they think about the value or purpose of college

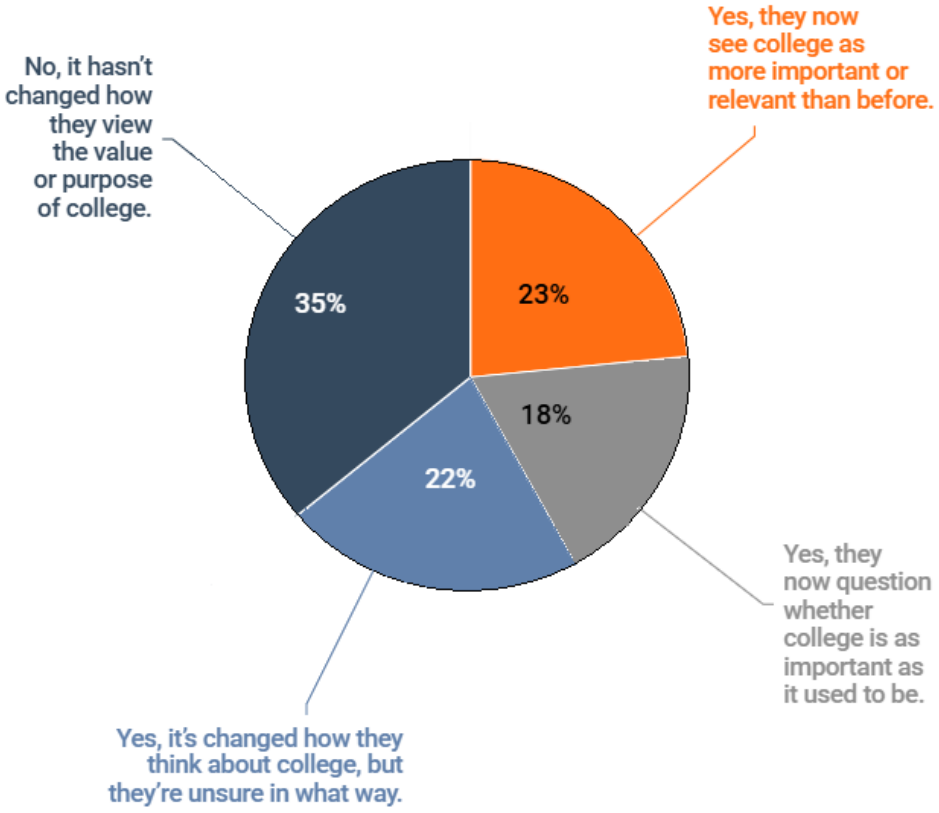

Arean bör vara proportionell mot storleken på det som "tårtbiten" visar. Gäller även andra typer av diagram ("areaprincipen").

Kategoriska variabler - grupperade och staplade stapeldiagram (grouped / stacked bar charts / bar plots)

- Två kategoriska variabler
- Olika varianter (och namn) finns, se boken kapitel 4.2.1

- **Ex nedan:** Titanic, överlevande per klass (två varianter)

Antal överlevande/icke överlevande i varje passagerarklass

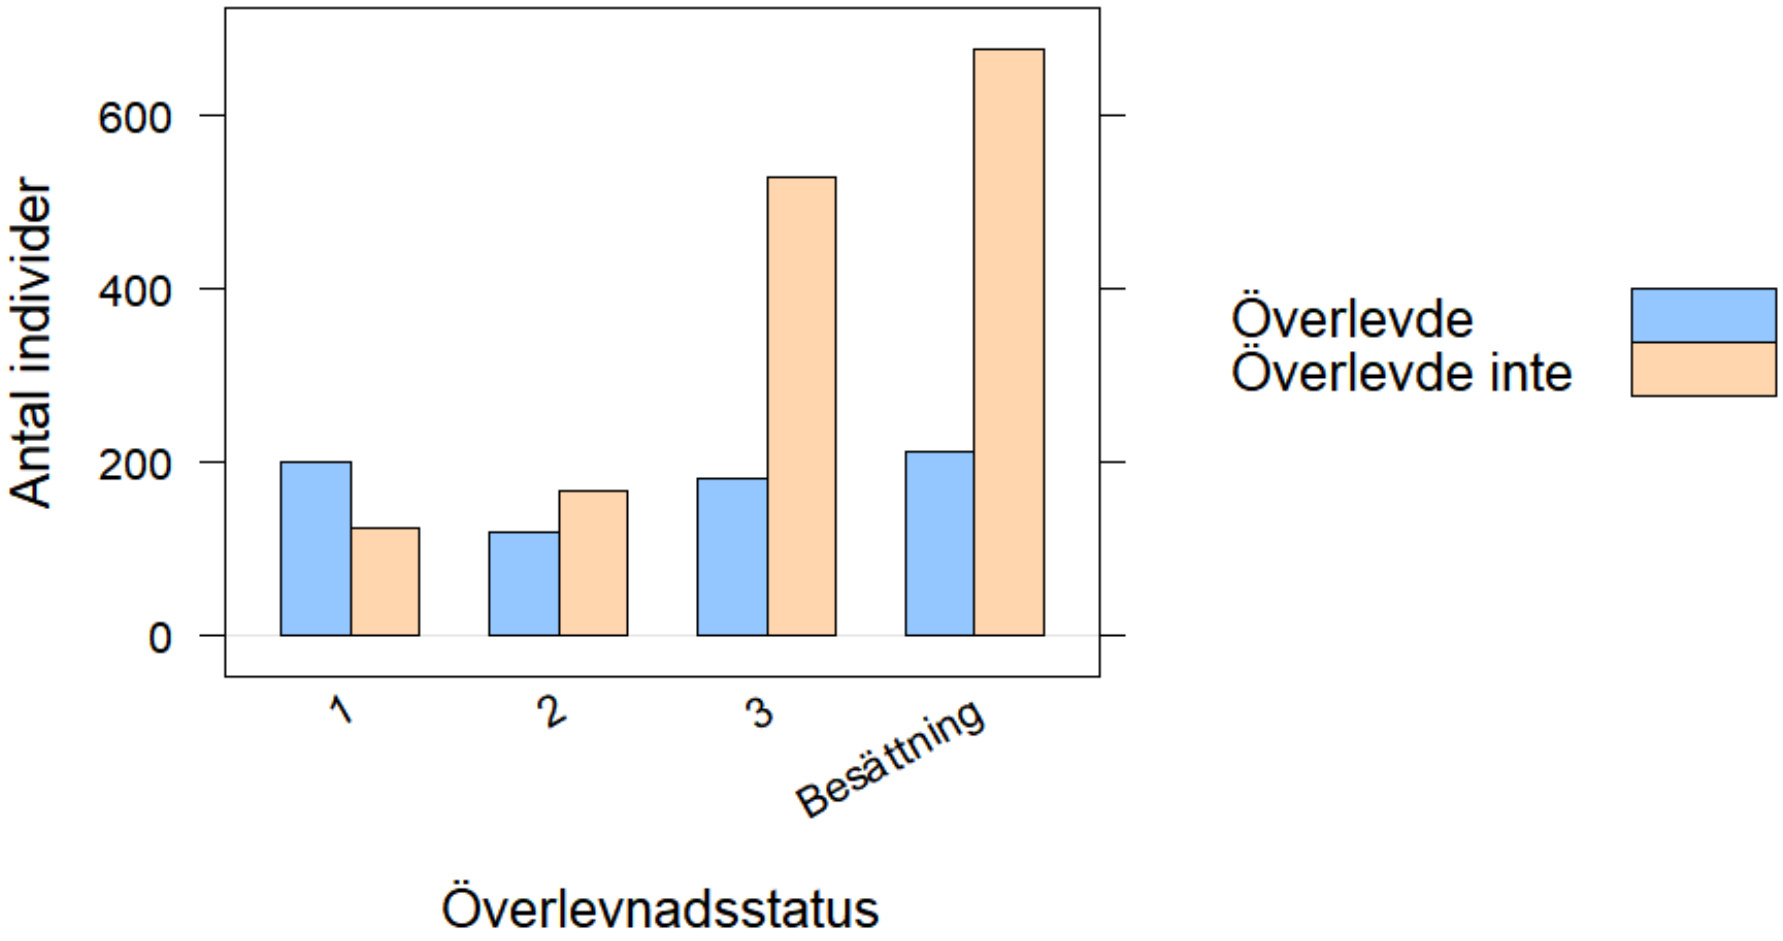

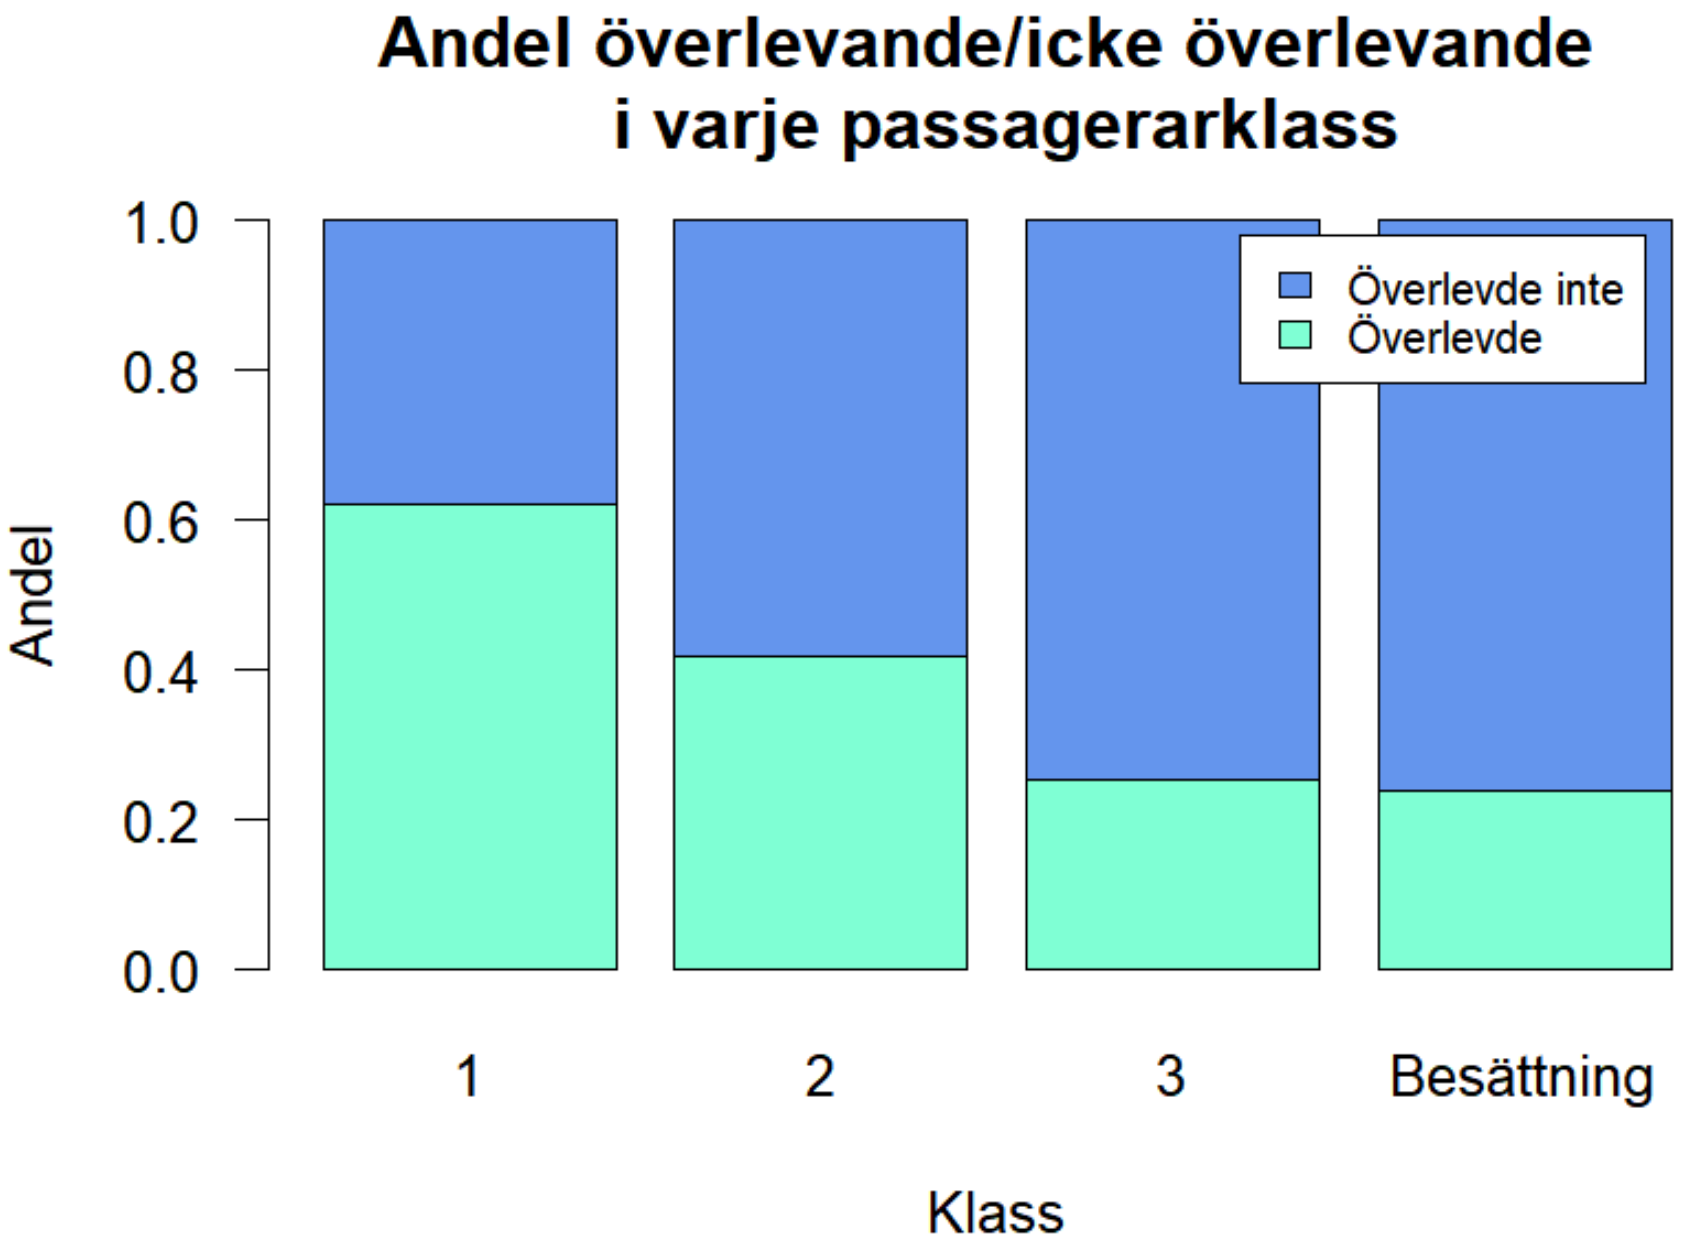
Andel överlevande/icke överlevande
i varje passagerarklass
1.0
0.8
0.6
0.4
0.2
0.0
Andel
Överlevde inte
Överlevde
1
2
3
Besättning
Klass

Numeriska variabler - histogram (histogram)

En numerisk variabel

- **Ex:** Titanic, biljettpris
- Skilj på histogram och stapeldiagram (som används för kategoriska variabler)
- I ett histogram kommer bredden på staplarna (hur många staplar vi har) spela roll för exakt vilken information vi får från figuren
- Mer om detta på datorlaborationerna

Fördelning av kostnaden för Titanicresan (för 1318 av 2208 passagerare)

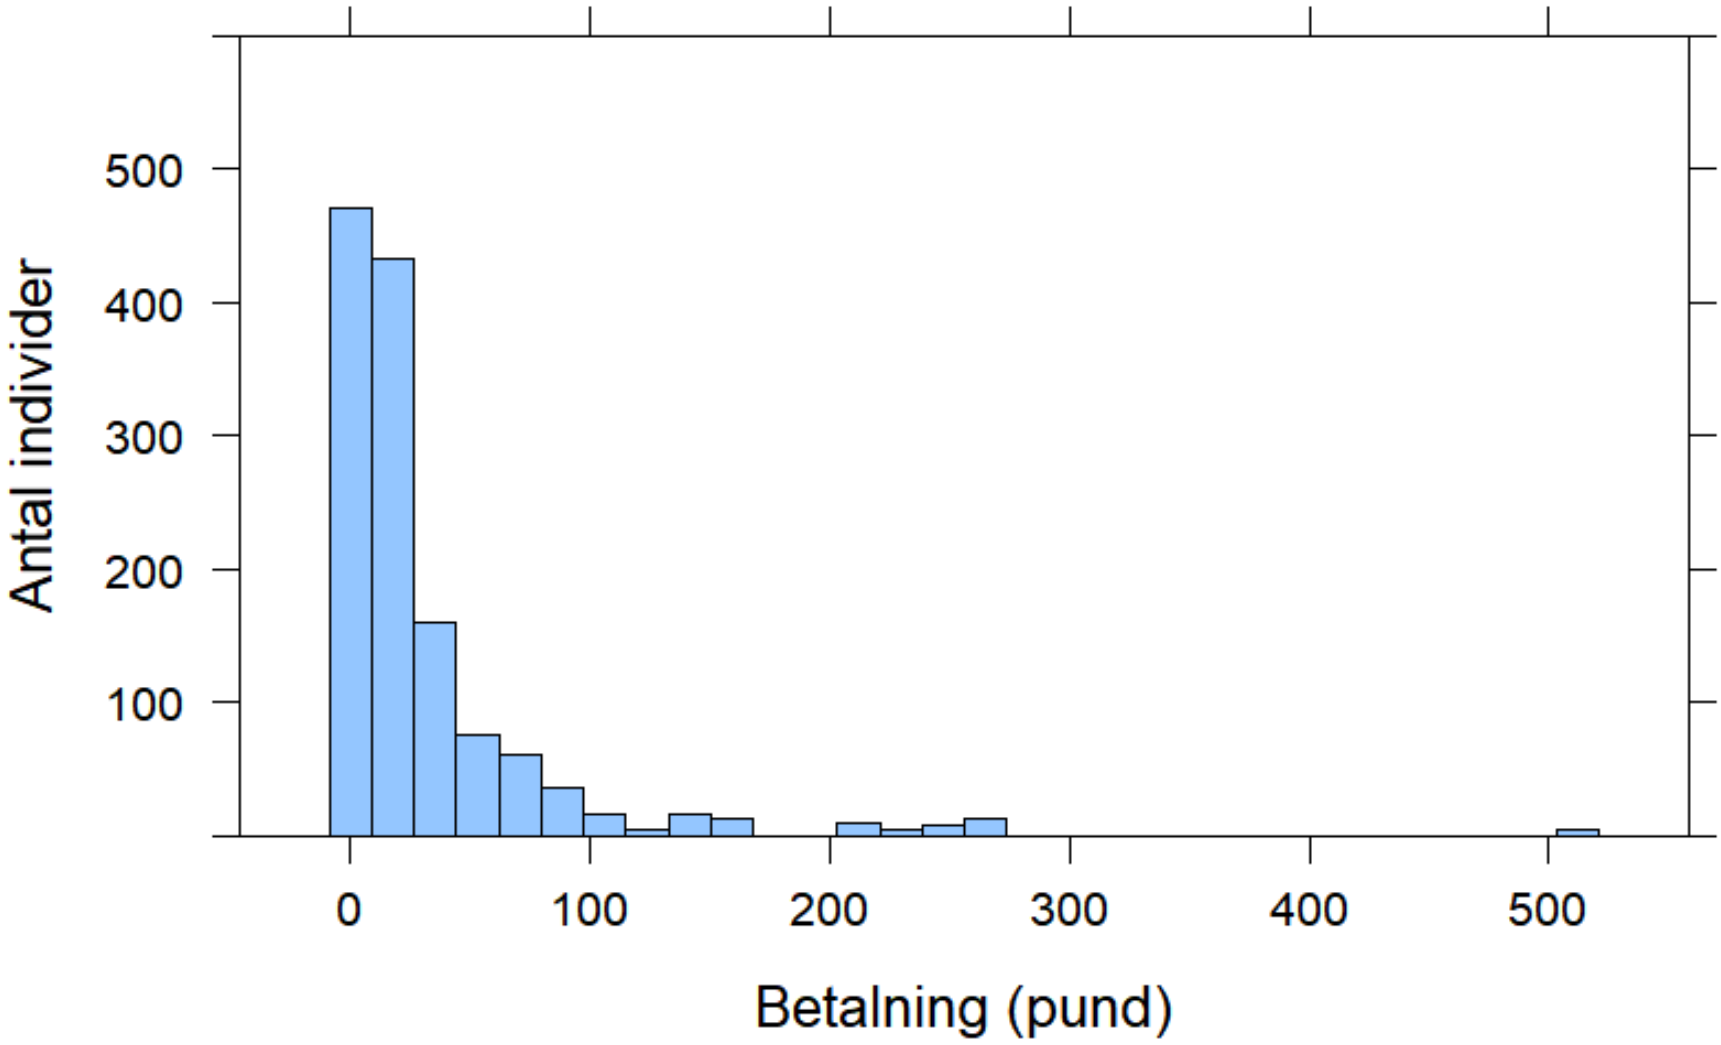

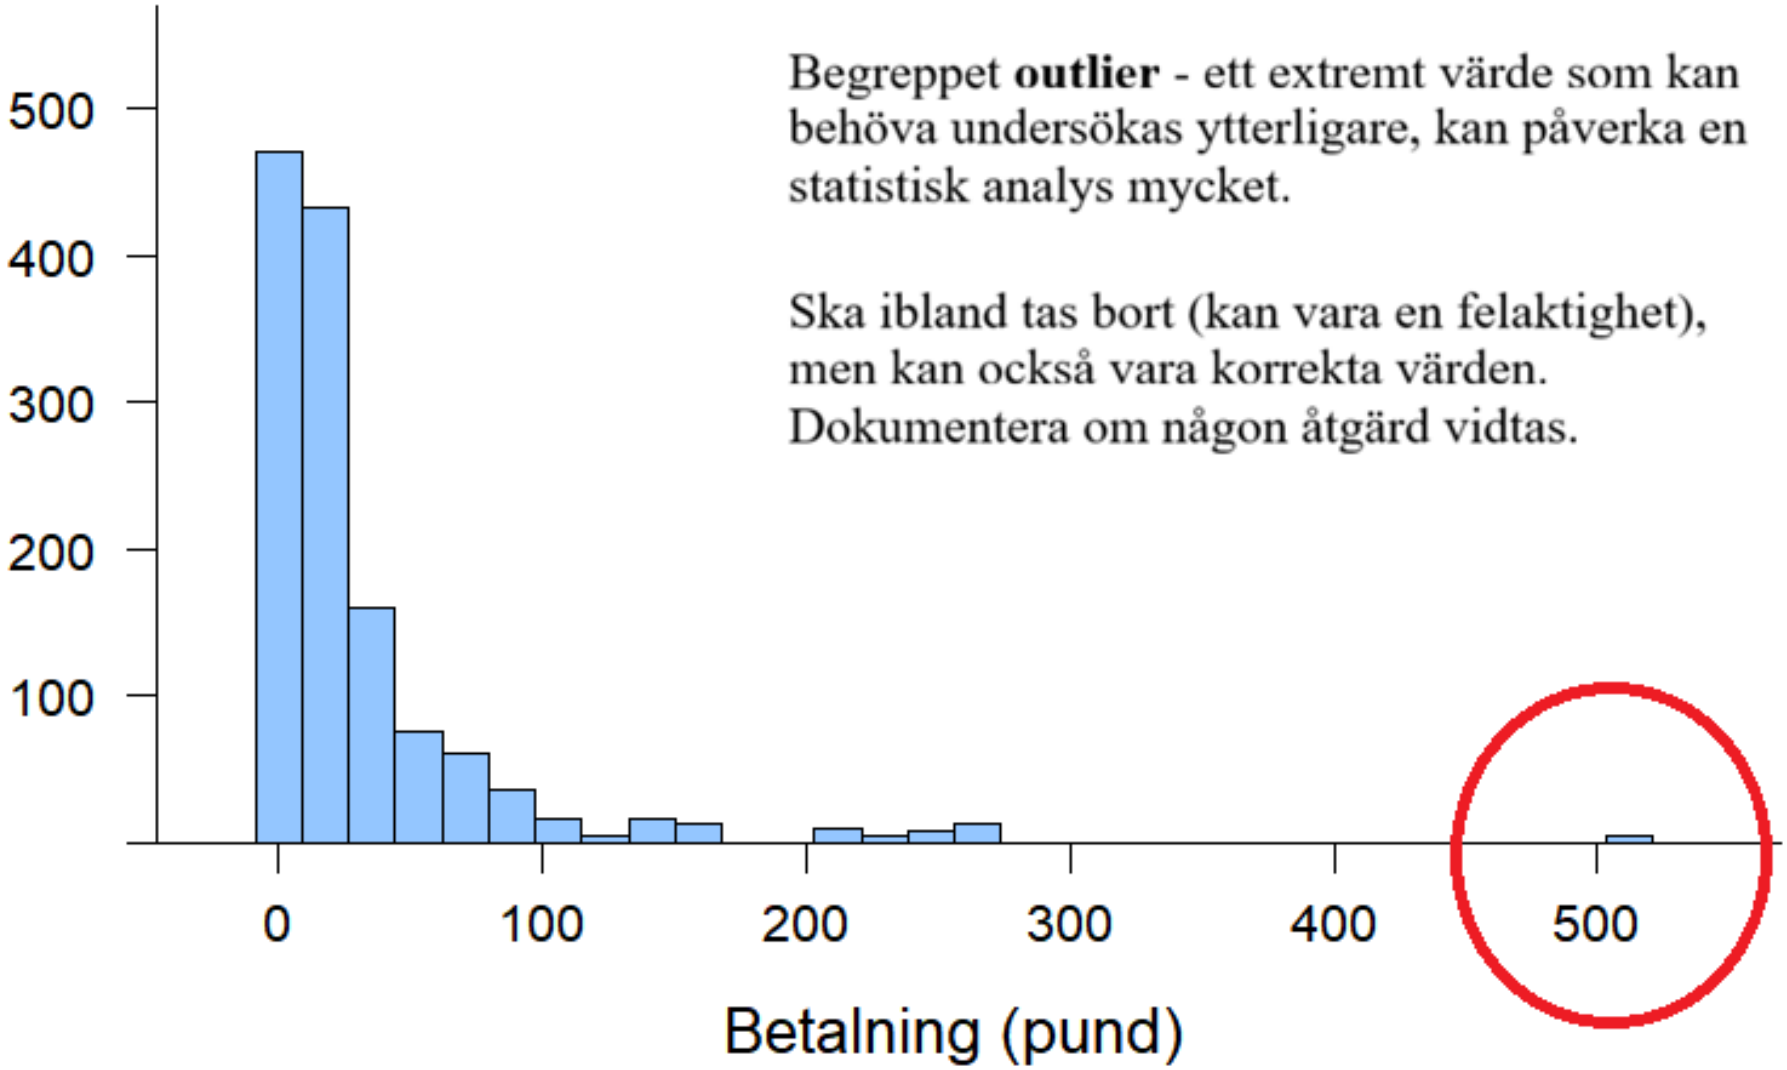

Begreppet **outlier** - ett extremt värde som kan behöva undersökas ytterligare, kan påverka en statistisk analys mycket.

Ska ibland tas bort (kan vara en felaktighet), men kan också vara korrekta värden. Dokumentera om någon åtgärd vidtas.

Fördelning av kostnaden för Titanicresan per klass (för 1318 av 2208 passagerare)

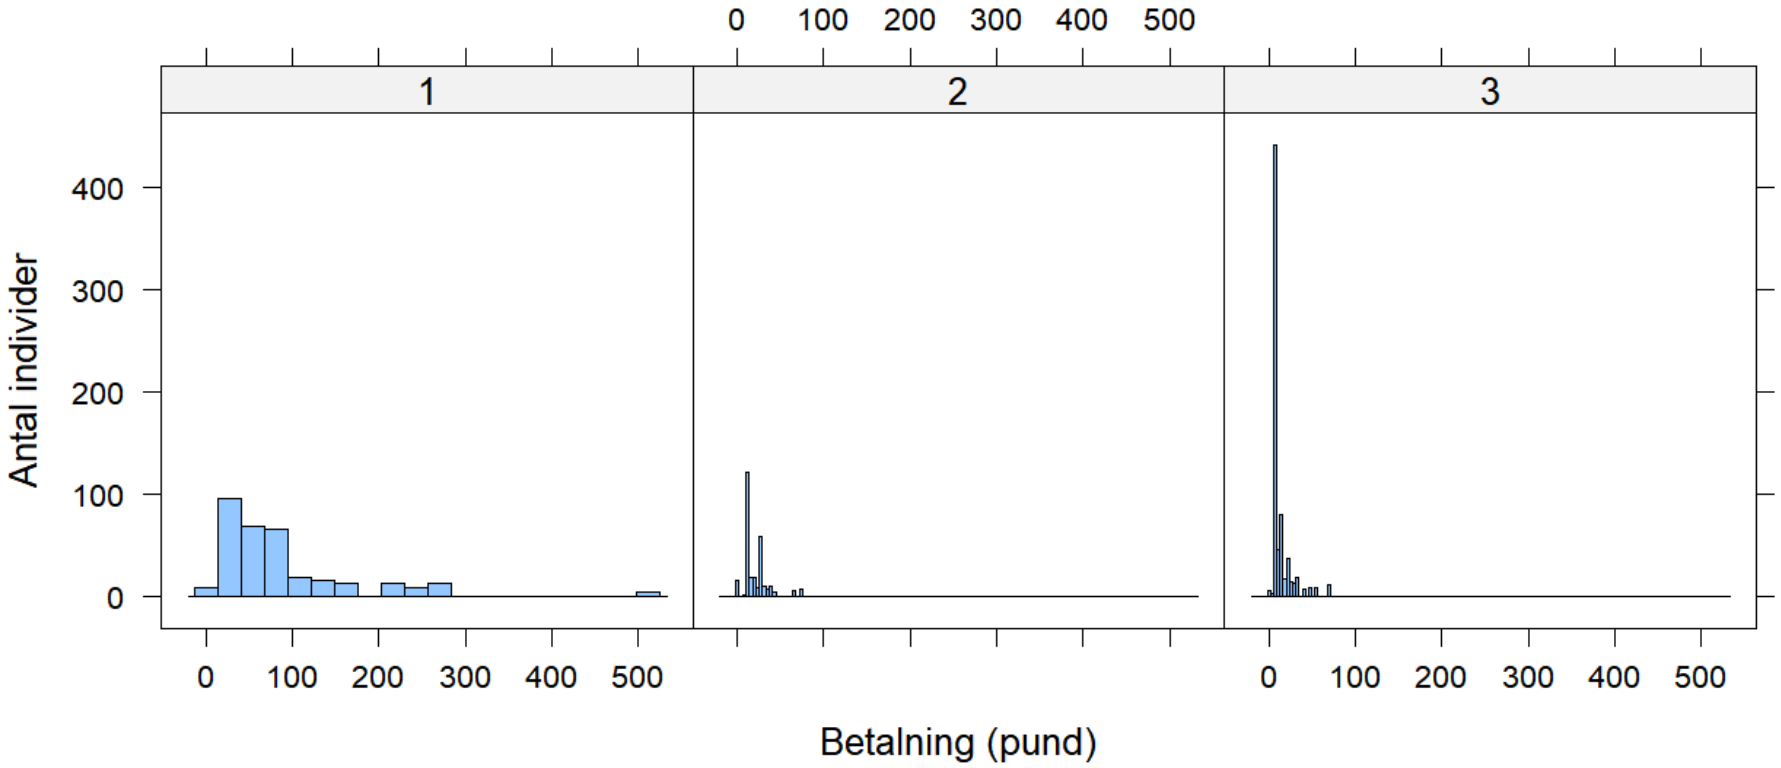

- I detta fall studerar vi fördelningen av en numerisk variabel (kostnad), betingat på en kategorisk variabel (klass)

Numeriska variabler - lådagram/låddiagram (boxplot)

En numerisk variabel

- **Ex:** Titanic, biljettpris
- Mer detaljer kommer på laboration 2

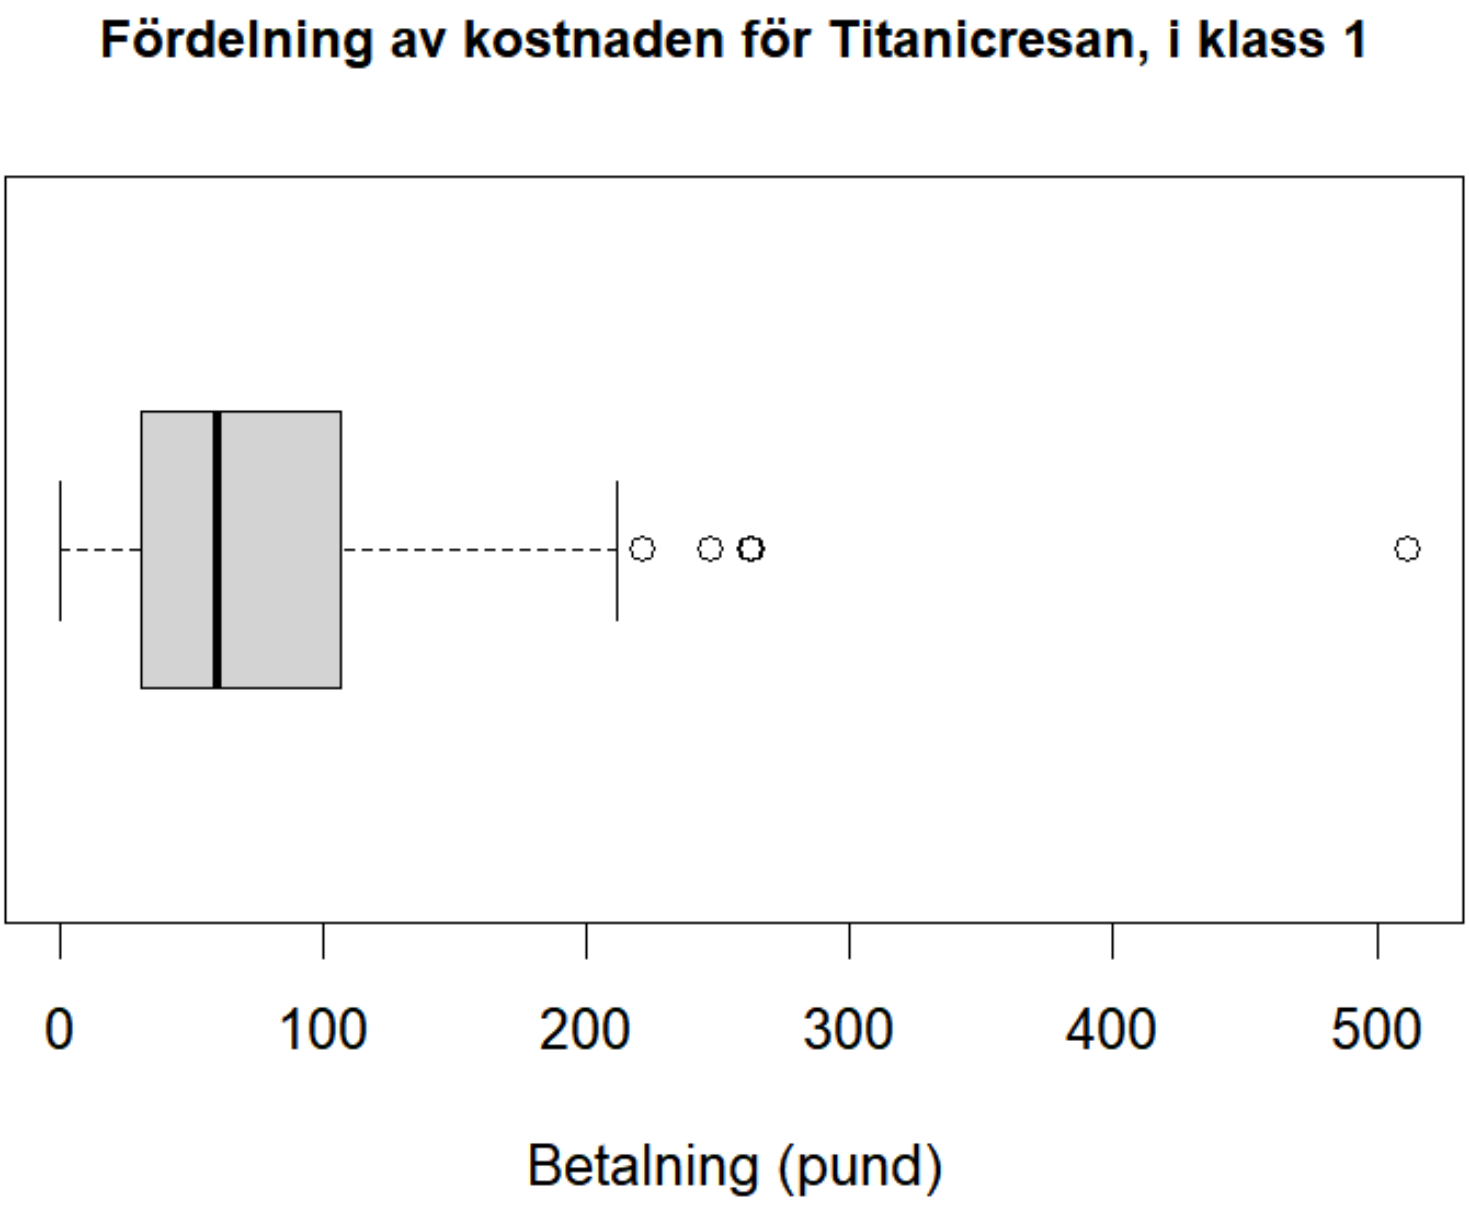
Fördelning av kostnaden för Titanicresan, i klass 1
0
100
200
300
400
500
Betalning (pund)

Numeriska variabler - spridningsdiagram (scatter plot)

Två numeriska variabler

- Exempel med påhittade data
- Exempel från The Economist
- Två exempel från boken
- Exempel från Gapminder (Hans Roslings presentationer)

- Färg, storlek, etc., kan användas för att åskådliggöra ytterligare variabler (typiskt kategoriska)

Exempel på spridningsdiagram - påhittade data

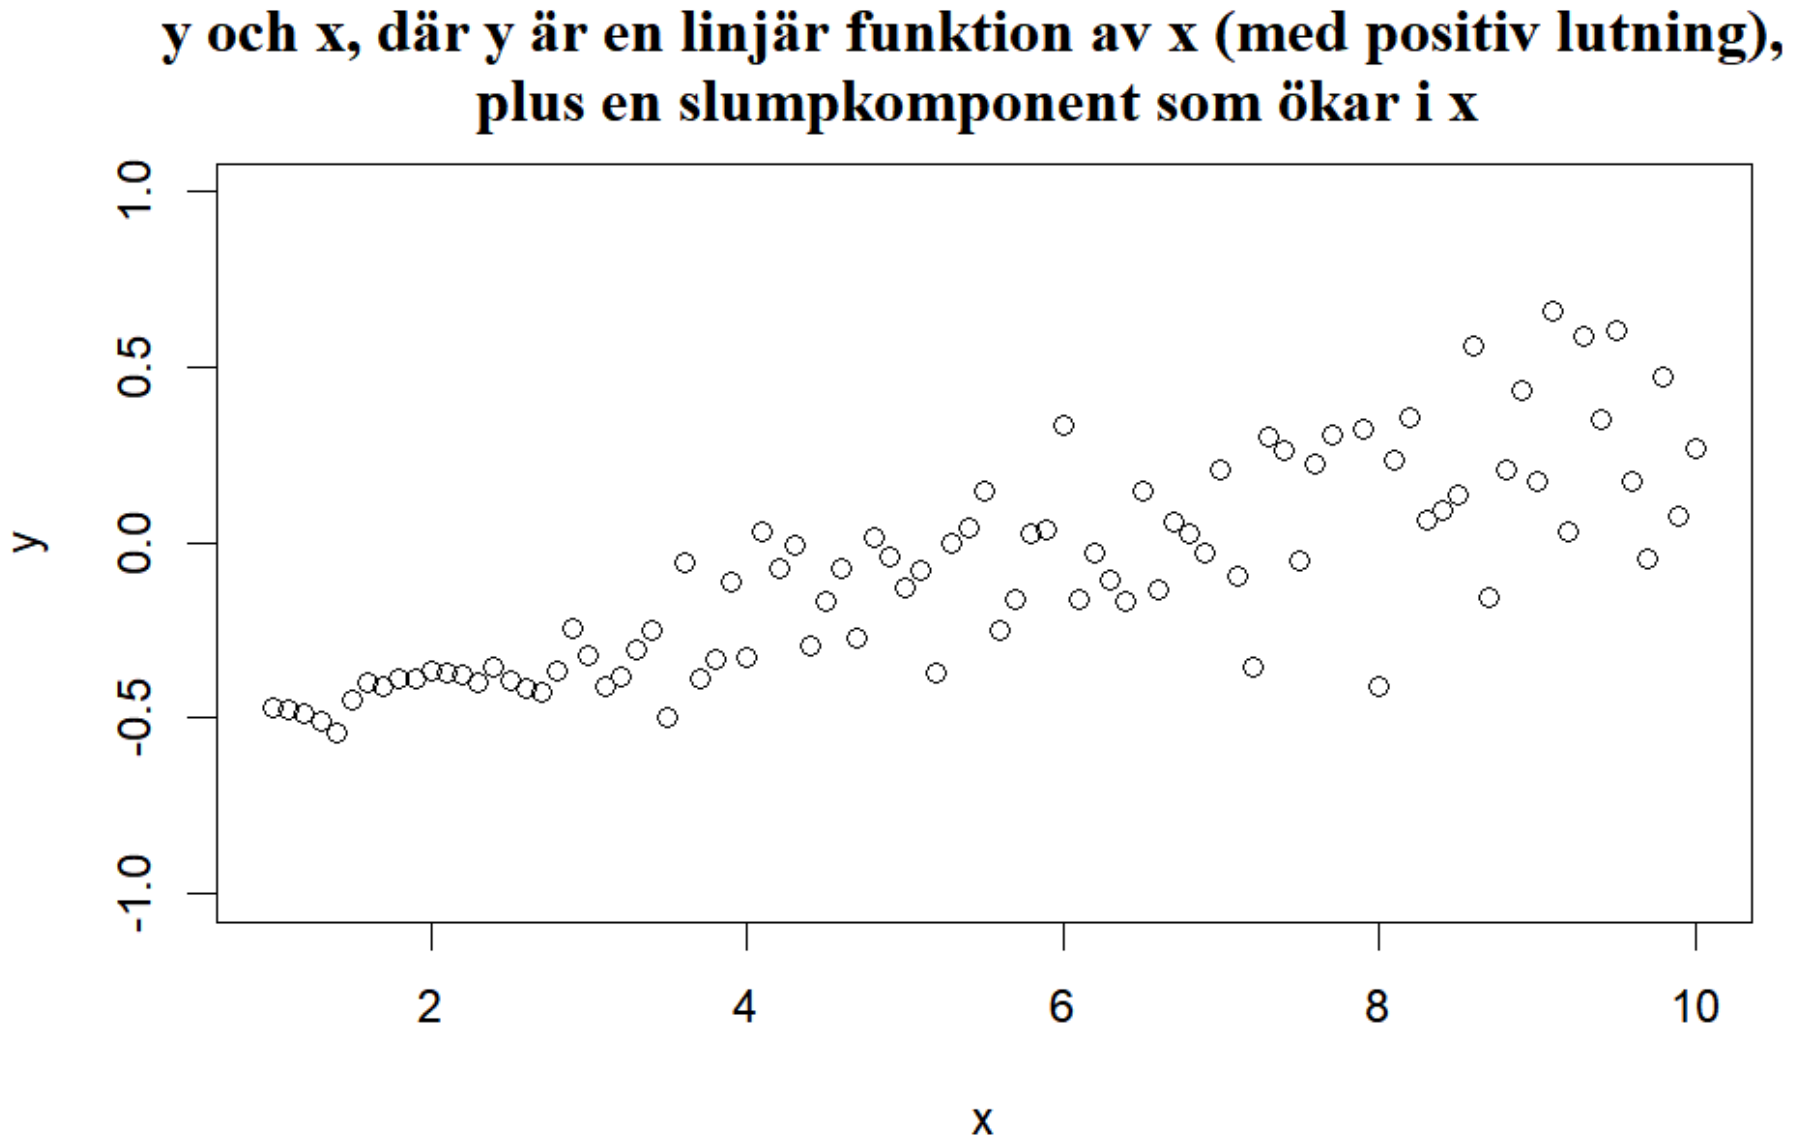

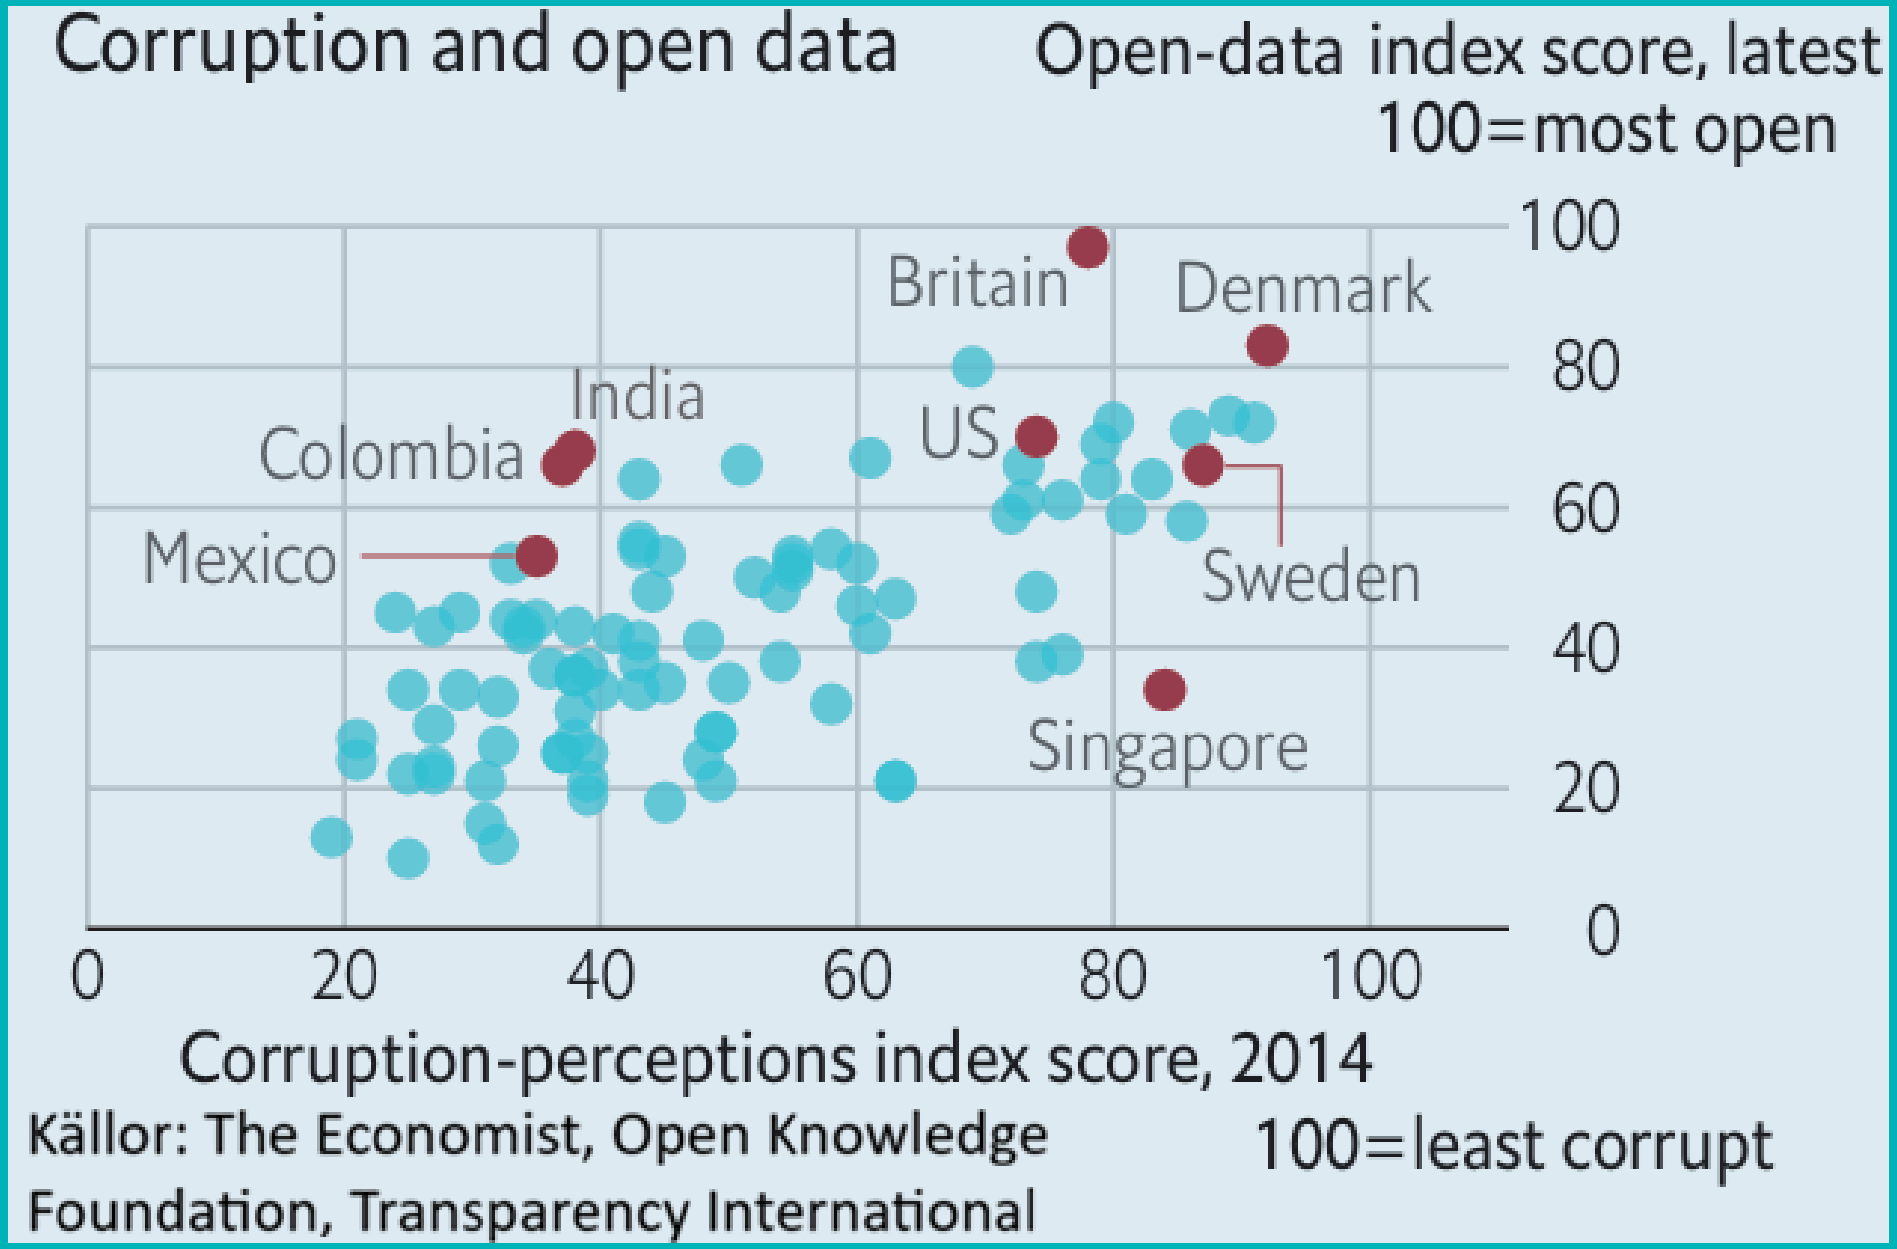
Corruption and open data
Open-data index score, latest
100=most open
Britain
Denmark
India
Colombia
US
Mexico
Sweden
Singapore
100
80
60
40
20
0
0
20
40
60
80
100
Corruption-perceptions index score, 2014
100=least corrupt
Källor: The Economist, Open Knowledge Foundation, Transparency International

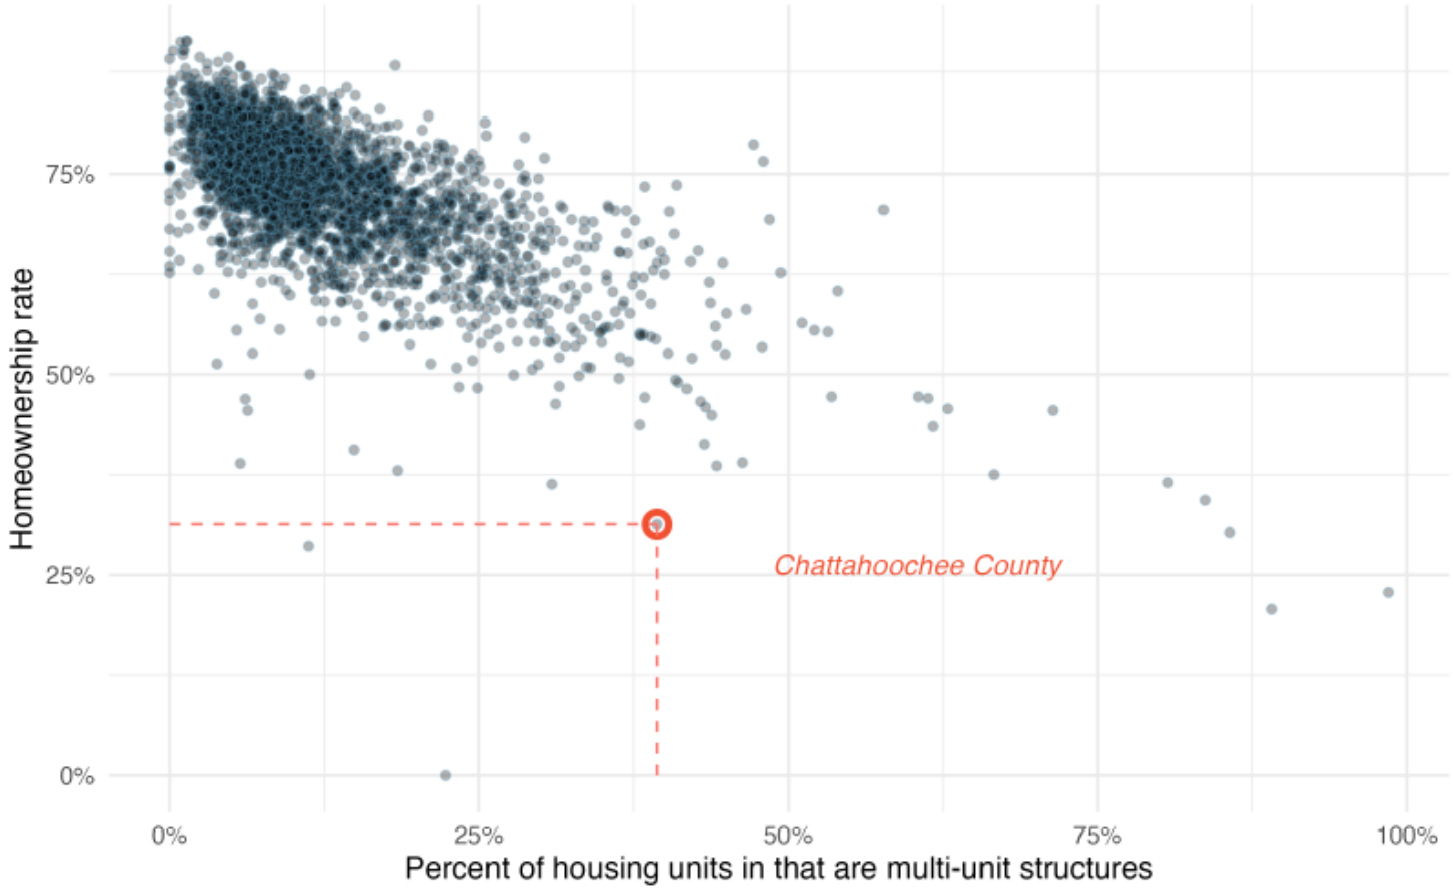

Figure 1.2: A scatterplot of homeownership versus the percent of housing units that are in multi-unit structures for US counties. The highlighted dot represents Chattahoochee County, Georgia, which has a multi-unit rate of 39.4% and a homeownership rate of 31.3%.

Figure 5.1: A scatterplot of loan amount versus total income for the `loan50` dataset.

BNP per capita och barnadödlighet (storlek på cirkel - (relativ) folkmängd)

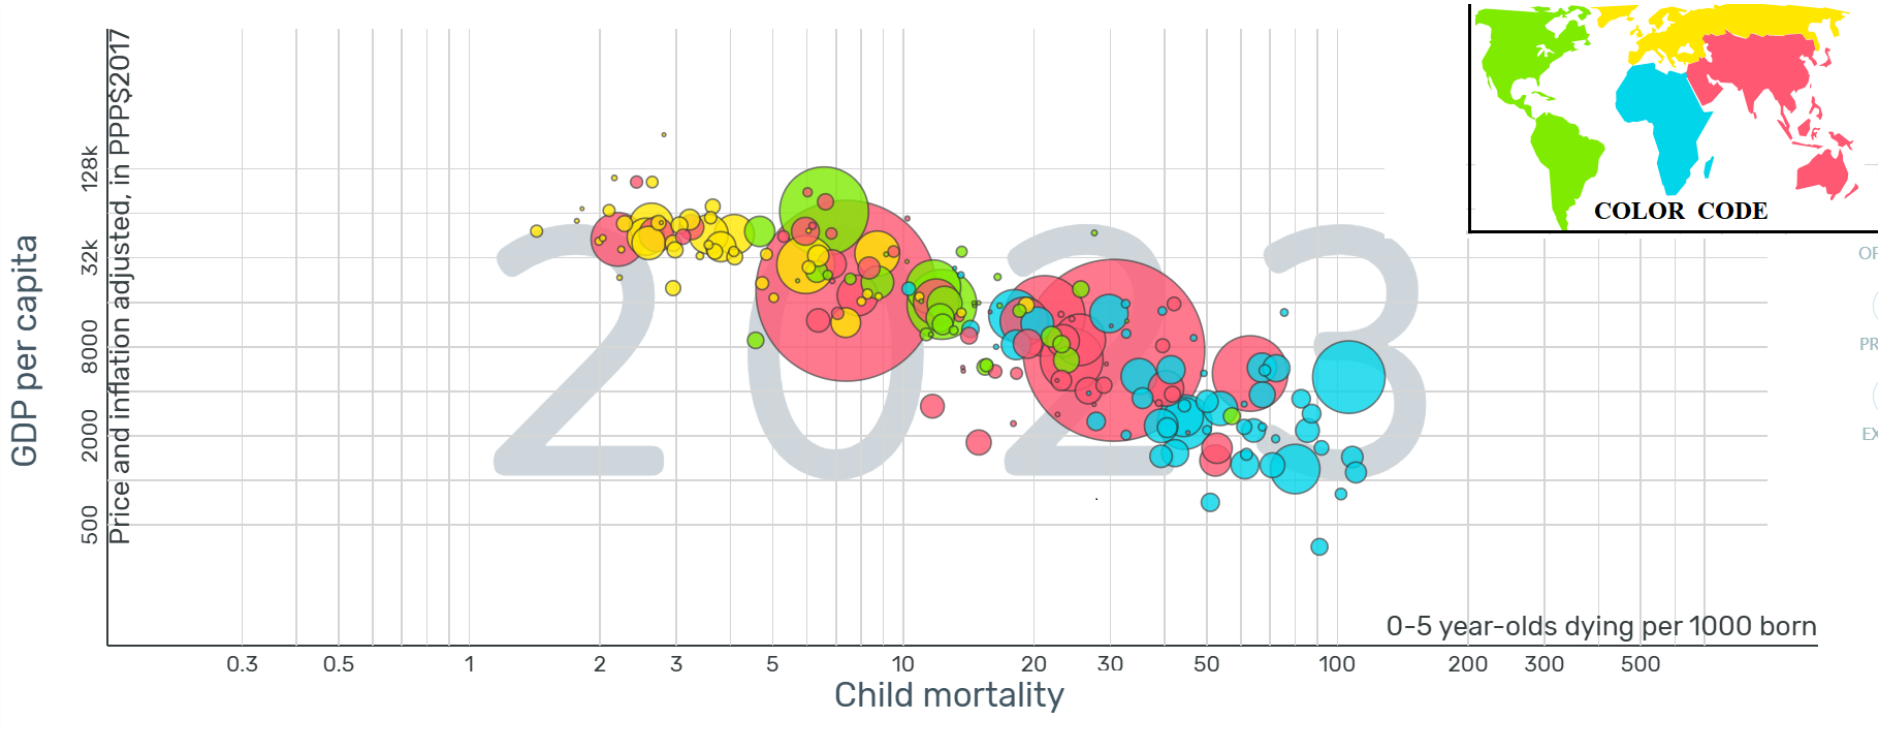

Källa: Gapminder

- Variabelparen i de olika spridningsdiagrammen ser ut att vara **relaterade** / **associerade** / **korrelerade**
- Mer om dessa begrepp på föreläsning 7

BNP per capita och barnadödlighet (storlek på cirkel - (relativ) folkmängd)

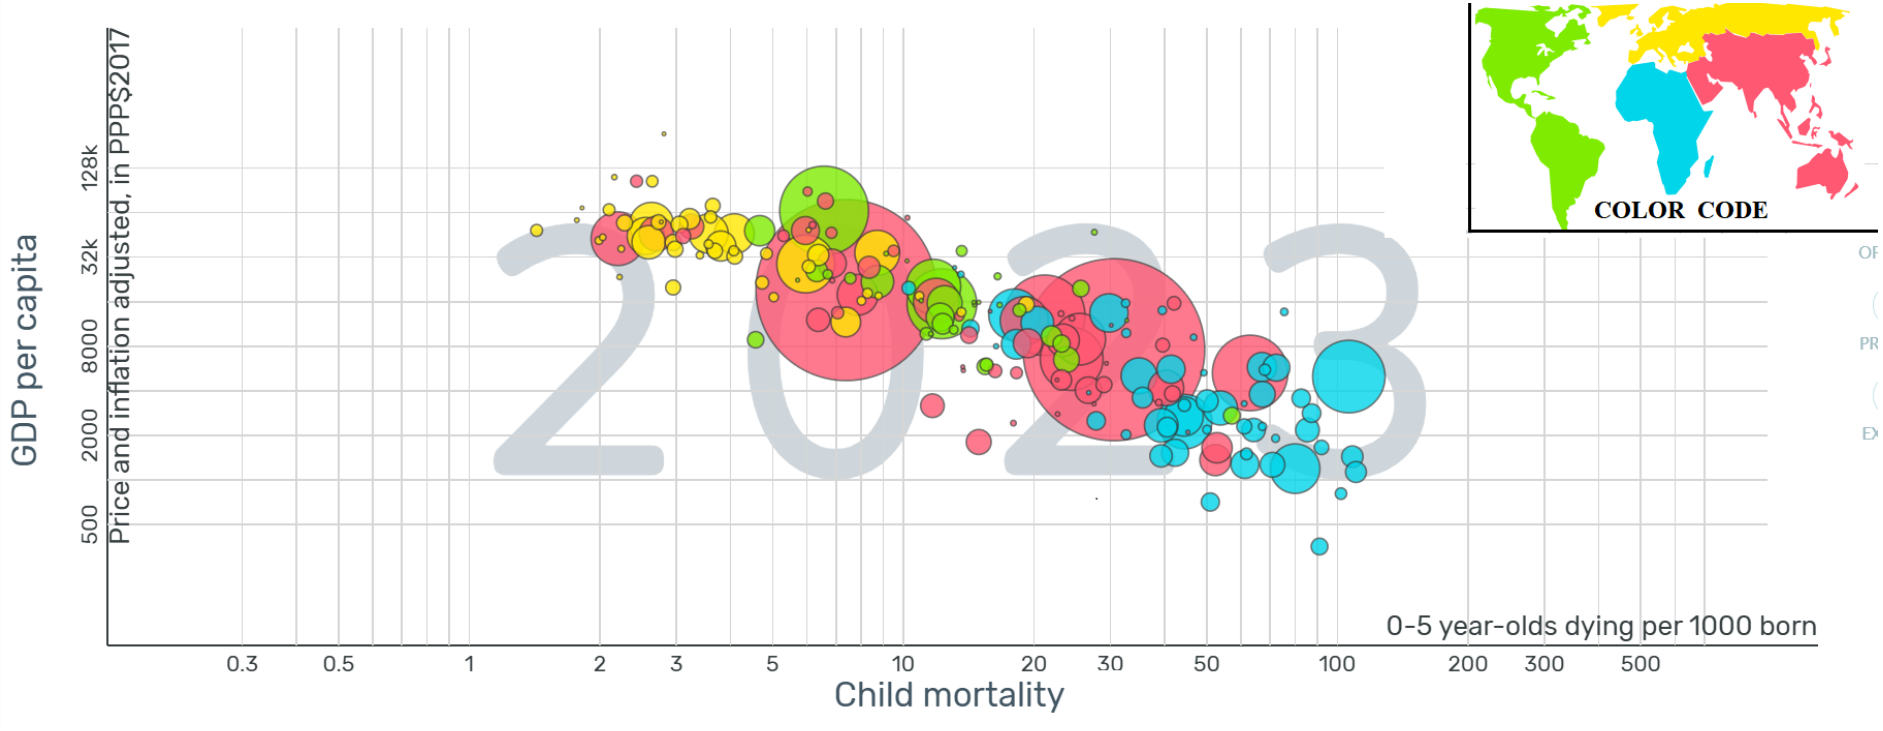

Källa: Gapminder

I denna graf är inte axlarna linjära - variablerna har **transformerats** (boken kap. 5.7). Vi återkommer till begreppet i regressionsdelen (F8-F10).

Numeriska data - tidsseriediagram (time series diagram)

En eller flera variabler som har en tidsdimension

- Exempel från Riksbanken

Styrräntan

Diagrammet visar styrräntan 2018–2024

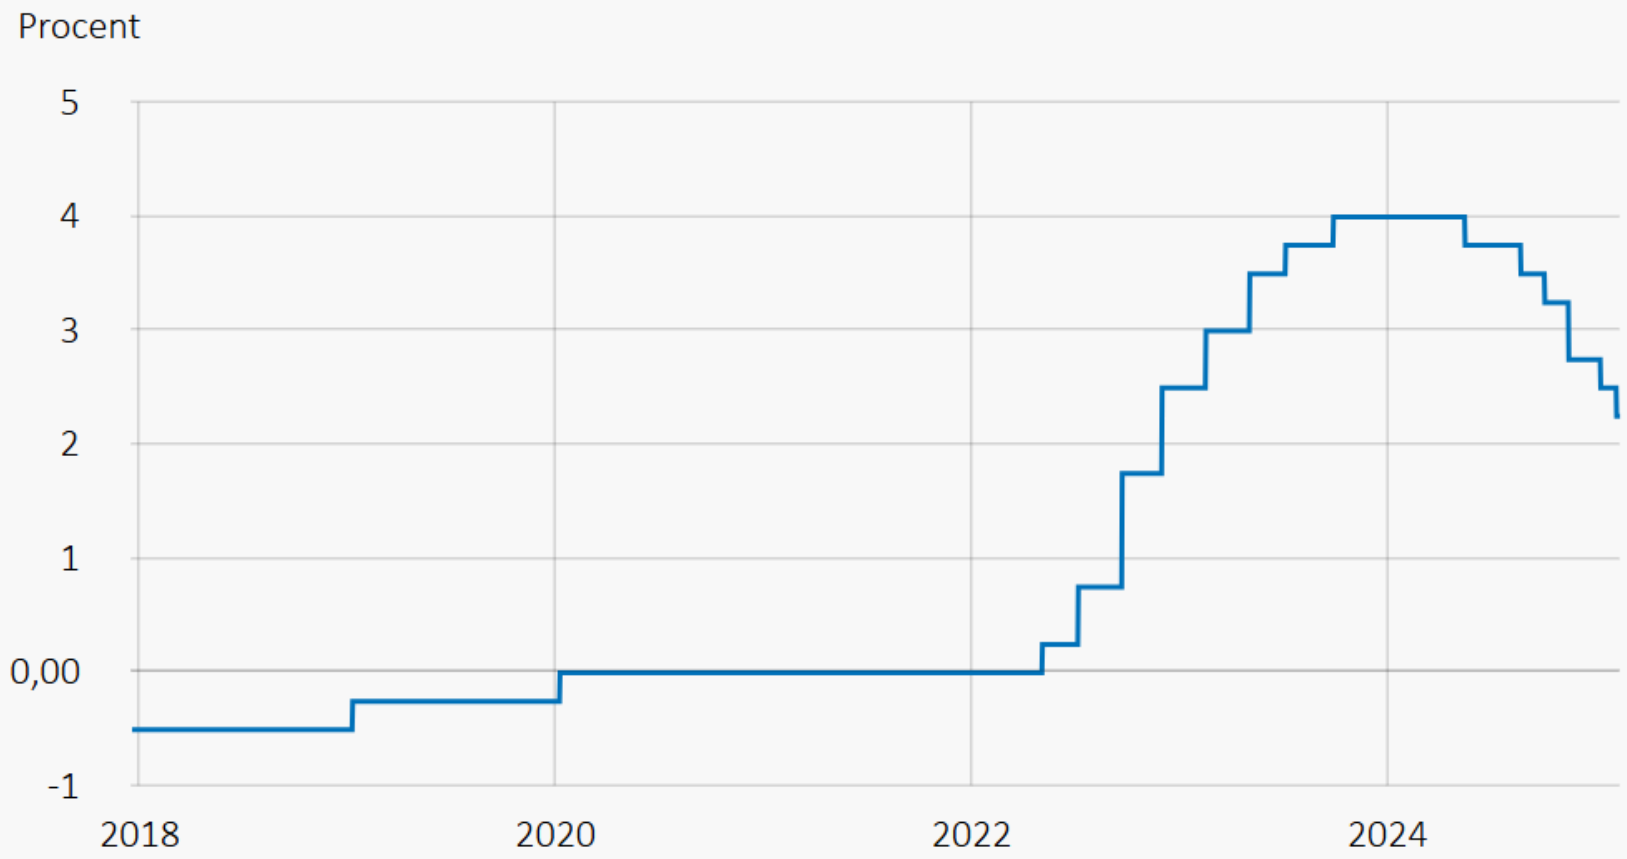

Källa Riksbanken.

När ni gör figurer

- I alla grafer - ange vad som finns på axlarna, inklusive enhet.
- Ha en informativ rubrik som kortfattat förklarar vad som visas.
- Ha lämpliga intervall på axlarna, som inte vilseleder läsaren.
- Följ areaprincipen.
- För akademiska artiklar - ha tabellrubrik ovanför tabellen och figurrubrik under figuren. I materialet här har vi alla rubriker ovanför.

Denna version av dokumentet: 2026-03-24

Materialet i Statistisk översiktskurs har tagits fram av Anders Fredriksson och Ulf Högnäs, med inspiration och ibland direkt användande av material från andra kurser och personer, bland annat kurserna Statistik och dataanalys 1-3, med material av Michael Carlson, Ellinor Fackle Fornius, Jessica Franzén, Oskar Gustafsson, Oscar Oelrich, Mona Sfaxi, Karl Sigfrid, Mattias Villani, Valentin Zulj, med flera.