Föreläsning 10

Statistisk översiktskurs

Anders Fredriksson

Statistiska Institutionen
Stockholms Universitet

9 april 2026

Exempel på när vi kan vilja använda flervariabelregression

- De flesta situationer där vi studerar ett samband (möjligtvis undantaget en del naturvetenskap och vissa experimentella studier - F4)
- Samband mellan utbildning och lön, vi behöver ta hänsyn till ("kontrollera för") exv. ålder/erfarenhet, etc.
- Träningsmängd & idrottsresultat, ta hänsyn till exv. ålder och kön
- Samband mellan gödsling & skörd, exv. väder, jordmån påverkar
- Samband mellan en kolonialmakts ursprungliga institutioner, i kolonin, och utveckling idag - exv. andra historiska händelser, grannländers ekonomi, klimat (?) påverkar
- Rökning & hälsa, terapi & mående, tullsats & handelsvolym, tid på dygnet & trafikmängd etc... - flera faktorer påverkar

Föreläsning 10 - innehåll

- Något om indikatorvariabler ("dummyvariabler")
- Vi går från en till två till flera X-variabler
- Som tidigare: populationssamband, skattas med data från urval
- Vad förändras?
  - Tolkning av regressionskoefficienter (begreppet **"allt annat lika"**)
  - **Multikollinearitet**
  - **R2-måttet ökar för varje ny variabel** - åtgärd behövs
- Prediktion, Inferens (hypotestest och konfidensintervall gällande en lutningskoefficient) - liknar enkel linjär regression
- Modellantaganden för linjär regression generellt
- Variabeltransformation

Indikatorvariabler / Dummyvariabler (kap 8.1)

- Representerar kategorier
- Kan vara binära (dikotoma) (0/1) (exv. variabeln landlocked i inlämningsuppgift, del 4, där "1" representerar "utan kust")
- Kan också ha fler kategorier, exv. **grön/gul/röd**
- En kategorisk variabel med **tre** kategorier görs om till **två** dummyvaribler, exv. variabeln **grön** (1 om grön, 0 annars) och **gul** (1 om gul, 0 annars)
- Den utelämnade kategorin **röd** representeras då när både gul och grön är noll
- Motsvarande för än fler kategorier

Från F9: Enkel linjär regression - populationen (1 variabel)

- Vi vill förstå hur ett samband ser ut i populationen
- **Ex:** Samband mellan lägenhetsstorlek (X) och hyresnivå (Y) i Uppsala
- **Population** - alla lägenheter i Uppsala
- Sambandet i populationen modelleras som
  $Y = \beta_0 + \beta_1 X + \varepsilon$
- Grekiska bokstäver används typiskt för populationssamband (F4)
- När vi skattat ett samband, baserat på ett urval, använder vi typiskt vanliga (latinska) bokstäver (F4)

Multipel linjär regression - populationen (2 variabler)

- Vi vill förstå hur ett samband ser ut i populationen
- Vi lägger till en förklaringsvariabel
- Kalla variablerna X_1, X_2
- **Ex:** Samband mellan lägenhetshyra (Y), storlek (X_1) och antal rum (X_2) i Uppsala
- **Population** - alla lägenheter i Uppsala

Multipel linjär regression - populationen (2 variabler)

- Sambandet i populationen modelleras som
  $Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \varepsilon$
- **I ord, för exemplet:**

  Hyran är lika med **interceptet** (β_0) +
  koefficienten för storlek gånger storlek $(\beta_1 X_1)$ +
  koefficienten för antal rum gånger antal rum $(\beta_2 X_2)$ +
  felterm (ε)
- Eftersom vi nu har fler än en X-dimension kan vi inte lika lätt visualisera sambandet i en graf
- Liksom tidigare har vi typiskt sett inte data på hela populationen och kan därför inte observera **populationssambandet**.

Multipel linjär regression - urvalet (2 variabler)

- Sambandet i urvalet skattas som

  $Y = b_0 + b_1 X_1 + b_2 X_2 + e$

- **I ord, för exemplet:**

  Hyran skattas vara lika med **interceptet** $(\mathbf{b_0})$ +
  koefficienten för storlek gånger storlek $(\mathbf{b_1} X_1)$ +
  koefficienten för antal rum gånger antal rum $(\mathbf{b_2} X_2)$ +
  skattningsfel $(\mathbf{e})$

- Koefficienterna är nu **skattningar** baserade på ett urval
- Sambandet är vår bästa skattning av populationssambandet
- Skattningsfel = Residual

Multipel linjär regression - populationen (3 variabler, osv..)

- Vi vill förstå hur ett samband ser ut i populationen
- Vi lägger till ytterligare en förklaringsvariabel
- Kalla variablerna X_1, X_2, X_3
- **Ex:** Samband mellan lägenhetshyra (Y), storlek (X_1), antal rum (X_2) och avstånd till city (X_3) i Uppsala
- **Population** - alla lägenheter i Uppsala

Multipel linjär regression - populationen (3 variabler)

- Sambandet i populationen modelleras som
  $Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \varepsilon$
- **I ord, för exemplet:**

  Hyran är lika med **interceptet** (β_0) +
  koefficienten för storlek gånger storlek $(\beta_1 X_1)$ +
  koefficienten för antal rum gånger antal rum $(\beta_2 X_2)$ +
  koefficienten för avstånd gånger avstånd $(\beta_3 X_3)$ +
  felterm (ε)
- Eftersom vi nu har fler än en X-dimension kan vi inte lika lätt visualisera sambandet i en graf
- Liksom tidigare har vi typiskt sett inte data på hela populationen och kan därför inte observera **populationssambandet**.

Multipel linjär regression - urvalet (3 variabler)

- Sambandet i urvalet skattas som

  $Y = b_0 + b_1 X_1 + b_2 X_2 + b_3 X_3 + e$

- **I ord, för exemplet:**

  Hyran skattas vara lika med **interceptet** $(\mathbf{b_0})$ +
  koefficienten för storlek gånger storlek $(\mathbf{b_1} X_1)$ +
  koefficienten för antal rum gånger antal rum $(\mathbf{b_2} X_2)$ +
  koefficienten för avstånd gånger avstånd $(\mathbf{b_3} X_3)$ +
  skattningsfel (e)

- Koefficienterna är nu **skattningar** baserade på ett urval
- Sambandet är vår bästa skattning av populationssambandet

Multipel linjär regression - intuition och tolkning

- Flera variabler X_i påverkar utfallsvariabeln (Y)
- Regressionskoefficienten (β_i) representerar den **marginella effekten** av X_i på Y (effekten givet övriga variabler)
- En geometrisk tolkning går teoretiskt att göra men utelämnas här
- Tolkning av regressionskoefficienterna kräver att andra variabler hålls konstanta (**"allt annat lika" - *ceteris paribus***)

Exempel kap 8 - ”vad förklarar räntan”? variabler

Table 8.2: Variables and their descriptions for the `loans` dataset.

Variable	Description
`interest_rate`	Interest rate on the loan, in an annual percentage.
`verified_income`	Categorical variable describing whether the borrower's income source and amount have been verified, with levels Verified (source and amount verified), Source Verified (source only verified), and Not Verified.
`debt_to_income`	Debt-to-income ratio, which is the percentage of total debt of the borrower divided by their total income.
`credit_util`	Of all the credit available to the borrower, what fraction are they utilizing. For example, the credit utilization on a credit card would be the card's balance divided by the card's credit limit.
`bankruptcy`	An indicator variable for whether the borrower has a past bankruptcy in their record. This variable takes a value of ‘1‘ if the answer is *yes* and ‘0‘ if the answer is *no*.
`term`	The length of the loan, in months.
`issue_month`	The month and year the loan was issued, which for these loans is always during the first quarter of 2018.
`credit_checks`	Number of credit checks in the last 12 months. For example, when filing an application for a credit card, it is common for the company receiving the application to run a credit check.

Exempel kap 8 - skattad regressionsekvation

We want to construct a model that accounts not only for any past bankruptcy or whether the borrower had their income source or amount verified, but simultaneously accounts for all the variables in the `loans` dataset: `verified_income`, `debt_to_income`, `credit_util`, `bankruptcy`, `term`, `issue_month`, and `credit_checks`.

$$
\begin{aligned}
\widehat{\texttt{interest_rate}} = b_0 & \\
& + b_1 \times \texttt{verified_income}_{\texttt{Source Verified}} + b_2 \times \texttt{verified_income}_{\texttt{Verified}} \\
& + b_3 \times \texttt{debt_to_income} + b_4 \times \texttt{credit_util} \\
& + b_5 \times \texttt{bankruptcy} + b_6 \times \texttt{term} \\
& + b_7 \times \texttt{credit_checks} + b_8 \times \texttt{issue_month}_{\texttt{Jan-2018}} \\
& + b_9 \times \texttt{issue_month}_{\texttt{Mar-2018}}
\end{aligned}
$$

Exempel kap 8 - typisk regressionstabell från mjukvara

Table 8.6: Output for the regression model, where interest rate is the outcome and the variables listed are the predictors. Degrees of freedom for this model is 9990.

term	estimate	std.error	statistic	p.value
(Intercept)	1.89	0.21	9.01	<0.0001
verified_incomeSource Verified	1.00	0.10	10.06	<0.0001
verified_incomeVerified	2.56	0.12	21.87	<0.0001
debt_to_income	0.02	0.00	7.43	<0.0001
credit_util	4.90	0.16	30.25	<0.0001
bankruptcy1	0.39	0.13	2.96	0.0031
term	0.15	0.00	38.89	<0.0001
credit_checks	0.23	0.02	12.52	<0.0001
issue_monthJan-2018	0.05	0.11	0.42	0.6736
issue_monthMar-2018	-0.04	0.11	-0.39	0.696

Exempel kap 8 - insatta värden och tolkningsexempel

The fitted model for the interest rate is given by:

$$
\begin{aligned}
\widehat{\texttt{interest_rate}} = 1.89 & \\
& + 1.00 \times \texttt{verified_income}_{\texttt{Source Verified}} + 2.56 \times \texttt{verified_income}_{\texttt{Verified}} \\
& + 0.02 \times \texttt{debt_to_income} + 4.90 \times \texttt{credit_util} \\
& + 0.39 \times \texttt{bankruptcy} + 0.15 \times \texttt{term} \\
& + 0.23 \times \texttt{credit_checks} + 0.05 \times \texttt{issue_month}_{\texttt{Jan-2018}} \\
& - 0.04 \times \texttt{issue_month}_{\texttt{Mar-2018}}
\end{aligned}
$$

GUIDED PRACTICE

Interpret the coefficient of the variable `credit_checks`.[4]

[4] All else held constant, for each additional inquiry into the applicant's credit during the last 12 months, we would expect the interest rate for the loan to be higher, on average, by 0.23 points.

"Allt annat lika, skattas en (1) extra kreditkoll under det senaste året, vara associerad med 0.23 procentenheter högre ränta."

Exempel kap 8 - ytterligare tolkningsexempel

- Vad betyder det att koefficienten för `bankruptcy` är 0.39?
- **Vi kan tänka som följer:**
  - Jämför två hypotetiska individer, Madison och Harper
  - Madison har aldrig gått igenom en konkurs
  - Harper har gått igenom (minst) en konkurs
  - Övriga variabler är lika för båda (**ceteris paribus**)
- Den skattade räntan är då 0.39 procentenheter högre för Harper än för Madison

Multikollinearitet

- Uppstår när förklaringsvariablerna (X-variablerna) är (starkt) korrelerade
- Då blir det svårt att **skilja på variablernas effekter**
- Regressionskoefficienterna kan bli **instabila och svårtolkade**
- **Ex:** Studera huspris beroende av yta, antal rum, garage eller inte, etc.
  - Är det husyta eller antal rum som påverkar huspris?
  - Variablerna rör sig tillsammans
  - Modellen har svårt att avgöra deras separata bidrag
  - Liknar Uppsalaexemplet, när vi la till variabeln antal rum
- Typiskt eftersträvar vi X-variabler som förklarar olika delar av variationen i Y, men som inte är sinsemellan relaterade
- Lättare att uppnå i experiment än i observationsstudier

Förklaringsgrad och justerad R2

- R2 mäter hur stor andel av variationen i Y som modellen förklarar
- Problem: R2 **ökar alltid (eller är oförändrad)** med nya variabler i modellen
- Även irrelevanta variabler kan få modellen att "se bättre ut"
- Därför kan R2 vara **missvisande**
- Lösning: **justerad R2** (adjusted R2)
  - Tar hänsyn till antalet variabler i modellen
  - Straffar onödigt komplexa modeller
  - Kan minska när irrelevanta variabler läggs till
- Läs kap 8.3 (vid intresse, för fördjupning)

Gällande inferens - håll reda på (från kap 25.1)

In Chapter 24, you learned that the hypothesis test for a linear model with **one predictor**[1] can be written as:

if only one predictor, $H_0 : \beta_1 = 0$.

That is, if the true population slope is zero, the p-value measures how likely it would be to select data which produced the observed slope (b_1) value.

With **multiple predictors**, the hypothesis is similar, however, it is now conditioned on each of the other variables remaining in the model.

if multiple predictors, $H_0 : \beta_i = 0$ given other variables in the model

Kort om regressionsmodellens antaganden

- Regression bygger på några grundläggande antaganden som bör vara uppfyllda
- Om antagandena bryts kan prediktioner och inferens bli missvisande
- **Viktiga antaganden för linjär regression**
  - **Linjära samband:** Varje förklarande variabel har ett linjärt samband med responsvariabeln
  - **Oberoende observationer:** Observationerna påverkar inte varandra
  - **Ingen multikollinearitet:** De förklarande variablerna är inte starkt korrelerade
  - **Homoskedasticitet:** Residualernas varians är konstant
  - **Normalfördelade residualer:** Residualerna följer ungefär en normalfördelning
- Gå till F9, s 15, mittengraferna, här såg vi ett exempel på när linearitet inte är uppfyllt. Analys därutöver - andra statistikkurser.

Något om variabeltransformation

- Om regressionsantaganden inte är uppfyllda kan vi inte lita på resultat
- Prediktioner och inferens kan bli **missvisande**
- En möjlig lösning är att **transformera** variabler
- En vanlig transformation är att ta logaritmen av responsvariabeln (och ev. också X-variabler)
- **Arbetsgång (mer detaljer i andra kurser)**
  - Gör ett spridningsdiagram och upptäck problem (plotta!)
  - Transformera Y, med (exv.) `log()`
  - Gör ett spridningsdiagram igen, ser det bättre ut map. linearitet?
  - Om inte - ytterligare transformation
  - Skatta modellen
  - Gå tillbaka till originalskala (ex: `exp()` om logtransformation av Y)
- Exempel på transformation i Gapmindergrafen (F3, F8, nästa sida)

BNP per capita och barnadödlighet (storlek på cirkel - (relativ) folkmängd)

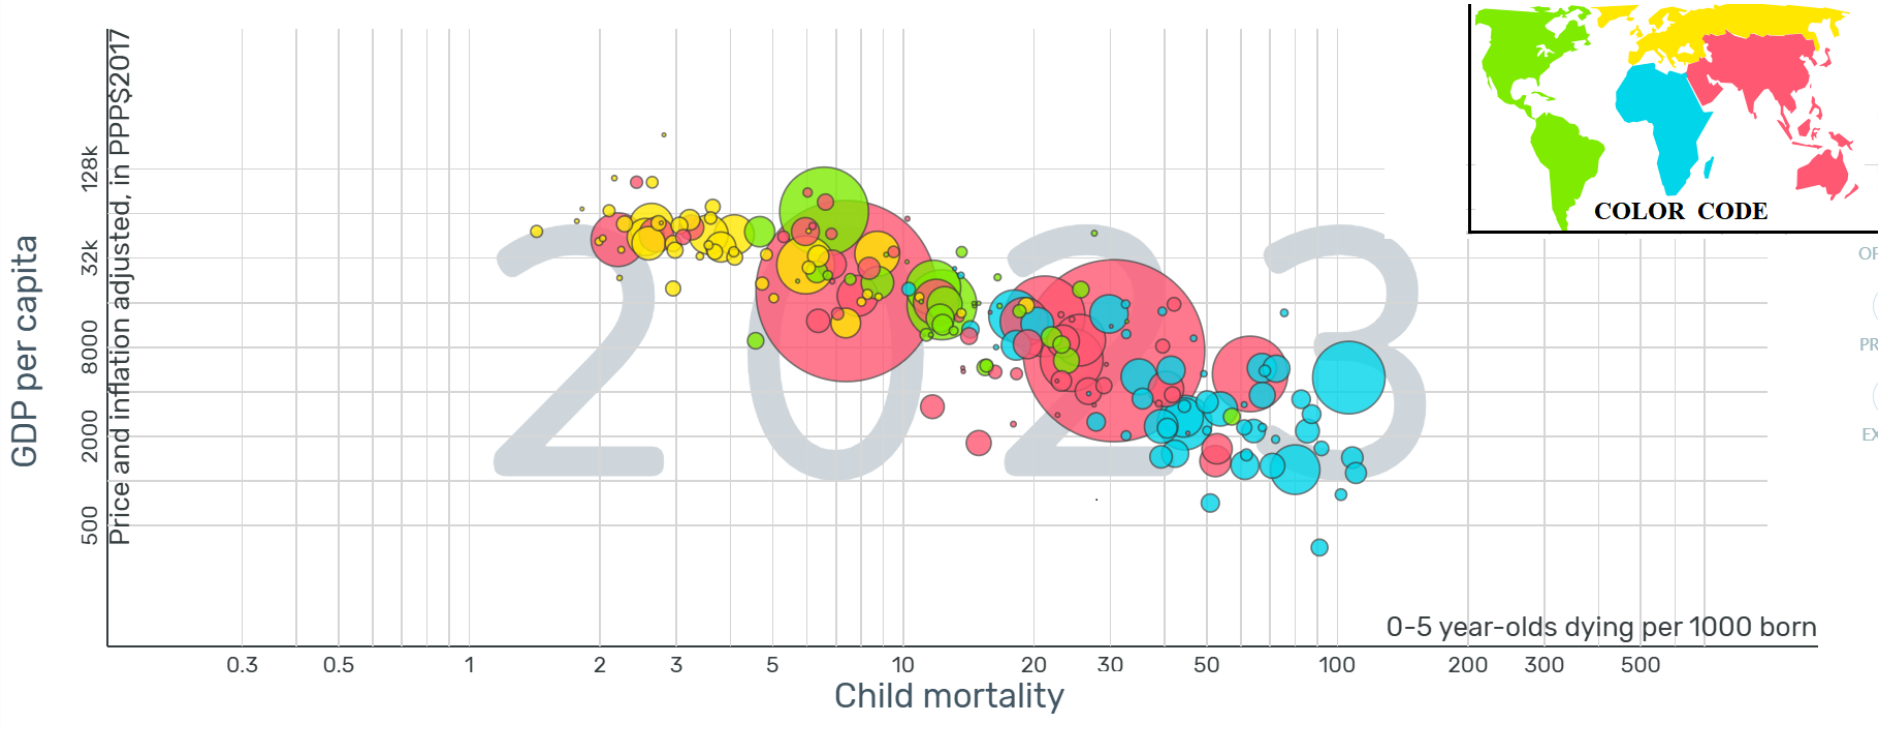

Källa: Gapminder

I denna graf är inte axlarna linjära - variablerna har **transformerats** (boken kap. 5.7).

Denna version av dokumentet: 2026-04-09

Materialet i Statistisk översiktskurs har tagits fram av Ulf Högnäs och Anders Fredriksson, med inspiration och ibland direkt användande av material från andra kurser och personer, bland annat kurserna Statistik och dataanalys 1-3, med material av Michael Carlson, Ellinor Fackle Fornius, Jessica Franzén, Oskar Gustafsson, Oscar Oelrich, Mona Sfaxi, Karl Sigfrid, Mattias Villani, Valentin Zulj, med flera.